

Consulte los debates, las estadísticas y los perfiles de los autores de esta publicación en: <https://www.researchgate.net/publication/323780357>

Un tutorial paso a paso para un BCI basado en imágenes motoras

Capítulo - Enero 2018

CITACIONES
12

LECTURAS
8,452

4 autores, entre ellos:



Hohyun Cho

Universidad de Washington en San
Luis

43 PUBLICACIONES 751 CITAS

VER PERFIL



Minkyu Ahn

Handong Global University

60 PUBLICACIONES 1.159 CITAS

VER PERFIL



Sung Chan Jun

Instituto de Ciencia y Tecnología de Gwangju

160 PUBLICACIONES 2.489 CITAS

VER PERFIL

Algunos de los autores de esta publicación también trabajan en estos proyectos relacionados:



Investigación de imágenes 3D estereoscópicas mediante EEG/MEG [Ver proyecto](#)



[Proyecto de Interacción Multicerebral](#)

Todo el contenido que sigue a esta página fue subido por [Hohyun Cho](#) el 18 de marzo de 2018.

El usuario ha solicitado la mejora del archivo descargado.

23 Un tutorial paso a paso para un BCI basado en imágenes motoras

*Hohyun Cho, Minkyu Ahn, Moonyoung Kwon
y Sung Chan Jun*

CONTENIDO

23.1	Introducción: BCI basado en imágenes motoras.....	446
23.2	Sesión de formación.....	446
23.2.1	Registro de los datos del IM.....	446
23.2.1.1	Dispositivo de grabación y software	446
23.2.1.2	Temas	447
23.2.1.3	Medio ambiente.....	447
23.2.1.4	Paradigma experimental	447
23.2.1.5	Instrucciones MI	449
23.2.1.6	Cuestionario.....	449
23.2.1.7	Discusiones.....	449
23.2.2	Algoritmos de formación y análisis de líneas	451
23.2.2.1	Preprocesamiento.....	451
23.2.2.3	Extracción de características.....	453
23.2.2.4	Clasificación.....	454
23.2.2.5	Discusión.....	456
23.3	Sesión de pruebas.....	456
23.3.1	Experimento en línea.....	456
23.3.2	Discusión	457
23.4	Resumen	458
	Agradecimientos.....	458
	Referencias.....	458

Resumen

La interfaz cerebro-ordenador (BCI) basada en la imaginería motora (MI) es uno de los conceptos estándar de la BCI, ya que el usuario puede generar actividad inducida desde el córtex motor imaginando movimientos motores sin ningún movimiento de las extremidades o estímulo externo. En este capítulo, presentamos un tutorial paso a paso sobre la ICM y discutimos los aspectos relacionados con cada paso. Describimos ejemplos detallados de nuestro experimento de IM con un procedimiento general desde la sesión de entrenamiento hasta la sesión de prueba. En la sesión de entrenamiento, introducimos y discutimos los dispositivos de grabación y el software, los ajustes experimentales, la recogida de datos de IM y los cuestionarios, el análisis de la línea para la inhibición del ritmo somatosensorial, y el entrenamiento de algoritmos simples de aprendizaje automático, incluyendo patrones espaciales comunes y el análisis discriminante lineal de Fisher. A continuación, introducimos los procedimientos básicos utilizados en la sesión de pruebas y discutimos cuestiones importantes, como las variabilidades de la sesión de la señal del electroencefalograma y la tasa de transferencia de información. Por último, resumimos el tutorial y enumeramos los problemas que quedan por resolver en la ICM.

23.1 INTRODUCCIÓN: IMÁGENES MOTORAS BCI

La interfaz cerebro-ordenador (BCI) de imaginería motora emplea la actividad cerebral endógena del usuario en ausencia de estímulos externos (Pfurtscheller y Da Silva 1999; Ramoser et al. 2000; Schalk et al. 2004; Wolpaw y Wolpaw 2012; Wolpaw et al. 1991). Un concepto estándar en BCI es la trans- lación de la intención del usuario a través de la imaginación mental del movimiento motor, que sirve de interfaz para comunicar la intención del usuario sin el movimiento de las extremidades. La aplicación más representativa de la ICM es la neurorrehabilitación, y los investigadores han informado de que la ICM repetitiva puede tener efectos positivos en dicha rehabilitación (Mattia et al. 2016; Pichiorri et al. 2015). Por lo tanto, la ICM sigue siendo un tema fascinante, aunque ya se ha investigado durante aproximadamente 20 años.

Al igual que otros paradigmas de ICB, el paradigma de ICM conlleva sesiones de entrenamiento y de prueba. En la sesión de entrenamiento, el experimentador recoge los datos de la IM de cada usuario, hace una extracción de características con ellos, y hace algoritmos de clasificación a través de los datos recogidos. Por lo tanto, es muy importante recoger datos de IM muy informativos, ya que pueden proporcionar una forma más fácil de entrenar los algoritmos. Si los datos contienen muchos artefactos, pueden requerir técnicas de preprocesamiento más complejas para eliminar o reducir los efectos no deseados de los artefactos. Durante la sesión de pruebas, los algoritmos ya entrenados se aplican a los nuevos datos de IM para su clasificación e n tiempo real. También es importante minimizar las diferencias psicológicas y ambientales entre las sesiones de entrenamiento y de prueba, ya que los algoritmos entrenados no funcionan propiamente en la sesión de prueba debido a la variabilidad entre sesiones de los electroencefalogramas (EEG).

En este capítulo, presentamos un tutorial paso a paso sobre la ICM. Describimos un experimento detallado de IM llevado a cabo en el laboratorio de BioComputing y, a continuación, analizamos los aspectos relacionados con cada paso. Este tutorial se compone principalmente de dos secciones: sesiones de entrenamiento y de prueba. En primer lugar, introducimos la forma de recopilar datos de alta calidad e informativos sobre el IM, así como varios algoritmos de extracción y clasificación de características, incluyendo el patrón espacial común (CSP) y el análisis discriminante lineal de Fisher (FLDA). A continuación, presentamos los procedimientos básicos utilizados en la sesión de prueba y revisamos brevemente las técnicas existentes utilizadas para superar la variabilidad entre las sesiones de entrenamiento y de prueba. Por último, resumimos el tutorial y enumeramos los problemas que quedan por resolver en la ICM.

23.2 SESIÓN DE FORMACIÓN

23.2.1 GRABACIÓN MI DATA

Aquí, presentamos los procedimientos involucrados en un experimento de IM en el laboratorio de BioComputing (<https://biocomput.gist.ac.kr>) en el Instituto de Ciencia y Tecnología de Gwangju (GIST), Corea del Sur. El acceso público a nuestro conjunto de datos estará disponible pronto en GigaDB (Cho et al. 2017). Al final de esta sección, discutimos posibles temas de investigación relacionados con las técnicas de registro, los sujetos, los entornos experimentales, los paradigmas experimentales, la instrucción de IM para los sujetos y los metadatos (cuestionario).

23.2.1.1 Dispositivo de grabación y software

Como muestra la Figura 23.1, utilizamos un montaje de 64 canales basado en el sistema internacional 10-10 para registrar las señales de EEG a velocidades de muestreo de 512 Hz. Cada sujeto llevaba un gorro de EEG. El dispositivo de EEG utilizado en este experimento fue el sistema Biosemi ActiveTwo (Ámsterdam, Países Bajos), que utiliza una batería de corriente continua (DC) como fuente de energía. Se utilizó el sistema BCI2000 3.0.2 (Schalk et al. 2004) para recoger los datos del EEG y presentar las instrucciones (MI izquierda o MI derecha). Además, registramos la electromiografía (EMG) y el EEG simultáneamente para comprobar los movimientos reales de la mano. Se colocaron cuatro electrodos EMG en el *lexor digitorum profundus* y en el *extensor digitorum* de ambos antebrazos.




FIGURA 23.1 Etiquetado de canales de EEG. (Adaptado de Cho, H., Ahn, M., Ahn, S., Kwon, M. y Jun, S.C., 2017. Conjuntos de datos de EEG para la interfaz cerebro-ordenador de imágenes motoras. *GigaScience*. DOI: <https://doi.org/10.1093/gigascience/gix034>. Copyright 2017 por GigaScience).

23.2.1.2 Temas

Llevamos a cabo un experimento de IM de las manos izquierda y derecha con 52 sujetos (19 mujeres, edad media \pm SD = $24,8 \pm 3,86$); la Junta de Revisión Institucional del GIST (2013-2) aprobó el experimento. En primer lugar, publicamos un aviso en el sitio web del GIST. Los estudiantes de posgrado y de grado, los empleados y el personal del campus participaron en este experimento. Todos los sujetos dieron su consentimiento informado para que los investigadores recogieran información sobre las señales cerebrales y se les pagó 30.000 wones coreanos (aproximadamente 27 dólares) después de participar en el experimento. Si los datos del IM de un sujeto eran discriminables -o si la precisión de la clasificación del IM izquierdo y del derecho era superior al 80%- le pagábamos el doble de la recompensa para fomentar la concentración de cada sujeto.

23.2.1.3 Medio ambiente

Todos los experimentos se realizaron en nuestro laboratorio durante una de las cuatro franjas horarias: T1 (9:30-12:00), T2 (12:30-15:00), T3 (15:30-18:00), o T4 (19:00-21:30), ya que nos interesaba saber si el rendimiento del ICB variaba con el tiempo. El nivel de ruido de fondo era de 37-39 decibelios debido a un aparato de aire acondicionado. Los experimentos comenzaron en agosto de 2011 y terminaron en septiembre de 2011.

23.2.1.4 Experimental Paradigma

Para cada sujeto, registramos los datos de los estados no relacionados con la tarea y (MI) relacionados con la tarea, de la siguiente manera:

Seis tipos de datos no relacionados con la tarea. Se registraron seis tipos de datos de ruido (parpadeo, movimiento del globo ocular hacia arriba/abajo, movimiento del globo ocular hacia la izquierda/derecha, movimiento de la cabeza, apretamiento de la mandíbula y estado de reposo) para los 52 sujetos. Cada tipo de ruido se recogió dos veces durante 5 s, excepto el estado de reposo, que se registró durante 60 s.

Experimento MI. El diseño experimental era casi el mismo que el del experimento de IG de Graz (Ramoser et al. 2000). Los sujetos se sentaron en una silla con reposabrazos y observaron un monitor. Al principio de cada ensayo, el monitor mostraba una pantalla negra con una cruz de fijación durante 2 s; a continuación, el sujeto se preparaba para imaginar los movimientos de la mano, y la pantalla daba una señal de preparado al sujeto. Como muestra la figura 23.2, una de las dos instrucciones ("mano izquierda" o "mano derecha")




FIGURA 23.2 Paradigma experimental. Un ensayo del experimento de IM. (Adaptado de Cho, H., Ahn, M., Ahn, S., Kwon, M. y Jun, S.C., 2017. Conjuntos de datos EEG para la interfaz cerebro-ordenador de imágenes motoras. *GigaScience*. DOI: <https://doi.org/10.1093/gigascience/gix034>. Copyright 2017 por GigaScience).

Aparecieron aleatoriamente en la pantalla durante 3 s, y se pidió a los sujetos que imaginaran el movimiento de la mano en función de la instrucción dada. Después de la imaginación, cuando aparecía la pantalla en blanco, el sujeto recibía una pausa aleatoria de 4,1 a 4,8 s. Estos procesos se repitieron 20 veces para una clase (una serie), y se realizaron cinco series. Después de cada carrera, se calculó la precisión de la clasificación en una carrera y se dio al sujeto información para aumentar su motivación. Entre cada carrera, los sujetos recibían un descanso de 4 m como máximo, según sus deseos. Si está interesado en una descripción más detallada de los procedimientos utilizados para establecer los parámetros y la configuración, recomendamos un tutorial de BCI de ritmo mu en BCI2000 wiki.

El procedimiento experimental completo se presenta en la tabla 23.1.

TABLA 23.1
Procedimiento experimental

Número	Tarea	Duración (min)
1	Rellenar el formulario de consentimiento y el cuestionario	10
2	Colocación de electrodos 2EEG	20
3	Adquisición de los seis tipos de datos no relacionados con la tarea	2
4	Practicar los movimientos reales de los dedos	3
5	RUN 1	6
6	Rellenar el cuestionario	4
7	RUN 2	6
8	Rellenar el cuestionario	4
9	RUN 3	6
10	Rellenar el cuestionario	4
11	RUN 4	6
12	Rellenar el cuestionario	4
13	RUN 5	6
14	Rellenar el cuestionario	4
15	Experimento en línea	6
16	Digitalización de las coordenadas 3D de los electrodos de EEG	15
17	Retirada de los electrodos y limpieza del laboratorio	20
Suma		126

Fuente: Adaptado de Cho, H., Ahn, M., Ahn, S., Kwon, M., y Jun, S.C., 2017. Conjuntos de datos EEG para la interfaz cerebro-ordenador de imágenes motoras. *GigaScience*. DOI: <https://doi.org/10.1093/gigascience/gix034>. Derechos de autor 2017 por GigaScience.




FIGURA 23.3 Instrucción de imágenes motoras. Pedimos a los sujetos que imaginaran cuatro movimientos reales de los dedos: tocar cada dedo índice, medio, anular y meñique con el pulgar en un plazo de 3 s. Antes de que comenzara el experimento de IM, los sujetos practicaron la ejecución de los cuatro movimientos en ese tiempo. (Adaptado de Cho, H., Ahn, M., Ahn, S., Kwon, M. y Jun, S.C., 2017. Conjuntos de datos EEG para la interfaz cerebro-ordenador de imágenes motoras. *GigaScience*. DOI: <https://doi.org/10.1093/gigascience/gix034>. Copyright 2017 por GigaScience).

23.2.1.5 MI Instrucciones

Antes de comenzar el experimento de IM, pedimos a cada sujeto que moviera sus dedos, comenzando por el dedo índice y continuando con el meñique (representado en la Figura 23.3) dentro de los 3 s siguientes al inicio. Cada sujeto practicó estos movimientos reales de los dedos antes de realizar el experimento de IM. Al imaginar el movimiento, pedimos a los sujetos que imaginaran la experiencia cinestésica, en lugar de la visual.

23.2.1.6 Cuestionario

Pedimos a los sujetos que rellenaran un cuestionario durante el experimento de IM, como se muestra en la Tabla 23.2. Antes de que comenzara el experimento de IM, los sujetos respondieron a 15 preguntas (preguntas 101 a 115). Después de cada ejecución, contestaron otras 10 preguntas (preguntas 210 a 219, 220 a 229, etc.). Tras el experimento de IM, pedimos a los sujetos que respondieran a una última serie de preguntas (preguntas 301 a 304). Todas las respuestas numéricas a las preguntas se almacenaron en un archivo de Microsoft Excel (Cho et al. 2017).

23.2.1.7 Discusiones

En esta sección, discutimos varios puntos que deben ser considerados en los experimentos de ICM, cada uno de los cuales puede ser un tema interesante para futuras investigaciones.

2321.7.1 Software y dispositivo de grabación

Es importante tener en cuenta el ruido de la línea cuando se registran datos de EEG. La potencia de la señal del ruido de línea de 50-60 Hz (220 o 110 V, respectivamente) es mucho mayor que la oscilación neural. Aunque existen soluciones de software para eliminar el ruido de línea (por ejemplo, el filtrado notch), el hardware de adquisición de datos que utiliza CC puede reducir el ruido de línea mucho más que los sistemas que utilizan corriente alterna, por ejemplo, el hardware basado en baterías. Por lo tanto, recomendamos un sistema de CC. Los ingenieros de hardware en el campo de la BCI están interesados en desarrollar electrodos inalámbricos, secos, concéntricos tripolares o EEG multimodales para estudiar usos más precisos y convenientes de la BCI (Ahn et al. 2016; Besio et al. 2006; Cincotti et al. 2006; Nguyen et al. 2016). Creemos que la cuestión más importante en la ingeniería de software es guardar los datos con la información de activación correcta y utilizar el EEG para estudiar experimentos precisos, basados en un solo ensayo y en tiempo real. La literatura (Wolpaw y Wolpaw 2012) incluye tipos representativos de software para experimentos de EEG: BCI2000 (Schalk et al. 2004), OpenVibe (Renard et al. 2010) y BCILAB (Kothe y Makeig 2013).

2321.7.2 Temas

El objetivo inicial de la investigación sobre los ICM de MI era proporcionar un nuevo canal de comunicación para las personas que están completamente paralizadas. Para estos pacientes, es muy útil incluso responder "sí" o "no" utilizando el IM de la mano izquierda y derecha. Hoy en día, los investigadores tienden a estudiar la IM para la neurorrehabilitación del ictus

TABLA 23.2**Cuestionario para el experimento de imágenes motoras**

Cuestionario		Identificación del sujeto:									
NúmeroInformación individual											
101	Hora (1 = 9:30; 2 = 12:30; 3 = 15:30; 4 = 19:00)										
102	Destreza (0 = izquierda; 1 = derecha; 2 = ambas)										
103	Edad (número)										
104	Sexo (0 = mujer; 1 = hombre)										
105	Experiencia en ICB (0 = no; número = cuántas veces)										
106	Experiencia en biorretroalimentación (0 = no; número = cuántas veces)										
Antes del experimento de imágenes motoras											
107.	3. ¿Cuánto tiempo has dormido? (1 = menos de 4 h; 2 = 5-6 h; 3 = 6-7 h; 4 = 7-8 h; 5 = más de 8 h)										
108.	4. ¿Ha tomado café en las últimas 24 horas? (0 = no; número = horas antes)										
109.	5. ¿Ha bebido alcohol en las últimas 24 horas (0 = no; número = horas antes)										
110.	6. ¿Ha fumado en las últimas 24 h (0 = no; número = horas antes)										
111.	7. ¿Cómo te sientes?		Relajado	1	2	3	4	5	Ansioso		
112.			Excitado	1	2	3	4	5	Aburrido		
113.	Estado físico		Muy bueno	1	2	3	4	5	Muy malo o cansado		
114.	Estado mental		Muy bueno	1	2	3	4	5	Muy malo o cansado		
115.	8. ¿Rendimiento del BCI (precisión) esperado? (%)										
Durante el experimento de imágenes motoras											
Carrera 1 (después de la primera carrera)											
210.	1. ¿Puede continuar con la siguiente carrera? (0 = No; 1 = Sí)										
211.	2. ¿Cómo te sientes?		Relajado	1	2	3	4	5	Ansioso		
212.			Excitado	1	2	3	4	5	Aburrido		
213.	Nivel de atención		Alto	1	2	3	4	5	Bajo		
214.	Estado físico		Muy bueno	1	2	3	4	5	Muy malo o cansado		
215.	Estado mental		Muy bueno	1	2	3	4	5	Muy malo o cansado		
216.	3. ¿Se ha quedado dormido durante esta carrera? (0 = no; número = cuántas veces)										
217.	4. ¿Fue fácil imaginar los movimientos de los dedos? Fácíl 1 2 3 4 5 Difícil										
218.	5. ¿Cuántas pruebas se han perdido? (0 = ninguna; número = cuántas veces)										
219.	6. ¿El rendimiento de tu BCI (precisión) para esta ejecución fue el que esperabas? (%) Carrera 2 (después de la segunda carrera)										
220-229	...										
Carrera 3 (después de la tercera carrera)											
230-239	...										
Carrera 4 (después de la cuarta carrera)											
240-249	...										
Carrera 5 (después de la quinta carrera)											
250-259	...										
Después del experimento de imágenes motoras											
301.	1. ¿Cómo fue este experimento?		Duración	Corto	1	2	3	4	5	Largo	
302.			Procedimiento	Bueno	1	2	3	4	5	Malo	
303.			Medio ambiente	Cómodo	1	2	3	4	5	Incómodo	
304.	2. ¿El rendimiento general del ICB (precisión) fue el que esperaba? (%)										

Fuente: Adaptado de Cho, H., Ahn, M., Ahn, S., Kwon, M., y Jun, S.C., 2017. Conjuntos de datos EEG para la interfaz cerebro-ordenador de imágenes motoras. *GigaScience*. DOI: <https://doi.org/10.1093/gigascience/gix034>. Derechos de autor 2017 por GigaScience.

pacientes. Los clínicos han informado de que la neuroretroalimentación con IM es eficaz para restablecer sus movimientos motores inmediatamente después de un accidente cerebrovascular (Mattia et al. 2016; Pichiorri et al. 2015). En el caso de los sujetos normales, los investigadores de la BCI se han interesado por la variación del rendimiento y la transferencia de sujeto a sujeto para proporcionar algoritmos independientes del sujeto (Blankertz et al. 2006; Fazli et al. 2009; Lotte et al. 2009; Reuderink et al. 2011; Samek et al. 2013; Tu y Sun 2012). Hay una fracción de usuarios analfabetos de BCI en los que es difícil detectar los ritmos μ de su corteza somatosensorial. La identificación y comprensión de las características neurofisiológicas y psicológicas que distinguen a los usuarios de alto y bajo rendimiento en la ICM son también un gran reto (Ahn et al. 2013; Ahn y Jun 2015; Blankertz et al. 2010).

2321.73 Medio ambiente

Los experimentos de BCI realizados en tiempo real y fuera del laboratorio están recibiendo más atención. La mayoría de estos estudios, incluido este experimento, se han realizado en un laboratorio relativamente silencioso (37-39 decibelios). Sin embargo, lo ideal sería poder llevar a cabo la ICB en cualquier lugar. Por ello, las cuestiones relativas al movimiento y al entorno son muy importantes.

2321.74 Paradigma experimental

El paradigma clásico de ICM presentado en esta sección es sencillo de seguir. Para obtener datos más informativos de la IM, se han propuesto el marco coadaptativo (Vidaurre et al. 2011), el marco instructivo (Jeunet et al. 2016) y la fusión del potencial evocado somatosensorial de estado estable y la IM (Ahn et al. 2014), utilizando el mismo tiempo de estímulo que en la experimentación en línea en la medida de lo posible (Cho et al. 2015).

2321.75 Instrucciones MI

Curiosamente, la instrucción óptima del IM sigue siendo desconocida. Aquí, adoptamos la imaginación de los movimientos complejos de los dedos, como se muestra en la Figura 23.3, basándonos en un tutorial sobre el ritmo μ en un taller de BCI2000 celebrado en 2011 que propuso el IM cinestésico y visual (Guillot et al. 2009; Neuper et al. 2005; Stinear et al. 2006). Stinear et al. (2006) informaron de que la IM cinestésica modula la excitabilidad corticomotora más que la IM visual. Además, se ha demostrado la velocidad del apretón imaginado (Yuan et al. 2010), y recientemente se ha propuesto un marco instructivo de la IM (Jeunet et al. 2016).

2321.76 Cuestionario

Aunque ya hemos indicado que el analfabetismo de la ICB, la variación del rendimiento y la transferencia de sujeto a sujeto son cuestiones complejas, comprender los metadatos de los sujetos también es un reto, incluyendo ejemplos como "mujer frente a hombre", "más joven frente a más viejo", tamaño de la cabeza, personalidad individual, etc.

23.2.2 ALGORITMOS DE FORMACIÓN Y ANÁLISIS OFFLINE

Aquí presentamos los procedimientos de preprocesamiento, entrenamiento del filtro espacial y selección de un clasificador en BioComputing. Al final de esta sección, discutimos los temas de investigación con respecto al preprocesamiento, el filtro de extracción de características de entrenamiento y la clasificación.

23.2.2.1 Preprocesamiento

Después de registrar los datos del IM, teníamos cinco archivos (*.dat) del sistema BCI2000 porque registramos cinco ejecuciones, como se muestra en la Tabla 23.1. BCI2000 proporciona un código MATLAB®, "BCI2000import.m", para convertir cada archivo *.dat al formato EEGlab de MATLAB. EEGlab es una conocida caja de herramientas de procesamiento de señales EEG (Delorme y Makeig 2004). En la estructura de datos de EEGlab, una variable "evento" contiene información de activación. La longitud de los datos de cada variable "evento" es la misma con respecto al número de estímulos. La variable "evento" incluye tres variables: latencia, posición y tipo.

La variable "latencia" contiene el valor del punto de tiempo de un estímulo disparado dentro de los datos de ejecución. La variable "posición" indica la posición de la matriz de estímulos de la configuración en BCI2000. Este valor puede considerarse una etiqueta de clase, ya que el primer y el segundo valor en nuestro experimento de IM son instrucciones de IM izquierda y derecha, como se muestra en la Figura 23.2. Por último, la variable "tipo" indica el tipo de código de estímulo. En un experimento en línea, hay muchos tipos de códigos de estímulo en BCI2000, por ejemplo, los códigos de estímulo, de objetivo y de retroalimentación, etc.; además, tenemos información de EEG y de disparo en bruto, incluyendo la latencia y las etiquetas de estímulo. Podemos extraer los datos de cada ensayo de cinco series de datos. Dependiendo de la latencia de cada estímulo (inicio), el marco de datos extraído estaba entre -2000 y 5000 ms. También realizamos el mismo procedimiento para los datos no relacionados con los ensayos.

23.2.2.1 Análisis fuera de línea

Comprobamos la desincronización/sincronización relacionada con eventos (ERD/ERS) del ritmo somatosensorial (SMR) para cada sujeto (Pfurtscheller y Da Silva 1999). Para calcular la ERD/ERS de cada canal, seguimos el mismo procedimiento que esos autores, utilizando los siguientes pasos:

- Filtrado de paso de banda de todos los ensayos a 8-30 Hz.
- Transformación de Hilbert de todos los ensayos.
- Tomando la magnitud absoluta para cada valor complejo de todos los ensayos.
- Promedio de la magnitud de las muestras transformadas de Hilbert en todos los ensayos.
- Realizamos la corrección de la línea de base para cada ensayo con el fin de obtener los valores porcentuales de ERD/ERS

utilizando la fórmula $ERD\% = \frac{A - R}{R} 100$, donde A es cada muestra de tiempo y R es la media valor del período de referencia, que estaba entre -500 y 0 ms.

La figura 23.4 ilustra los resultados de la ERD/ERS y muestra el promedio general de la ERD/ERS en 38 sujetos que tuvieron mejores tasas de clasificación que el azar. Trazamos la topografía y un gráfico de barras del periodo intensivo de ERD (500-2500 ms), como se muestra en la Figura 23.4b y c. El

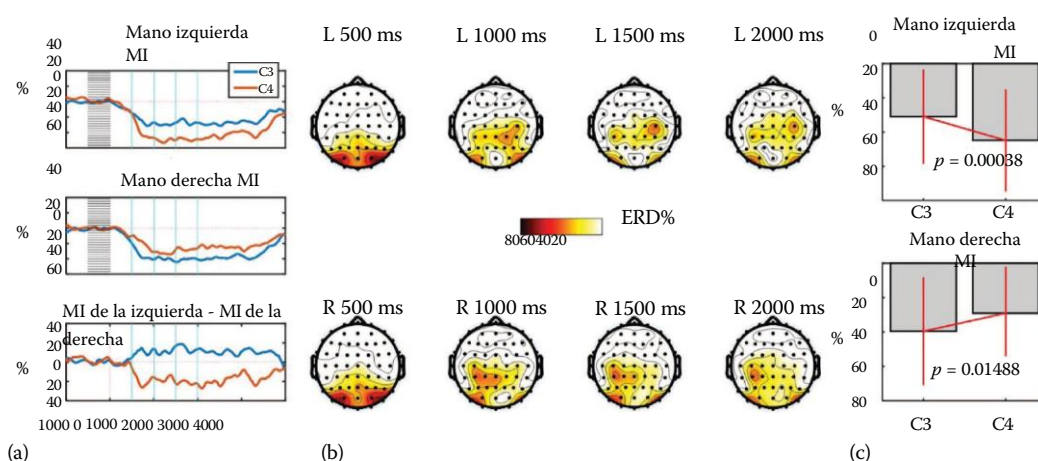


FIGURA 23.4 ERD de SMR (8-14 Hz) de sujetos discriminativos (38 sujetos). (a) La primera y la segunda fila muestran la ERD de los canales C3 y C4 en el MI izquierdo y derecho, respectivamente, y la última fila muestra la diferencia de ERD entre ambos. La región sombreada en gris es el periodo de referencia. Las líneas verticales cian representan puntos de tiempo, como 500, 1000, 1500 y 2000 ms. (b) Topografías de las ERDs en los puntos de tiempo coloreados en cian en (a). Las iniciales "L" y "R" indican los movimientos del IM izquierdo y derecho, respectivamente. (c) Comparación de la ERD en los canales C3 y C4 dentro de los 500-2500 ms. Los valores p se estimaron mediante la prueba t emparejada. (Adaptado de Cho, H., Ahn, M., Ahn, S., Kwon, M. y Jun, S.C., 2017. Conjuntos de datos EEG para la interfaz cerebro-ordenador de imágenes motoras. *GigaScience*. DOI: <https://doi.org/10.1093/gigascience/gix034>. Copyright 2017 por GigaScience).

Las topografías mostraron que las áreas central, parietal y occipital están implicadas en la tarea de IM. Los gráficos de barras del IM izquierdo muestran que el ERD contralateral (canal C4) fue más fuerte que el ERD ipsilateral (canal C3).

23.2.2.3 Característica Extracción

Para el algoritmo de entrenamiento, cada ensayo se filtró con un filtro de paso de banda de 8 a 30 Hz y se extrajo temporalmente 500-2500 ms después del inicio del estímulo. El rango de 8 a 30 Hz es una banda de frecuencia bien conocida del SMR o de los ritmos alfa y beta (Pfurtscheller y Da Silva 1999). Los investigadores han informado de que existen bandas de frecuencia individuales del SMR. Es posible mejorar la precisión de la clasificación aplicando bandas de frecuencia individuales del SMR para entrenar algoritmos (Ang et al. 2008; Cho et al. 2012, 2015; Dornhege et al. 2006; Lemm et al. 2005; Nikulin et al. 2011; Tomioka et al. 2006). Aquí, simplemente filtramos los datos espectralmente con una banda ancha de SMR. En el comportamiento temporal de la SMR, la inhibición comienza a los 500 ms y es bastante general para la mayoría de los sujetos (Pfurtscheller y Da Silva 1999). De forma similar a las diferencias individuales encontradas en la SMR, también existen ventanas temporales características individuales y conocerlas puede mejorar la precisión de la clasificación. Sin embargo, para simplificar nuestro tutorial paso a paso, aplicamos la misma ventana temporal a cada participante.

En el campo de la ICM basada en el EEG, el algoritmo CSP es un método muy conocido y eficiente que se utiliza para extraer características discriminativas de dos señales cerebrales condicionadas diferentes -generalmente, ICM izquierda/derecha (Blankertz et al. 2008; Fukunaga 1972; Koles 1991; Ramoser et al. 2000). El algoritmo CSP encuentra vectores que maximizan la varianza de una clase y simultáneamente minimizan la varianza de la otra. Los vectores son filtros espaciales comunes centrados en los canales que son muy eficaces para diferenciar las dos clases. Esto se expresa mediante el siguiente problema de optimización:

$$\mu \alpha \xi \frac{w^T C_i w}{w^T C_j w}, \quad (23.1)$$

donde T denota transposición, C_i es la matriz de covarianza espacial de X_i de la clase i , y X_i son los datos brutos de la clase i (matriz de tamaño # de canales \times # de las muestras de tiempo), asumiendo una media cero para las señales de EEG. Esta suposición suele cumplirse cuando las señales de EEG están filtradas por banda. El problema de optimización es equivalente a esta forma:

$$C_1 w \quad C_2 w. \quad (23.2)$$

Obtuvimos un problema de valores propios generalizado. Al resolver este problema, pudimos identificar los filtros, o los vectores propios correspondientes a los mayores valores propios. Nos referimos a los eigenvectores W filtros espaciales y $(W^{-1})^T$ patrones espaciales. Mientras tanto, podemos llamar al filtro W la matriz de desmezcla (modelo hacia atrás) y $(W)^{-1T}$ la matriz de mezcla (modelo hacia adelante) para los puntos de tiempo (Blankertz et al. 2008; Parra et al. 2005). Por ejemplo, si X es igual a los datos observados (datos mezclados), entonces $Z (=W^T X)$ son los datos proyectados (datos desmezclados o datos de origen). Así, $X (= (W^{-1})^T Z)$ son datos mezclados con diferentes fuentes en Z , y los valores en los filtros espaciales explican qué canales son importantes para extraer la característica de la fuente, mientras que los valores en los patrones espaciales explican qué fuentes son importantes para generar los datos mezclados X . Cuando utilizamos el CSP para la extracción de características, la señal del EEG se proyectó en los filtros w . A continuación, tomamos el logaritmo de la varianza de la señal de EEG proyectada. Como muestra la figura 23.5, w_1 y w_2 son los vectores propios correspondientes al valor propio más grande y al valor propio más pequeño obtenidos al resolver la ecuación 23.2. w_1 es para la clase 1 o MI de la izquierda, mientras que w_2 es para la clase 2 o MI de la derecha. Utilizando la función "eig()" en MATLAB, podemos obtener los filtros CSP fácilmente. Aquí, w_1 es un vector de 64×1 dimensiones debido al número de canales, como se muestra en la Figura 23.1. $X^{(k)}$ son los datos de prueba en una matriz de 64×1024 (= frecuencia de muestreo \times 2 s de ventana extraída).

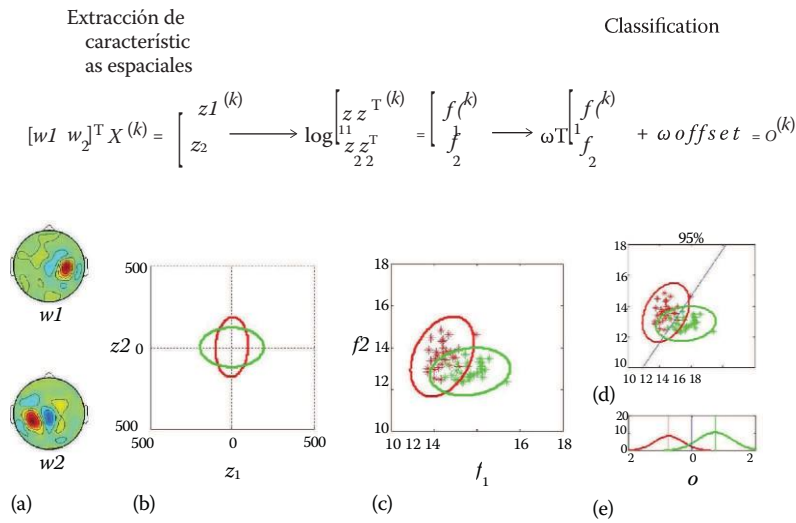


FIGURA 23.5 Modelo convencional CSP y FLDA: (a) filtros CSP; (b) varianza de la señal proyectada: el verde indica el MI de la izquierda y el rojo el MI de la derecha; (c) varianza logarítmica de la característica proyectada; (d) línea de discriminación del FLDA; y (e) distribuciones de los resultados del clasificador para dos clases. (Adaptado de Cho, H., Ahn, M., Kim, K. y Jun, S.C., 2015. Aumento de la transferencia de sesión a sesión en una interfaz cerebro-ordenador con adquisición de ruido de fondo in situ. *Journal of Neural Engineering*, 12 (6), 66009. Copyright 2015 por el *Journal of Neural Engineering*).

La figura 23.5a muestra que las topografías de w_1 y w_2 . $z_1 (= w_1^T \cdot X^{(k)})$ y $z_2 (= w_2^T \cdot X^{(k)})$ se proyectan datos. La figura 23.5b muestra la distribución a lo largo de los ejes z_1 y z_2 . Cada punto de la figura 23.5b es $(z_1(t), z_2(t))$, donde t es el índice de tiempo entre los 1024 puntos de tiempo. La figura 23.5b muestra dos distribuciones de un ensayo de MI izquierdo y datos de MI derecho. La distribución verde indica el MI izquierdo proyectado $X^{(k)}$, y la distribución roja indica el MI derecho proyectado $X^{(k)}$. Cada distribución se maximizó en el eje correspondiente. f_1 y f_2 son valores escalares. Como los datos proyectados son cuadrados, la distribución de los valores cuadrados no es gaussiana. Si tomamos el logaritmo de los datos al cuadrado, la variación de los valores grandes puede reducirse para obtener una distribución gaussiana. Esta variación logarítmica también ayuda a satisfacer el supuesto básico del FLDA, que es que los datos de dos clases tienen una distribución gaussiana. Por lo tanto, el número de estrellas rojas en la Figura 23.5c es igual al número de ensayos de entrenamiento. Figura

23.5c muestra las distribuciones de los ensayos para los datos del IM izquierdo y derecho. Finalmente, podemos obtener la matriz F_i ($2 \times \text{ensayos}$) para la clase i , donde $F = [F^{(1)}, F^{(2)}, \dots, F^{(N)}]$ y $F^{(k)} = [f_1^{(k)}, f_2^{(k)}]^T$.

23.2.2.4 Clasificación

Como muestra la Figura 23.5c, los datos de entrenamiento F_i están preparados para la clasificación. El FLDA es un clasificador simple utilizado frecuentemente en el campo de la BCI y asume que las dos distribuciones son gaussianas. Curiosamente, las funciones objetivo de FLDA también utilizan un cociente de Rayleigh similar a la función objetivo de CSP, como se muestra en la Ecuación 23.1. La fórmula del FLDA se expresa como

$$\max_w \frac{\sum_i (\mu_1 - \mu_2) \cdot (\mu_1 - \mu_2)^T}{\sum_w B}, \quad (23.3)$$

donde μ_B es $(\mu_1 - \mu_2) \cdot (\mu_1 - \mu_2)^T$, μ_i es un vector de medias de los datos de F_i de la clase i , y \sum_w es la suma de dos matrices de covarianza de F_1 y F_2 . Esta ecuación maximiza la diferencia entre los vectores de medias al tiempo que minimiza ambas covarianzas de los datos de dos clases. El problema de optimización puede resolverse como

$$S_B S_w \quad (23.4)$$

Aquí nos encontramos de nuevo con un problema de valores propios generalizado. Al resolver este problema, podemos obtener un vector propio ω correspondiente al mayor valor propio. El vector propio ω es la normal al hiperplano discriminante. El desplazamiento ω puede calcularse mediante $\omega^T \cdot 0,5 \cdot (\mu_1 + \mu_2)$. Por último, podemos clasificar un conjunto de datos de prueba asegurándonos de que $\omega^T \cdot F^{(k)} + \omega_{\text{offset}} > 0$. En la figura 23.5d, si $\omega^T \cdot F^{(k)} + \omega_{\text{offset}} > 0$, entonces la prueba puede clasificarse como datos de MI derecha.

Por último, realizamos una validación cruzada para calcular el rendimiento de nuestros datos de IM. Para cada clase, dividimos los 100 ensayos de datos de IM en 10 subconjuntos de 10 ensayos cada uno. Se eligieron siete subconjuntos al azar y se utilizaron para entrenar CSP y FLDA, y los tres subconjuntos restantes se utilizaron para probarlos. Este procedimiento se repitió 120 veces eligiendo 3 de los 10 subconjuntos al azar. Finalmente, se estimaron y promediaron 120 precisiones de clasificación.

La precisión media del rendimiento de la BCI en los 50 sujetos, excluyendo los malos, fue del 67,46% ($\pm 13,17\%$) en nuestros conjuntos de datos. En el conjunto de datos BCI2000 MI (EEG Motor Movement/Imagery Dataset 2016; Goldberger et al. 2000; Schalk et al. 2004), la precisión media fue del 60,42% ($\pm 11,68\%$) en 109 sujetos utilizando CSP y FLDA. En nuestros conjuntos de datos, 14 sujetos (26,92% de 52 sujetos) mostraron un bajo rendimiento de la BCI (por debajo del azar, que es el límite superior de confianza del azar con $\alpha = 5\%$), como se muestra en la Figura 23.6. Esto es mayor que un informe sobre 99 sujetos (Guger et al. 2003) y mostró que el 6,7% de los sujetos tenían precisiones inferiores al 60% (aquí, no se informó de la precisión media sobre los 99 sujetos). En comparación con el EEG Motor Movement/Imagery Dataset (2016), nuestros conjuntos de datos incluían más ensayos, aunque rechazamos los ensayos malos y los excluimos de los resultados. El EEG Motor Movement/Imagery Dataset (2016) incluye datos de MI para 109 sujetos, pero el número de ensayos totales para cada sujeto es de aproximadamente 20 ensayos, lo que tiene un nivel de azar del 65% ($\alpha = 5\%$).

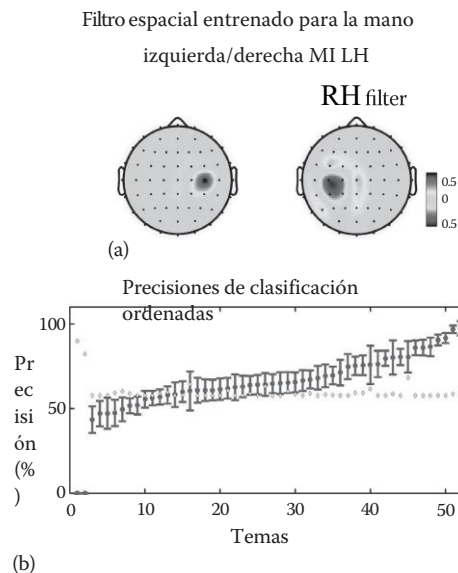


FIGURA 23.6 Filtros CSP entrenados para los datos de imágenes motoras de la mano izquierda y derecha y resultados de clasificación cruzados y validados. (a) Para demostrar la característica discriminativa de nuestro conjunto de datos, los filtros CSP fueron entrenados por la matriz de covarianza media de treinta y ocho sujetos que tienen un alto rendimiento de BCI ($>$ azar). (b) Resultados de clasificación validados de forma cruzada. Las precisiones clasificadas se muestran en orden creciente. Catorce sujetos mostraron un rendimiento de BCI bajo ($<$ azar marcado con un diamante amarillo). Debido a la clasificación, el número en el eje x no corresponde a los números de sujetos "s01" a "s52". (Adaptado de Cho, H., Ahn, M., Ahn, S., Kwon, M. y Jun, S.C., 2017. Conjuntos de datos EEG para la interfaz cerebro-ordenador de imágenes motoras. *GigaScience*. DOI: <https://doi.org/10.1093/gigascience/gix034>. Copyright 2017 por GigaScience).

23.2.2.5 Discusión

23.2.2.5.1 Preprocesamiento

En cualquier ensayo, diversos artefactos -ruido relacionado con el movimiento, parpadeo, movimiento ocular, ruido relacionado con el corazón, etc.- pueden contaminar los datos. En este tutorial, simplemente utilizamos un filtro de paso de banda de 8 a 30 Hz para eliminar el ruido relacionado con los ojos por encima de la marca de 8 Hz. Para eliminar el ruido relacionado con el parpadeo de los ojos o el corazón, un análisis de componentes independientes es una solución mejor que el filtro de paso de banda. En este caso, recomendamos utilizar la caja de herramientas MATLAB de EEGLab (Delorme y Makeig 2004; Wang et al. 2012). Para extraer un EEG fiable y estacionario, se ha propuesto el análisis del subespacio estacionario (von Bünaú et al. 2009) y la descomposición espacio-espectral (Nikulin et al. 2011).

23.2.2.5.2 Análisis fuera de línea

La comprensión de la RMS de la IM puede mejorar la selección de hiperparámetros para el entrenamiento de los algoritmos de extracción y clasificación de características. El análisis *r-cuadrado* es un método bien conocido que se utiliza para identificar bandas de frecuencia individuales (Schalk et al. 2004). En su apéndice, Blankertz et al. (2008) introdujeron algoritmos sencillos para identificar ventanas de tiempo y bandas de frecuencia discriminantes. Para seleccionar la mejor banda de frecuencias, el algoritmo calcula las correlaciones entre cada punto de un canal utilizando una matriz de frecuencias de ensayos MI y etiquetas de clase. De forma similar a la selección de la banda de frecuencia, el algoritmo utilizado para localizar la mejor ventana temporal de IM calcula las correlaciones entre cada punto de un canal utilizando una matriz temporal de ensayos con transformación de Hilbert absoluta y etiquetas de clase. Por lo tanto, el rendimiento de la BCI puede mejorarse utilizando los resultados del análisis offline para identificar las bandas de frecuencia y las ventanas temporales individuales. Además, se pueden utilizar las conocidas cajas de herramientas MATLAB de análisis offline EEGLab (Delorme y Makeig 2004) y Fieldtrip (Oostenveld et al. 2010).

23.2.2.5.3 Extracción de características

Debido a las propiedades espaciales de las IM izquierda y derecha, el CSP es un método muy potente. Como se muestra en la figura 23.4, las características espaciales de la IM izquierda pueden observarse en el área sensoriomotora derecha, mientras que las características espaciales de la IM derecha pueden observarse en el área sensoriomotora izquierda. Desde que se propuso el CSP por primera vez hace aproximadamente una década, se han desarrollado muchas variantes de algoritmos de CSP, y se han propuesto numerosas ideas de CSP para superar la variación de la sesión y del sujeto. De forma representativa, la teoría del CSP regularizado adopta dos enfoques para regularizar el algoritmo del CSP: regularizar la matriz de covarianza y la función objetivo del CSP (Lotte y Guan 2011). Además, la ampliación del espacio de características espaciales también puede mejorar el rendimiento de la BCI con respecto a la variación de la sesión y del sujeto.

23.2.2.5.4 Clasificación

Una revisión de los métodos de clasificación para BCI (Lotte et al. 2007) mostró que una máquina de vectores de apoyo (SVM) era el mejor clasificador entre los algoritmos existentes. En comparación con el FLDA, la SVM es un sistema exitoso para clasificar los valores atípicos y, por lo tanto, es un clasificador más universal que el FLDA. Anteriormente, había pocos estudios que abordaran la red neuronal profunda (Sakhavi et al. 2015; Walker et al. 2015). Sin embargo, un estudio reciente sobre este tema mostró resultados convincentes. La DNN acomoda tanto la extracción de características como la clasificación en una sola estructura. Para lograr un mejor rendimiento de la BCI, el enfoque de la DNN requiere más investigación de sus hiperparámetros (número óptimo de capas, funciones de activación, etc.) y análisis de pesos. Tras el entrenamiento de la DNN, ¿cuál es el significado de los pesos en las capas con respecto al procesamiento de la señal?

23.3 PRUEBA SESIÓN

23.3.1 EXPERIMENTO EN LÍNEA T

En cualquier sesión de prueba, el método utilizado para clasificar los nuevos datos en gran medida es el mismo que el utilizado en las sesiones de entrenamiento. En nuestras sesiones de prueba se

Un tutorial paso a paso para un BCI basado en imágenes

457

procesaron nuevos datos cada 2 s. En la Figura 23.7 se muestra un ensayo del paradigma experimental online implementado por el sistema BCI2000. Se utilizó el




FIGURA 23.7 Paradigma experimental en línea. La bola amarilla está controlada por los datos recogidos de 0 a 2 s después de la señal (azul). El punto rojo en la pantalla era el punto de fijación. (Adaptado de Cho, H., Ahn, M., Kim, K., y Jun, S.C., 2015. Aumento de la transferencia de sesión a sesión en una interfaz cerebro-ordenador con adquisición de ruido de fondo in situ. *Journal of Neural Engineering*, 12 (6), 66009. Copyright 2015 por el *Journal of Neural Engineering*).

El módulo de adquisición de Biosemi para la adquisición de señales y adoptó el módulo de procesamiento de señales de MATLAB para cargar los pesos entrenados de CSP y FDLA y para clasificar los nuevos datos en tiempo real. El módulo de aplicación era una aplicación de tarea de cursor con una ventana deslizante de 2 s. Tras el descanso de 2 s, se mostraron 2 s de instrucción de IM como una barra gris. Tras esta instrucción, el sujeto realizaba el IM a la izquierda o a la derecha. Si aparecía una barra gris en el lado derecho, el sujeto debía imaginar los movimientos de los dedos de la mano derecha. Este periodo de 2 s fue clasificado por CSP y FLDA entrenados en el módulo de procesamiento de señales de MATLAB, y el resultado clasificado se transmitió a la aplicación de la tarea del cursor. Finalmente, después del periodo de imaginación de 2 s, el cursor se movió de acuerdo con el resultado clasificado, como se muestra en la Figura 23.7. Estos nuevos datos fueron filtrados con paso de banda a 8-30 Hz, filtrados espacialmente por CSP, y la característica extraída fue clasificada por FLDA, como se muestra en la Figura 23.5. Aquí, el tamaño de la ventana deslizante fue de 2 s porque fue el periodo utilizado en la sesión de entrenamiento.

23.3.2 DISCUSIÓN N

De forma representativa, se recomiendan BCI2000 (Schalk et al. 2004) y OpenVibe (Renard et al. 2010) para la retroalimentación de BCI en línea. Para los principiantes en BCI, OpenVibe es fácil de usar porque soporta un lenguaje gráfico. Sin embargo, según nuestra experiencia, debido al lenguaje gráfico, OpenVibe requiere espacios de memoria relativamente grandes. Por ello, el sistema BCI2000 es más ligero que OpenVibe.

Una limitación de nuestro experimento en línea fue el desajuste entre las ventanas temporales presentadas. Mientras que la ventana temporal de la sesión de entrenamiento era de 500-2500 ms después del inicio, la ventana temporal de los nuevos datos clasificados era de 0-2000 ms. Para superar este problema de desajuste, aplicamos un paradigma experimental en línea utilizado en sesiones de entrenamiento en otro trabajo (Cho et al. 2015). Para la clasificación de datos MI, es muy importante extraer la ventana de tiempo más discriminativa para los datos offline en los algoritmos de entrenamiento. El paradigma experimental en línea de este capítulo se incluyó en la BCI sincrónica, que tiene claves de ensayo y estímulo. En el caso de la BCI asíncrona, que no tiene inicio de instrucción ni señal, reconocer las auto-señales del usuario también es un reto, por ejemplo, clasificar los estados de reposo y de tarea.

Para minimizar la brecha entre las sesiones de entrenamiento y de prueba, los investigadores de BCI han propuesto enfoques adaptativos y coadaptativos (Baldwin y Penaranda 2012; Satti et al. 2010; Shenoy et al. 2006; Shin et al. 2015; Sun y Zhang 2006; Vidaurre et al. 2011). Aquí, "adaptativo" significa "dejar que la máquina aprenda en tiempo real" y "coadaptativo" significa "dejar que tanto el usuario como la máquina aprendan." En el enfoque adaptativo, el CSP o el FLDA se actualizaron con nuevos datos después de cada ensayo en línea. Controlar la tasa de aprendizaje o el gradiente era un reto. El enfoque coadaptativo mostró un mejor rendimiento de la ICB y una posible solución al analfabetismo de la ICB. Además, hay otras razones que explican el desfase entre las sesiones de entrenamiento y las de prueba, como las diferencias psicológicas y ambientales, entre otras. Por lo tanto, minimizar el desfase entre las sesiones de entrenamiento y las de prueba sigue siendo una cuestión difícil de resolver.

Un punto que faltaba en la sección de sesiones de entrenamiento era la tasa de transferencia de información (ITR), que proporciona una evaluación general del rendimiento de la ICB. En

BCI con respecto a la interacción persona-ordenador. Al principio de la investigación de la BCI, muchas personas estaban interesadas en ella porque puede proporcionar un nuevo canal de comunicación sin ningún movimiento de las extremidades; sin embargo, el ITR en la BCI es mucho más bajo que el de otras interfaces de entrada, incluyendo el teclado, el ratón y el joystick. Muy pocos estudios (Bin et al. 2011; Wang et al. 2008) han mostrado un ITR que supera los 100 bits/min (no basado en MI). A modo de comparación, los ITRs utilizando un teclado o un ratón son de 900 bits/min y unos cientos de bits por minuto, respectivamente (Clerc et al. 2016). Si una BCI pudiera demostrar de alguna manera una tasa similar a la del uso del teclado, sería muy innovador.

23.4 RESUMEN

En este capítulo, proporcionamos un tutorial paso a paso de la ICM y discutimos temas de investigación relacionados con cada paso. En las sesiones de entrenamiento, detallamos los temas de registro de datos, incluyendo el software, el dispositivo, el entorno, el paradigma experimental, la instrucción MI y el cuestionario, el análisis de línea y los algoritmos de entrenamiento. En la sesión de pruebas, introducimos un procedimiento sencillo de aplicación de la tarea del cursor y discutimos la ventana de tiempo y las cuestiones sincrónicas y asincrónicas.

No sólo proporcionamos un tutorial paso a paso, sino que también discutimos posibles formas de mejorar la calidad de los datos y el rendimiento de la ICM. Seleccionamos las cuestiones más prometedoras, aunque desafiantes, de la siguiente manera: dispositivo de grabación, paradigma experimental o instrucción de IM, análisis de metadatos para la variación del sujeto/sesión o analfabetismo de la BCI, DNN, BCI de IM asíncrona e ITR. Los investigadores de la BCI han realizado enormes esfuerzos para resolver estos problemas. Por ello, esperamos que en un futuro próximo se desarrollen más BCI innovadoras y fáciles de usar.

AGRADECIMIENTOS

Este trabajo fue apoyado por la subvención del Instituto para la Promoción de la Tecnología de la Información y las Comunicaciones (IITP) financiada por el gobierno coreano (Nº 2017-0-00451) y el Ministerio de Cultura, Deportes y Turismo (MCST) y la Agencia de Contenido Creativo de Corea (KOCCA) en el Programa de Investigación y Desarrollo de Tecnología Cultural (CT) 2017.

REFERENCIAS

- Ahn, M., Cho, H., Ahn, S., y Jun, S.C., 2013. Altas potencias theta y bajas alfa pueden ser indicativas de analfabetismo BCI en la imaginación motora. *PloS one*, 8 (11), e80886.
- Ahn, M. y Jun, S.C., 2015. Variación del rendimiento en la interfaz cerebro-ordenador de imágenes motoras: Una breve revisión. *Journal of Neuroscience Methods*, 243, 103-110.
- Ahn, S., Ahn, M., Cho, H., y Jun, S.C., 2014. Lograr una interfaz cerebro-ordenador híbrida con atención selectiva táctil e imágenes motoras. *Journal of Neural Engineering*, 11 (6), 66004.
- Ahn, S., Nguyen, T., Jang, H., Kim, J.G., y Jun, S.C., 2016. Explorando los correlatos neurofisiológicos de la fatiga mental de los conductores causada por la privación del sueño utilizando datos simultáneos de EEG, ECG y fNIRS. *Fronteras de la Neurociencia Humana*, 10.
- Ang, K.K., Chin, Z.Y., Zhang, H., y Guan, C., 2008. Filter bank common spatial pattern (FBCSP) in brain-computer interface. En: *Neural Networks, 2008. IJCNN 2008 (IEEE World Congress on Computational Intelligence)*. *IEEE International Joint Conference on*. IEEE, 2390-2397.
- Baldwin, C.L. y Penaranda, B.N., 2012. Adaptive training using an artificial neural network and EEG metrics for within-and cross-task workload classification. *NeuroImage*, 59 (1), 48-56.
- Besio, G., Koka, K., Aakula, R., y Dai, W., 2006. Desarrollo de un electrodo de anillo concéntrico tripolar para la electroencefalografía laplaciana. *IEEE Transactions on Biomedical Engineering*, 53 (5), 926-933.
- Bin, G., Gao, X., Wang, Y., Li, Y., Hong, B., y Gao, S., 2011. Un BCI de alta velocidad basado en VEP de modulación de código. *Journal of Neural Engineering*, 8 (2), 25015.
- Blankertz, B., Dornhege, G., Krauledat, M., Müller, K.-R., Kunzmann, V., Losch, F., y Curio, G., 2006. La interfaz cerebro-ordenador de Berlín: Comunicación basada en EEG sin entrenamiento del sujeto. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 14 (2), 147-152.
- Blankertz, B., Sannelli, C., Halder, S., Hammer, E.M., Kübler, A., Müller, K.-R., Curio, G., y Dickhaus, T., 2010. Predictor neurofisiológico del rendimiento del BCI basado en SMR. *Neuroimage*, 51 (4), 1303-1309.

- Blankertz, B., Tomioka, R., Lemm, S., Kawanabe, M., y Muller, K.-R., 2008. Optimización de filtros espaciales para el análisis robusto de un solo ensayo de EEG. *IEEE Signal Processing Magazine*, 25 (1), 41-56.
- von Büna, P., Meinecke, F.C., y Müller, K.-R., 2009. Análisis del subespacio estacionario. En: *International Conference on Independent Component Analysis and Signal Separation*. Springer, 1-8.
- Cho, H., Ahn, M., Ahn, S., y Jun, S.C., 2012. Patrones espacio-espectrales comunes invariantes. En: *Proc. of TOBI 3rd Workshop*. 31-32.
- Cho, H., Ahn, M., Ahn, S., Kwon, M., y Jun, S.C., 2017. Conjuntos de datos EEG para la interfaz cerebro-ordenador de imágenes motoras. *GigaScience*. DOI: <https://doi.org/10.1093/gigascience/gix034>
- Cho, H., Ahn, M., Kim, K., y Jun, S.C., 2015. Aumento de la transferencia de sesión a sesión en una interfaz cerebro-ordenador con adquisición de ruido de fondo in situ. *Journal of Neural Engineering*, 12 (6), 66009.
- Cincotti, F., Bianchi, L., Birch, G., Guger, C., Mellinger, J., Scherer, R., Schmidt, R.N., Suárez, O.Y., y Schalk, G., 2006. BCI Meeting 2005-Workshop on technology: Hardware and software. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 14 (2), 128-131.
- Clerc, M., Bougrain, L., y Lotte, F., 2016. *Brain-Computer Interfaces 1: Methods and Perspectives*. John Wiley & Sons.
- Delorme, A. y Makeig, S., 2004. EEGLAB: An open source toolbox for analysis of single-trial EEG dynamics including independent component analysis. *Journal of Neuroscience Methods*, 134 (1), 9-21.
- Dornhege, G., Blankertz, B., Krauledat, M., Losch, F., Curio, G., y Muller, K.-R., 2006. Optimización combinada de filtros espaciales y temporales para mejorar la interfaz cerebro-ordenador. *IEEE Transactions on Biomedical Engineering*, 53 (11), 2274-2281.
- EEG Motor Movement/Imagery Dataset [en línea], 2016. Disponible en: <https://physionet.org/pn4/eegmmidb/> [Consultado el 20 de diciembre de 2016].
- Fazli, S., Popescu, F., Danóczy, M., Blankertz, B., Müller, K.-R., y Grozea, C., 2009. Clasificación del estado mental independiente del sujeto en ensayos individuales. *Neural Networks*, 22 (9), 1305-1312.
- Fukunaga, K., 1972. *Introduction to Statistical Pattern Recognition*. Academic Press.
- Goldberger, A.L., Amaral, L.A.N., Glass, L., Hausdorff, J.M., Ivanov, P.C., Mark, R.G., Mietus, J.E., Moody, G.B., Peng, C.-K., y Stanley, H.E., 2000. PhysioBank, PhysioToolkit y PhysioNet. *Circulation*, 101 (23), e215-e220.
- Guger, C., Edlinger, G., Harkam, W., Niedermayer, I., y Pfurtscheller, G., 2003. ¿Cuántas personas son capaces de manejar una interfaz cerebro-ordenador (BCI) basada en el EEG? *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 11 (2), 145-147.
- Guillot, A., Collet, C., Nguyen, V.A., Malouin, F., Richards, C., y Doyon, J., 2009. Brain activity during visual versus kinesthetic imagery: Un estudio de IRMf. *Human Brain Mapping*, 30 (7), 2157-2172.
- Jeunet, C., Jahanpour, E., y Lotte, F., 2016. Por qué hay que cambiar los protocolos de formación de la interfaz cerebro-ordenador (BCI) estándar: Un estudio experimental. *Journal of Neural Engineering*, 13 (3), 36024.
- Koles, Z.J., 1991. La extracción cuantitativa y el mapeo topográfico de los componentes anormales en el EEG clínico. *Electroencefalografía y Neurofisiología Clínica*, 79 (6), 440-447.
- Kothe, C.A. y Makeig, S., 2013. BCILAB: Una plataforma para el desarrollo de interfaces cerebro-ordenador. *Journal of Neural Engineering*, 10 (5), 56014.
- Lemm, S., Blankertz, B., Curio, G., y Muller, K.-R., 2005. Spatio-spectral filters for improving the classification of single trial EEG. *IEEE Transactions on Biomedical Engineering*, 52 (9), 1541-1548.
- Lotte, F., Congedo, M., Lécuyer, A., Lamarche, F., y Arnaldi, B., 2007. A review of classification algorithms for EEG-based brain-computer interfaces. *Journal of Neural Engineering*, 4 (2), R1.
- Lotte, F., Guan, C., y Ang, K.K., 2009. Comparación de diseños hacia una interfaz cerebro-ordenador independiente del sujeto basada en imágenes motoras. En: *2009 Annual International Conference of the IEEE Engineering in Medicine and Biology Society*. IEEE, 4543-4546.
- Lotte, F. y Guan, C., 2011. Regularización de patrones espaciales comunes para mejorar los diseños de BCI: teoría unificada y nuevos algoritmos. *IEEE Transactions on biomedical Engineering*, 58 (2), 355-362.
- Mattia, D., Astolfi, L., Toppi, J., Petti, M., Pichiorri, F., y Cincotti, F., 2016. Interfaz entre el cerebro y el ordenador en la neurorrehabilitación. En: *Brain-Computer Interface (BCI), 2016 4th International Winter Conference on*. IEEE, 1-2.
- Neuper, C., Scherer, R., Reiner, M., y Pfurtscheller, G., 2005. Imaginería de acciones motoras: Efectos diferenciales del modo cinestésico y visual-motor de la imaginería en el EEG de un solo ensayo. *Cognitive Brain Research*, 25 (3), 668-677.
- Nguyen, T., Ahn, S., Jang, H., Jun, S.C., y Kim, J.G., 2016. Applying support vector machine on hybrid fNIRS/EEG signal to classify driver's conditions (Presentación en conferencia). En: *SPIE BiOS. International Society of Optical and Photonics*, 969003-969003.
- Nikulin, V.V., Nolte, G., y Curio, G., 2011. A novel method for reliable and fast extraction of neuronal EEG/MEG oscillations on the basis of spatio-spectral decomposition. *NeuroImage*, 55 (4), 1528-1535.

- Oostenveld, R., Fries, P., Maris, E., y Schoffelen, J.-M., 2010. FieldTrip: Software de código abierto para el análisis avanzado de MEG, EEG y datos electrofisiológicos invasivos. *Computational Intelligence and Neuroscience*, 2011, e156869.
- Parra, L.C., Spence, C.D., Gerson, A.D., y Sajda, P., 2005. Recetas para el análisis lineal del EEG. *Neuroimage*, 28 (2), 326-341.
- Pfurtscheller, G. y Da Silva, F.L., 1999. Event-related EEG/MEG synchronization and desynchronization: basic principles. *Clinical Neurophysiology*, 110 (11), 1842-1857.
- Pichiorri, F., Morone, G., Petti, M., Toppi, J., Pisotta, I., Molinari, M., Paolucci, S., Inghilleri, M., Astolfi, L., Cincotti, F., y otros, 2015. La interfaz cerebro-ordenador potencia la práctica de imágenes motoras durante la recuperación del ictus. *Anales de Neurología*, 77 (5), 851-865.
- Ramoser, H., Muller-Gerking, J., y Pfurtscheller, G., 2000. Filtrado espacial óptimo del EEG de un solo ensayo durante el movimiento imaginado de la mano. *IEEE Transactions on Rehabilitation Engineering*, 8 (4), 441-446.
- Renard, Y., Lotte, F., Gibert, G., Congedo, M., Maby, E., Delannoy, V., Bertrand, O., y Lécuyer, A., 2010. Openvibe: Una plataforma de software de código abierto para diseñar, probar y utilizar interfaces cerebro-ordenador en entornos reales y virtuales. *Presence: Teleoperadores y Entornos Virtuales*, 19 (1), 35-53.
- Reuderink, B., Farquhar, J., Poel, M., y Nijholt, A., 2011. Una interfaz cerebro-ordenador independiente del sujeto basada en una línea de base suavizada de segundo orden. En: *2011 Annual International Conference of the IEEE Engineering in Medicine and Biology Society*. IEEE, 4600-4604.
- Sakhavi, S., Guan, C., y Yan, S., 2015. Red neuronal convolucional-lineal paralela para la clasificación de imágenes motoras. En: *Signal Processing Conference (EUSIPCO), 2015 23rd European*. IEEE, 2736-2740.
- Samek, W., Meinecke, F.C., y Müller, K.R., 2013. Transferencia de subespacios entre sujetos en la interfaz cerebro-ordenador. *IEEE Transactions on Biomedical Engineering*, 60 (8), 2289-2298.
- Satti, A., Guan, C., Coyle, D., y Prasad, G., 2010. A covariate shift minimisation method to alleviate non-stationarity effects for an adaptive brain-computer interface. En: *Pattern Recognition (ICPR), 2010 20th International Conference on*. IEEE, 105-108.
- Schalk, G., McFarland, D.J., Hinterberger, T., Birbaumer, N., y Wolpaw, J.R., 2004. BCI2000: A general-purpose brain-computer interface (BCI) system. *IEEE Transactions on Biomedical Engineering*, 51 (6), 1034-1043.
- Shenoy, P., Krauledat, M., Blankertz, B., Rao, R.P.N., y Müller, K.-R., 2006. Towards adaptive classification for BCI. *Journal of Neural Engineering*, 3 (1), R13.
- Shin, Y., Lee, S., Ahn, M., Cho, H., Jun, S.C., y Lee, H.-N., 2015. Simple adaptive sparse representation based classification schemes for EEG based brain-computer interface applications. *Computers in Biology and Medicine*, 66, 29-38.
- Stinear, C.M., Byblow, W.D., Steyvers, M., Levin, O., y Swinnen, S.P., 2006. Las imágenes motoras cinestésicas, pero no visuales, modulan la excitabilidad corticomotora. *Experimental Brain Research*, 168 (1-2), 157-164.
- Sun, S. y Zhang, C., 2006. Adaptive feature extraction for EEG signal classification. *Medical and Biological Engineering and Computing*, 44 (10), 931-935.
- Tomioka, R., Dornhege, G., Nolte, G., Blankertz, B., Aihara, K., y Müller, K.-R., 2006. Algoritmo de patrón espacial común ponderado espectralmente para la clasificación de un solo ensayo de EEG. *Dept. Math. Eng., Univ. Tokyo, Tokyo, Japan, Tech. Rep*, 40.
- Tu, W. y Sun, S., 2012. A subject transfer framework for EEG classification. *Neurocomputing*, 82, 109-116.
- Vidaurre, C., Sannelli, C., Müller, K.-R., y Blankertz, B., 2011. Calibración co-adaptativa para mejorar la eficiencia de la BCI. *Journal of Neural Engineering*, 8 (2), 25009.
- Walker, I., Deisenroth, M., y Faisal, A., 2015. Redes neuronales convolucionales profundas para la interfaz cerebro-ordenador utilizando imágenes motoras. *Departamento de Informática del Imperial College of Science, Technology and Medicine*.
- Wang, Y., Gao, X., Hong, B., Jia, C., y Gao, S., 2008. Interfaces cerebro-ordenador basadas en potenciales evocados visuales. *Revista IEEE Engineering in Medicine and Biology*, 27 (5).
- Wang, Y., Wang, Y.-T., y Jung, T.-P., 2012. Traducción de los filtros espaciales del EEG desde el reposo a las imágenes motoras utilizando el análisis de componentes independientes. *PloS one*, 7 (5), e37665.
- Wolpaw, J. y Wolpaw, E.W., 2012. *Brain-Computer Interfaces: Principles and Practice*. OUP USA.
- Wolpaw, J.R., McFarland, D.J., Neat, G.W., y Forneris, C.A., 1991. An EEG-based brain-computer interface para el control del cursor. *Electroencefalografía y Neurofisiología Clínica*, 78 (3), 252-259.
- Yuan, H., Perdoni, C., y He, B., 2010. Relación entre la velocidad y la actividad del EEG durante los movimientos imaginados y ejecutados de la mano. *Journal of Neural Engineering*, 7 (2), 26001.

