

Conozca su mente: actividad cognitiva adaptativa Reconocimiento con CNN Reforzada

Xiang Zhang[¶], Lina Yao[¶], Xianzhi Wang[§], Wenjie Zhang[¶], Shuai Zhang[¶], Yunhao Liu[¶] [¶]Universidad de Nueva Gales del Sur, Sídney, Australia [§] Universidad de Tecnología de Sídney, Sídney, Australia [¶] Universidad Estatal de Michigan, East Lansing, EE. UU. {xiang.zhang3, shuai.zhang}@student.unsw.edu.au, {lina.yao, wenjie.zhang}@unsw.edu.au xianzhi.wang@uts.edu.au, yunhao@cse.msu.edu

Resumen—Las señales de electroencefalografía (EEG) reflejan y miden actividades en ciertas áreas del cerebro. Su riesgo clínico cero y sus características fáciles de usar lo convierten en una buena opción para proporcionar información sobre el proceso cognitivo. Sin embargo, el análisis efectivo de las señales de EEG variables en el tiempo sigue siendo un desafío. En primer lugar, el procesamiento de señales EEG y la ingeniería de características requieren mucho tiempo y dependen en gran medida del conocimiento de expertos, y la mayoría de los estudios existentes se centran en algoritmos de clasificación específicos de dominio, que pueden no aplicarse a otros dominios. En segundo lugar, las señales de EEG suelen tener una relación señal/ruido baja y son más caóticas que las señales de otros sensores. En este sentido, proponemos un marco genérico de reconocimiento de actividad cognitiva basado en EEG que puede admitir de forma adaptativa una amplia gama de aplicaciones cognitivas para abordar los problemas anteriores. El marco utiliza un modelo de atención selectiva reforzada para elegir automáticamente la información característica entre las señales de EEG sin procesar. Emplea una operación de mapeo convolucional para transformar dinámicamente la información seleccionada en un espacio de características para descubrir la dependencia espacial implícita de la distribución de muestras de EEG. Demostramos la eficacia del marco en tres escenarios representativos: reconocimiento de intenciones con EEG de imágenes motoras, identificación de personas y diagnóstico neurológico, y lo evaluamos más en tres conjuntos de datos públicos ampliamente utilizados. Los resultados experimentales muestran que nuestro marco supera múltiples líneas de base de última generación y logra una precisión competitiva en todos los conjuntos de datos al tiempo que logra una baja latencia y una alta resiliencia en el manejo de señales EEG complejas en varios dominios. Los resultados confirman la idoneidad del enfoque genérico propuesto para una serie de problemas en el ámbito de las aplicaciones de interfaz cerebro-ordenador.

Términos de índice: aprendizaje profundo, aprendizaje por refuerzo, mecanismo de atención, interfaz cerebro-computadora

I. INTRODUCCIÓN

La electroencefalografía (EEG) es un indicador de monitoreo electrofisiológico para analizar los estados y actividades del cerebro midiendo las fluctuaciones de voltaje de la corriente iónica dentro de las neuronas del cerebro [1]. En la práctica, las señales de EEG pueden ser recolectadas por equipos portátiles y estándar de una manera no invasiva y no estacionaria [2]. Los algoritmos de clasificación de señales EEG se han estudiado para una variedad de aplicaciones del mundo real [3]. La precisión y la solidez del modelo de clasificación EEG tienen significados prometedores para identificar actividades cognitivas en los ámbitos del reconocimiento de la intención del movimiento, la identificación de personas y el diagnóstico neurológico. Los sistemas de reconocimiento de actividad cognitiva [4] proporcionan un puente entre el mundo cognitivo interior y el mundo físico exterior. Se utilizan recientemente en viviendas asistidas [5], casas inteligentes [6] y la industria del entretenimiento.




Fig. 1: Topografía EEG con muestras continuas. El intervalo entre muestras es de 0,00625 segundos.

[7]; La técnica de identificación de personas basada en EEG potencia los diagnósticos de una amplia gama de aplicaciones cognitivas para abordar los problemas anteriores. El diagnóstico neurológico basado en señales de EEG se puede utilizar para detectar la lesión cerebral orgánica y la actividad neuronal sincrónica anormal, como un ataque epiléptico [10], [11].

La clasificación de la actividad cognitiva enfrenta varios desafíos. En primer lugar, los métodos de preprocesamiento de datos EEG y extracción de características (p. ej., filtrado, transformación de wavelet discreta y selección de características) que se emplean en la mayoría de los estudios de clasificación EEG existentes [3], [7] consumen mucho tiempo y dependen en gran medida de la experiencia. Mientras tanto, las características hechas a mano requieren extensos experimentos para generalizarse bien a diversos entornos, como bandas de filtrado y órdenes de ondas. Por lo tanto, es necesario un método efectivo que pueda trabajar directamente con datos de EEG sin procesar.

En segundo lugar, la mayoría de los métodos de clasificación de EEG actuales están diseñados en base al conocimiento específico del dominio y, por lo tanto, pueden volverse ineficaces o incluso fallar en diferentes escenarios [2]. Por ejemplo, el enfoque personalizado para el diagnóstico neurológico basado en EEG puede no funcionar bien en el reconocimiento de intenciones. Por lo tanto, se espera que un método general de clasificación de señales de EEG sea eficiente y robusto en varios dominios para una mejor usabilidad e idoneidad.

En tercer lugar, las señales de EEG tienen una baja relación señal-ruido y son más caóticas que las señales de otros sensores, como los sensores portátiles. Por lo tanto, la clasificación basada en segmentos que se usa ampliamente en la clasificación de señales de detección puede no ajustarse al reconocimiento de actividad cognitiva. Un segmento contiene algunas muestras de EEG continuas recortadas por el método de ventana deslizante [12], mientras que una sola muestra de EEG (también llamada instancia de EEG) se recopila en un momento específico. En particular, la clasificación basada en segmentos tiene dos inconvenientes en comparación con la clasificación basada en muestras: 1) en un segmento con muchas muestras, el

TABLA I: Análisis en el dominio del tiempo y coeficiente de correlación. n-puntos denota los valores medidos por las muestras con n puntos de muestreo. Comparamos las señales de EEG con otros datos de detección (como datos de sensores portátiles y datos de teléfonos inteligentes) durante cinco escalas diferentes y los resultados muestran constantemente que las señales de EEG tienen la mayor inestabilidad.

Tiempo Dominio	Señales	5 puntos		50 puntos		1000 puntos		10000 puntos		STD Rango		STD Rango		STD Rango		Promedio	
		STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango				
		0,0025	0,0061	0,0179	0,0494	0,0166	0,0612	0,0253	0,1177	0,0259	0,1281	0,0882	0,3625				
Correlación Coeficiente	Teléfono Usable	0,0012	0,0029	0,0107	0,0369	0,0147	0,0519	0,0197	0,1041	0,016	EEG			0,1058	0,0623	0,3016	
		0,0087	0,0218	0,0199	0,0824	0,0245	0,1195	0,0299	0,1619	0,0308	0,1802	0,1138	0,5658				
Correlación Coeficiente	Señales	5 puntos		50 puntos		1000 puntos		10000 puntos		STD Rango		STD Rango		STD Rango		Promedio	
		STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango	STD Rango				
		0,0015	0,0038	0,0243	0,0832	0,0248	0,0964	0,0244	0,104	0,0247	0,104	0,0997	0,3914				
Correlación Coeficiente	Teléfono Usable			0,0252	0,0155	0,0702	0,0147	0,0866	0,0469	0,2299	0,0729	0,3905	0,16	0,8024			
		0,01	EEG	0,0392	0,0991	0,1077	0,4096	0,0955	0,4849	0,1319	0,7626	0,1533	0,99				
																0,5276	2,7462

la diversidad de muestras puede compensarse con otras muestras modificadas inversamente ya que las señales del EEG varían rápidamente (Sección II). 2) basado en segmentos la clasificación requiere más datos de entrenamiento y un mayor tiempo de recopilación de datos. Por ejemplo, suponga que cada segmento tiene diez muestras sin superposición; para el mismo tamaño de lote de entrenamiento, la clasificación basada en segmentos requiere diez veces los datos tamaño y el tiempo de recolección de datos que la clasificación basada en muestras. Como resultado, la clasificación basada en segmentos no puede explotar la intención inmediata de cambiar y por lo tanto logra bajo precisión en el despliegue práctico. Para ello, basado en muestras la clasificación es más atractiva.

Para abordar las cuestiones antes mencionadas, en primer lugar, proponemos un marco novedoso que puede aprender automáticamente características de las señales de EEG sin procesar mediante el desarrollo de un componente de mapeo convolucional profundo. Además, para captar la información característica de diferentes circunstancias de aplicación de EEG de forma adaptativa, diseñamos una atención selectiva reforzada componente que combina los beneficios del mecanismo de atención [13] y aprendizaje de refuerzo profundo. Además, nos sobrepasamos el desafío de la información caótica trabajando en EEG muestras en lugar de segmentos. La única muestra de EEG solamente contiene información espacial sin pista espacial¹. El principal Las contribuciones de este trabajo se destacan a continuación:

- Proponemos un marco general para la cognición automática reconocimiento de actividad para facilitar un alcance de diversos dominios de aplicación cognitiva, incluido el reconocimiento de intenciones, identificación de personas y diagnóstico neurológico.
- Diseñamos el modelo de atención selectiva reforzada, por Combinando el aprendizaje de refuerzo profundo y el mecanismo de atención, para extraer automáticamente el robusto y características profundas distintas. En especial, diseñamos un no lineal función de recompensa para animar al modelo a seleccionar el mejor área de atención que conduce a la clasificación más alta precisión. Además, personalizamos los estados y acciones. basado en nuestro entorno de reconocimiento de actividad cognitiva.
- Desarrollamos un método de mapeo convolucional para explorar la dependencia espacial distinguible y alimentarlo a la clasificador para clasificación, entre señales EEG seleccionadas.
- Demostramos la efectividad del marco de trabajo propuesto utilizando cuatro conjuntos de datos del mundo real relacionados con tres representantes y aplicaciones cognitivas desafiantes.

¹No negamos la utilidad de la información temporal, pero este artículo hace hincapié en la información espacial, que puede ser más fácil de capturar.

Los resultados del experimento demuestran que la propuesta marco supera el estado del arte y fuerte líneas de base logrando consistentemente la precisión de más del 96% y baja latencia.

Tenga en cuenta que todos los conjuntos de datos y códigos reutilizables necesarios tienen ha sido de código abierto para su reproducción, consulte este enlace².

II. ANÁLISIS DE SEÑALES DE EEG

En esta sección, demostramos las características únicas de las señales de EEG (p. ej., de variación rápida y caóticas) y que las muestras son más adecuadas que los segmentos para la clasificación. Por comparación de señales de EEG con dos señales típicas de sensores recopiladas por teléfonos inteligentes (acelerómetros en Samsung Galaxy S2) y sensores portátiles (IMU inalámbrica Colibri). Los participantes están caminando durante la sesión de recolección de datos.

La actividad cerebral es muy compleja y varía rápidamente, pero Las señales de EEG solo pueden capturar una pequeña información a través del muestreo discreto de corriente biológica. La Figura 1 demuestra las características de rápida variación y complejo de EEG señales y proporciona la topografía EEG de 5 consecutivos muestras La frecuencia de muestreo es de 160 Hz, mientras que el intervalo de muestreo es de 0,00625 segundos. Se puede observar que la topografía cambia dramáticamente dentro de un intervalo de tiempo tan pequeño.

Además, para ilustrar el caos de las señales EEG, compare EEG con teléfonos inteligentes y sensores portátiles en dos aspectos: el dominio del tiempo y las correlaciones intermuestras.

En el dominio del tiempo, evaluamos el STD y el rango de señales del sensor en cinco niveles de longitud de muestra: 5, 50, 100, 500, 1000 muestras continuas. Las valoraciones sobre lo anterior Se espera que cinco escalas muestren la tendencia de que cómo La característica del EEG varía con el período de muestreo.

El coeficiente de correlación entre muestras calcula las correlaciones de coseno promedio entre la muestra específica y su muestras vecinas (5, 50, 100, 500 y 1000 muestras). un bajo coeficiente de correlación representa las señales de EEG dramáticamente y variando rápidamente todo el tiempo.

Como resultado, la Tabla I presenta los valores de STD y rango en el dominio del tiempo y coeficiente de correlación. Observamos que las señales de EEG tienen el STD y el rango más altos de todos las cinco escalas de ventana de muestra tanto en el dominio del tiempo como coeficiente de correlación, en comparación con los datos del sensor portátil y señales de teléfonos inteligentes. Esto demuestra que el EEG

²https://github.com/xiangzhang1015/conoce_tu_mente_

muestra tiene correlaciones más inestables con los vecinos y la inestabilidad es muy alta incluso en las cinco muestras más cercanas. Más específicamente, las señales de EEG son muy caóticas y cambian rápidamente en cada punto de muestreo.

tercero MÉTODO PROPUESTO

Con base en el análisis anterior, proponemos refuerzo atento redes neuronales convolucionales (CNN) para clasificar EEG sin procesar señales con precisión y eficiencia directamente. El flujo de trabajo general se muestra en la Figura 2.

A. Replicar y mezclar

Para proporcionar la mayor cantidad de información posible, diseñamos un enfoque para explotar las relaciones espaciales entre EEG señales Las señales pertenecientes a diferentes actividades cerebrales son se supone que tienen diferentes relaciones de dependencia espacial. Nosotros replicar y barajar las señales EEG de entrada en cuanto a la dimensión. Dentro de este método, todos los posibles arreglos de dimensiones tienen la apariencia equiprobable.

Supongamos que los datos de EEG sin procesar de entrada se indican con $X = \{(x_i, y_i), i = 1, 2, \dots, I\}$, donde (x_i, y_i) denota un solo Muestra de EEG e I denota el número de muestras. En cada muestra, la característica $x_i = \{x_{ik}, k = 1, 2, \dots, K\}$, x_i y RK K elementos correspondientes a K canales EEG y y_i y R denota la etiqueta correspondiente. x_{ik} denota el k -ésimo valor de la dimensión en la i -ésima muestra.

En escenarios de recopilación del mundo real, los datos de EEG generalmente se concatenan siguiendo la distribución de datos biomédicos. Canales EEG. Sin embargo, el orden de las dimensiones biomédicas puede no presentar la mejor dependencia espacial. el agotador El método es demasiado costoso desde el punto de vista computacional para agotar todos los arreglos de dimensiones posibles. Por ejemplo, un canal de 64 La muestra de EEG tiene $64 = 1,28 \times 1089$ combinaciones, que es una figura astronómica.

Para proporcionar más combinaciones de dimensiones potenciales, proponen un método llamado Replicar y Barajar (RS). RS es un método de mapeo de dos pasos que mapea x_i a un mayor espacio dimensional x_i con combinaciones completas de elementos:

$$x_i \rightarrow RK \rightarrow x_i \rightarrow RK, K > K \tag{1}$$

En el primer paso (Replicar), replicar x_i para $h = K / K+1$ veces. Entonces, obtenemos un nuevo vector con longitud como $h \times K$ que no es menor que K ; en el segundo paso (Shuffle), aleatoriamente mezclar el vector replicado en el primer paso e interceptar los primeros K elementos para generar x_i . Teóricamente, en comparación con x_i , x_i contiene combinaciones de dimensiones más diversas. Tenga en cuenta que esta operación RS solo se realiza una vez para un determinado conjunto de datos de entrada con el fin de proporcionar un entorno estable para el después del aprendizaje por refuerzo.

B. Atención selectiva reforzada

Inspirado por el hecho de que la relación espacial óptima sólo depende de un subconjunto de dimensiones de características, introducimos un zona de atención para centrarse en un fragmento de las dimensiones de la característica. Aquí, la zona de atención se optimiza mediante un refuerzo profundo.

aprendizaje, que ha demostrado ser estable y bien realizado en el aprendizaje de políticas.

En particular, nuestro objetivo es detectar la combinación óptima de dimensiones, que incluye la dependencia espacial más distintiva entre las señales de EEG. Desde k , la longitud de x_i . Es demasiado largo y computacionalmente costoso, para equilibrar la longitud y la contenido de información, introducimos el mecanismo de atención [14] ya que su eficacia ha sido demostrada en recientes áreas de investigación como el reconocimiento de voz [15]. intentamos para enfatizar el fragmento informativo en x_i y denota el fragmento por x_i , que se llama zona de atención. Sea $x_i \rightarrow RK$ y K denotan la longitud de la zona de atención que es aprendido automáticamente por el algoritmo propuesto. Empleamos aprendizaje de refuerzo profundo para descubrir la mejor zona de atención

[decisiones].

Como se muestra en la Figura 2, la detección de la mejor atención La zona incluye dos componentes clave: el entorno (que incluye la transición de estado y el modelo de recompensa) y el agente. Tres elementos (el estado s , la acción a , y la recompensa r) son intercambiados en la interacción entre el medio ambiente y el agente. Los tres elementos se personalizan según en nuestro contexto en este estudio. A continuación, presentamos el diseño. de los componentes cruciales de nuestro aprendizaje de refuerzo profundo estructura:

- El **estado** $S = \{st, t = 0, 1, \dots, T\}$, st y $R2$ describe la posición de la zona de atención, donde t denota la sello de tiempo Dado que la zona de atención es un fragmento cambiante en 1-D x_i , diseñamos dos parámetros para definir el estado: $st = \{\text{inicio}_{idx}, \text{end}_{idx}\}$, donde comenzó idx y terminó idx denote el índice de inicio y el índice final de la atención zona3, por separado. En el entrenamiento, $s0$ se inicializa como

$$s0 = [(K \rightarrow K^-)/2, (K + K^-)/2] \tag{2}$$

- La **acción** $A = \{en, t = 0, 1, \dots, T\}$ y $R4$ describe qué acción podría elegir el agente para actuar sobre la ambiente. Aquí en la marca de tiempo t , la transición de estado elige una acción para implementar siguiendo las instrucciones del agente política \tilde{y} :

$$st+1 = \tilde{y}(st, en) \tag{3}$$

En nuestro caso, definimos cuatro categorías de acciones (Figura 3) para la zona de atención: desplazamiento a la izquierda, desplazamiento a la derecha, extender y condensar. Para cada acción, la atención la zona se mueve una distancia aleatoria d y $[1, du]$ donde du es el límite superior. Para cambio a la izquierda y cambio a la derecha acciones, la zona de atención se desplaza hacia la luz o hacia la derecha con el paso d ; para las acciones extender y condensar, ambas idx y idx se están moviendo d . Por fin, si el Estado inicio o índice final está más allá del límite, un clip se lleva a cabo la operación. Por ejemplo, si $startt_{idx} = \tilde{y}5$ que es más bajo que el límite inferior 0, recortamos el índice de inicio como $startt_{idx} = 0$.

Por ejemplo, para una x aleatoria ($startt_i = [3, 5, 8, 9, 2, 1, 6, 0]$, el estado $idx = 2$, $termin_{idx} = 5$) es suficiente para determinar la zona de atención como $[8, 9, 2, 1]$.

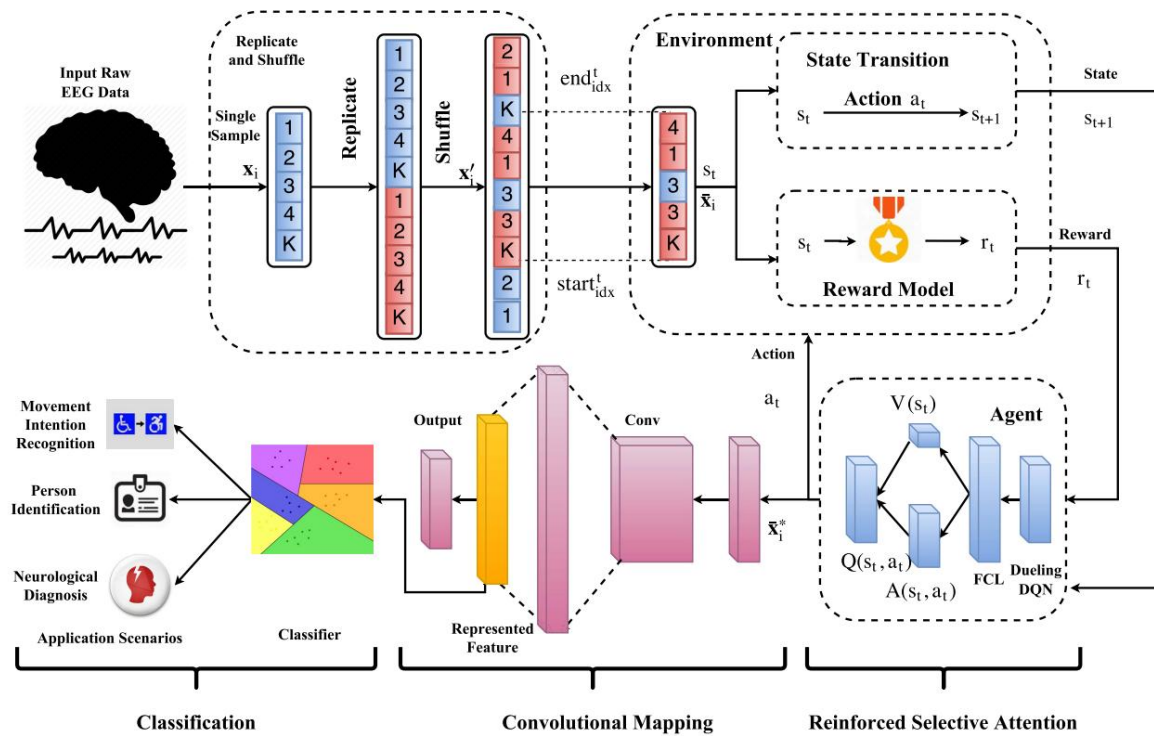


Fig. 2: Diagrama de flujo del enfoque propuesto. La muestra única x_i de EEG sin procesar de entrada (K denota el elemento K th) se replica y se baraja para proporcionar combinaciones espaciales más latentes de dimensiones de características. Luego, se selecciona una zona de atención \tilde{x}_i , que es un x_{y_0} , con el estado $s_t = \{\text{start}_{idx}, \text{fragmento en end}_{idx}\}$. La zona de atención seleccionada se introduce en la transición de estado y el modelo de recompensa. En cada paso t , la transición de estado selecciona una acción para actualizar s_t en función de la retroalimentación del agente. El modelo de recompensa evalúa la calidad de la zona de atención por la puntuación de recompensa r_t . El duelo DQN se emplea para descubrir la mejor zona de atención \tilde{x}_i^* que se introduce en el procedimiento de mapeo convolutivo para extraer la representación de estado s_t . El modelo de recompensa evalúa la combinación del mapeo convolutivo y la clasificación. Cada una de las capas completamente conectadas. El modelo de recompensa evalúa



Left Shifting Right Shifting Extend Condense

Fig. 3: Cuatro acciones en la transición de estado: desplazamiento a la izquierda, desplazamiento a la derecha, extensión y condensación. La línea discontinua indica la posición de la zona de atención antes de la acción, mientras que la línea sólida indica después de la acción.

- La **recompensa** $R = \{r_t, t = 0, 1, \dots, T\}$ se calcula mediante el modelo de recompensa, que se detallará más adelante. El modelo de recompensa \tilde{y} :

$$r_t = \tilde{y}(s_t) \quad (4)$$

recibe el estado actual y devuelve una evaluación como el premio.

Modelo de recompensa. A continuación, presentamos en detalle el diseño del modelo de recompensa. El propósito del modelo de recompensa es evaluar cómo el estado actual impacta el desempeño de la clasificación. Intuitivamente, el estado que conduce a una mejor clasificación

el desempeño debe tener una recompensa mayor: $r_t = F(s_t)$. Establecemos la recompensa modal F como una combinación del mapeo convolutivo y la clasificación (Sección III-C). Dado que en la optimización del enfoque práctico, cuanto mayor es la precisión, más difícil es aumentar la precisión de la clasificación. Por ejemplo, mejorar la precisión en un nivel superior (p. ej., del 90 % al 100 %) es mucho más difícil que en un nivel inferior (p. ej., del 50 % al 60 %). Para fomentar la mejora de la precisión en el nivel superior, diseñamos una función de recompensa no lineal:

$$r_t = \frac{\text{cada uno}}{y \tilde{y} 1} \frac{K^* - k}{K} \quad (5)$$

donde acc denota la precisión de la clasificación. La función contiene dos partes; la primera parte es una función exponencial normalizada con el exponente $\text{acc} \tilde{y} [0, 1]$, esta parte anima al algoritmo de aprendizaje por refuerzo a buscar la mejor s_t que conduce a una acc más alta. La motivación de la función exponencial es que: la tasa de crecimiento de la recompensa aumenta con el aumento de la precisión⁴. La segunda parte es un factor de penalización por

⁴Por ejemplo, para el mismo incremento de precisión 10%, acc : 90% y 100% puede ganar un incremento de recompensa más alto que acc : 50% y 60%.

la longitud de la zona de atención para mantener la barra más corta y el γ es el coeficiente de penalización.

En resumen, el objetivo del aprendizaje por refuerzo profundo es aprender la zona de atención óptima \hat{x} que condecompensaría mecanismo selectivo itera totalmente $N = n_e \gamma n_s$ veces donde n_e y n_s denotan el número de episodios y pasos [17], respectivamente. El método γ -voraz [18] se emplea en la transición de estado, que elige una acción aleatoria con probabilidad $1 - \gamma$ o una acción de acuerdo con la función Q óptima $\arg\max_t \gamma A_Q(st, at)$ con probabilidad γ .

en fórmula,

$$a_{t+1} = \arg\max_t \gamma A_Q(st, at) \quad a_t \neq \gamma \quad \gamma < \gamma \quad \text{de lo contrario} \quad (6)$$

donde $\gamma \in [0, 1]$ se genera aleatoriamente para cada iteración mientras que a_t se selecciona aleatoriamente en A .

Para una mejor convergencia y un entrenamiento más rápido, el γ aumenta gradualmente con la iteración. El incremento γ_0 sigue:

$$\gamma_{t+1} = \gamma_t + \gamma_0 N \quad (7)$$

Política y optimización de agentes. El Dueling DQN (Deep Q Networks [17]) se emplea como la política de optimización $\gamma(st, at)$, que permite aprender la función estado-valor de manera eficiente. La razón principal por la que empleamos un DQN en duelo para descubrir la mejor zona de atención es que actualiza los cuatro valores Q en cada paso, mientras que otras políticas solo actualizan un valor Q en cada paso. La función Q mide la suma esperada de recompensas futuras al realizar esa acción y seguir la política óptima a partir de entonces. En particular, para el paso específico t , tenemos:

$$Q(st, at) = E(rt+1 + \gamma rt+2 + \gamma^2 rt+3 \dots) \\ = \sum_{n=0}^{\infty} \gamma^n rt+k+1 \quad (8)$$

donde $\gamma \in [0, 1]$ es el parámetro de decaimiento que compensa la importancia de las recompensas inmediatas y futuras, mientras que n denota el número de pasos siguientes. La función de valor $V(st)$ estima la recompensa esperada cuando el agente se encuentra en el estado s . La función Q está relacionada con el par (st, at) mientras que la función de valor solo se asocia con st .

Dueling DQN aprende la función Q a través de la función de valor $V(st)$ y la función de ventaja $A(st, at)$ y las combina con la siguiente fórmula

$$Q(st, at) = \gamma V(st) + \gamma A(st, at) \quad (9)$$

donde γ , γ y γ son parámetros en la red DQN en duelo y se optimizan automáticamente. La ecuación: 9 no es identificable, lo que se puede observar por el hecho de que no podemos recuperar $V(st)$ y $A(st, at)$ únicamente con el $Q(st, at)$ dado. Para solucionar este problema, podemos forzar que la función de ventaja sea igual a cero en la acción elegida. Es decir, dejamos que la red implemente el mapeo directo:

$$Q(st, at) = V(st) + [A(st, at) - \max_{a'} A(st, a')] \quad (10)$$

Por lo tanto, para la acción específica a_t , si

$$\arg\max_{a'} \gamma A_Q(st, at+1) = \arg\max_{a'} \gamma A_A(st, at+1) \quad (11)$$

entonces tenemos

$$Q(st+1, a_t) = V(st) \quad (12)$$

Así, como se muestra en la Figura 2 (la penúltima capa de la parte del agente), el flujo $V(st)$ se ve obligado a aprender una estimación de la función de valor, mientras que el otro flujo produce una estimación de la función de ventaja.

Para evaluar la función Q , optimizamos el siguiente costo función en la i -ésima iteración:

$$Li(\gamma_i) = E_{st, at, rt, st+1} [(\gamma_i - Q(st, at))^2] \\ = E_{st, en, rt, st+1} [(\gamma_i - \gamma V(st) + \gamma A(st, at))^2] \quad (13)$$

con

$$\gamma_i = rt + \gamma \max_{a'} Q(st+1, at+1) \quad (14)$$

El método de actualización de gradiente es

$$\gamma_i Li(\gamma_i) = E_{st, at, rt, st+1} [(\gamma_i - Q(st, at)) \gamma_i Q(st, at)] \\ = E_{st, en, rt, st+1} [(\gamma_i - \gamma V(st) + \gamma A(st, at)) \gamma_i (\gamma V(st) + \gamma A(st, at))] \quad (15)$$

C. Mapeo convolucional

Para cada zona de atención, explotamos aún más la dependencia espacial potencial de las características seleccionadas formando una muestra, la muestra de EEG solo contiene un vector numérico con información muy limitada y se corrompe fácilmente por el ruido. Para corregir este inconveniente, intentamos mapear la muestra única de EEG desde el espacio original O y RK a un espacio de dispersión T y RM mediante una estructura CNN.

Para extraer tantas dependencias espaciales potenciales como sea posible, empleamos una capa convolucional [19] con muchos filtros para escanear en la zona de atención aprendida \hat{x} y i convolucional.

La estructura de mapeo contiene cinco capas (como se muestra en la Figura 2): la capa de entrada recibe la zona de atención aprendida, la capa convolucional seguida de una capa completamente conectada y la capa de salida. La verdad del suelo caliente se compara con la capa de salida para calcular la pérdida de entrenamiento.

La función de activación no lineal Relu se aplica a las salidas convolucionales. Describimos la capa convolucional de la siguiente manera:

$$x_c = \text{ReLU} \left(\sum_{b=1}^b W_c x_{ij} + b_i \right) \quad (\text{decisión})$$

donde x_{ij} denota el resultado de la capa convolucional mientras que b y W_c denotan la longitud del filtro y los pesos del filtro, respectivamente. La capa de agrupación tiene como objetivo reducir la información redundante en las salidas convolucionales para disminuir el costo computacional. En nuestro caso, tratamos de conservar la mayor cantidad de información posible. Por lo tanto, nuestro método no emplea una capa de agrupación. Luego, en la capa totalmente conectada y la capa de salida

$$x_f = \text{ReLU}(W_f x_c + b_f) \quad (17)$$

ALGORITMO 1: El enfoque propuesto

```
Entrada: señales de EEG sin procesar X
Salida: etiqueta de actividad cognitiva pronosticada y i
1: Inicialización s0;
2: RS: xi y xi;
3: Atención selectiva reforzada:
4: si t<N entonces at =
= y(stargmaxxi/RQst7a)51st+yt
rt 10: fin 8: xy 9: i y xi, at, st,
11: Mapeo convolucional y clasificador: 12: si la
iteración < N entonces 13: y i y xy 14: finaliza si
15: regresa y i i
```

y_{yo} = suave tmax(Woxf + b_o) (18)

donde $_$, ay , bf , bo denota los pesos y sesgos correspondientes, respectivamente. La y denota la etiqueta predicha. La función de costo se mide por entropía cruzada, y se adopta la norma 2 (con parámetro \tilde{y}) como regularización para evitar el sobreajuste:

costo = \tilde{y} y $\log(yi) + \tilde{y}$ 2 (19)

El algoritmo AdamOptimizer optimiza la función de coste. La capa completamente conectada se extrae como las características representadas y las introduce en un clasificador de vecino más cercano ligero. Las actualizaciones de mapeo convolucional para N iteraciones. El reconocimiento de actividad cognitiva adaptativa propuesta con redes neuronales convolucionales atentas reforzadas se muestra en el Algoritmo 1.

IV. EXPERIMENTOS

En esta sección, informamos nuestra evaluación del enfoque propuesto en tres conjuntos de datos correspondientes a diferentes escenarios de aplicación, con un enfoque en la precisión, la latencia y la resiliencia.

A. Escenarios de aplicación y conjuntos de datos

1) Escenarios de aplicación: Evaluamos nuestro enfoque en varios conjuntos de datos en tres aplicaciones de interfaces cerebro-computadora basadas en EEG.

Reconocimiento de Intención de Movimiento (MIR). Las señales EEG miden las actividades del cerebro humano. Intuitivamente, diferentes intenciones humanas conducirán a diversos patrones de EEG [5]. El reconocimiento de intenciones juega un papel importante en escenarios prácticos como el hogar inteligente, la vida asistida [6], la tipificación cerebral [5] y Para los discapacitados y los ancianos, el reconocimiento de intenciones puede ayudarlos a interactuar con dispositivos inteligentes externos, como sillas de ruedas o sistemas BCI en tiempo real de robots de servicio. Además, las personas sin capacidad vocal pueden tener la oportunidad de expresar sus pensamientos con la ayuda de ciertas tecnologías de reconocimiento de intenciones (p. ej., tipificación cerebral). Incluso para el ser humano sano, el reconocimiento de intenciones se puede utilizar en juegos de video y otras aplicaciones de la vida diaria.

Identificación de la Persona (PI). La identificación biométrica basada en EEG [8] es un enfoque emergente de identificación de personas, que es altamente resistente a los ataques. Tiene la ventaja única de evitar o aliviar la amenaza de ser engañado que a menudo enfrentan otras técnicas de identificación. Esta técnica se puede implementar en escenarios de identificación y autenticación, como el sistema de seguridad bancario y el control de seguridad aduanero.

Diagnóstico Neurológico (ND). Las señales de EEG recopiladas en el estado no saludable difieren significativamente de las recopiladas en el estado normal en cuanto a la frecuencia y el patrón de activación neuronal [2]. Por lo tanto, las señales de EEG se han utilizado para el diagnóstico neurológico durante décadas [39]. Por ejemplo, el ataque epiléptico es un trastorno cerebral común que afecta a alrededor del 1% de la población, y un análisis de EEG del paciente podría detectar su estado octal.

2) Conjuntos de datos: para evaluar cómo funciona el enfoque propuesto en los escenarios de aplicación antes mencionados, elegimos varios conjuntos de datos de EEG con varios equipos de recopilación, frecuencias de muestreo y fuentes de datos. Utilizamos señales EEG de imágenes motoras de un conjunto de datos público eegmmidb para el reconocimiento de intenciones, el conjunto de datos EEG-S para la identificación de personas y el conjunto de datos TUH para el diagnóstico neurológico. eegmmidb. La base de datos de imágenes/movimiento motor EEG (eegm midb)5 fue recopilada por el sistema BCI200 EEG, que registró las señales cerebrales utilizando 64 canales con una frecuencia de muestreo de 160 Hz. Las señales de EEG se registraron cuando el sujeto estaba imaginando ciertas acciones (sin ninguna acción física). Este conjunto de datos incluye 560 000 muestras recolectadas de 20 sujetos. Cada muestra tiene una de cinco etiquetas diferentes: ojos cerrados, mano izquierda, mano derecha, ambas manos y ambas alimentaciones.

Cada muestra es un vector de 64 elementos que corresponden a 64 canales de datos de EEG.

EEG-S. EEG-S es un subconjunto de eegmmidb, en el que los datos se recopilaron mientras el sujeto mantenía los ojos cerrados y permanecía relajado. Participaron ocho sujetos y cada sujeto generó 7.000 muestras. Las etiquetas son las identificaciones de los sujetos, que oscilan entre [0-7].

TUH. TUH [40] es un conjunto de datos de convulsiones neurológicas de registros clínicos de EEG. El registro EEG está asociado a 22 canales a partir de una configuración 10/20 y una frecuencia de muestreo de 250 Hz. Seleccionamos 12.000 muestras de cada uno de cinco sujetos (2 hombres y tres mujeres). La mitad de las muestras se etiquetaron como estado de ataque epiléptico. Las muestras restantes se etiquetaron como estado normal.

3) Configuración de parámetros: configuramos la configuración predeterminada de nuestro enfoque de la siguiente manera. En el aprendizaje de atención selectiva: $K^* = 128$, el Dueling DQN tuvo 4 lays y el número de nodo en cada capa fue: 2 (capa de entrada), 32 (FCL), 4 (A(st, at)) +1(V (st)), y 4 (salida). El parámetro de decaimiento $\tilde{y} = 0.8$, $ne = ns = 50$, $N = 2,500$, $= 0.2$, $0 = 0.002$, tasa de aprendizaje = 0.01, $\lambda = 0.01$, coeficiente de penalización de longitud $\tilde{y} = 0.1$ y la longitud mínima de la zona de atención se estableció en 10. En el mapeo convolucional, el número de nodo en la entrada

5<https://www.physionet.org/pn4/eegmmidb/>

TABLA II: Comparación con líneas de base

Conjuntos de datos de escenarios	Métrica	Lineas base de aprendizaje no profundo							Lineas base de aprendizaje profundo	
		SVM	RF	KNN	AB	LDA	LSTM	GRU	CNN	Nuestro
YO	eegmmidb	Precisión	0,5596	0,6996	0,5814	0,3043	0,5614	0,648	0,9632	0,6786 0,91
		Precisión	0,5538	0,7311	0,6056	0,2897	0,5617	0,6952	0,8873	
		Recuerdo	0,5596	0,6996	0,5814	0,3043	0,5614	0,6446	0,6127	
		Puntuación F1	0,5396	0,6738	0,5813	0,2037	0,5526	0,6619	0,7128	
Pi	CEE-S	Precisión	0,6604	0,9619	0,9278	0,35	0,6681	0,9571	0,9821	0,9984
		Precisión	0,6551	0,9625	0,9336	0,3036	0,6779	0,9706	0,9858	
		Recuperación	0,6604	0,9619	0,9278	0,35	0,6681	0,9571	0,9821	
		Puntuación F1	0,6604	0,9619	0,9278	0,35	0,6681	0,9571	0,9821	
	OH	Precisión	0,7692	0,92	0,9192	0,5292	0,7675	0,6625	0,9592	0,9975
		Precisión	0,7695	0,9206	0,923	Recordar		0,7525	0,7675	
		puntuación F1	0,7692	0,92	0,9192	0,5292	0,7675	0,6417	0,6583	
			0,7692	0,9199	0,9188	0,3742	0,7675	0,6449	0,6685	

TABLA III: Comparación con los enfoques del estado del arte

Conjuntos de datos de escenarios	Métrica	Lo último						
		Rasid [20]	Zhang [5]	Y [21]	Alomario [22]	Seis [23]	Alomario [24]	
YO	eegmmidb	Método						
		Exactitud	0,9193	0,9561	0,6820	0,8679	0,8788	0,7584
		Precisión	0,9156	0,9566	0,6971	0,8786	0,8787	0,7631
		Recuperación	0,9231	0,9621	0,7325			0,7702
		Puntuación F1	0,9156	0,9593	0,7144			0,7666
		Método						
		Shenoy [25]	Szczuko [26]	Stefano [27]	pino [28]	kim [29]		Nuestro
		Precisión	0,8308	0,9301	0,8724	0,8488	0,8115	0,9632
		Precisión	0,8301	0,9314	0,8874	0,8513	0,8128	0,9632
		Recordar	0,8425	0,9287	0,8874	0,8569	0,8087	0,9632
Pi	CEE-S	Método						
		Método Ma [30]		yang [31]	Rodrigues [32]	Frashini [12]	Tomás [33]	Nuestro
		Precisión	0,88	0,99	0,8639	0,956	0,9807	0,9984
		Precisión	0,8891	0,9637	0,8721	0,9458	0,9799	0,9984
		Recuperación	0,8891	0,9594	0,8876	0,9539	0,9887	0,9984
		Puntuación F1	0,8891	0,9615	0,8798	0,9498	0,9843	0,9984
	OH	Método						
		Ziyabari [34]	Harati [35]	Zhang [36]	Goodwin [37]	Golmohammadi [38]	Nuestro	
		Precisión	0,9382	0,9975	0,9429	0,994	0,924	0,9479
		Precisión	0,9438	0,9975				

capa igual al número de dimensiones de la zona de atención. En la capa convolucional: la zancada tenía la forma [1, 1], la el tamaño del filtro se estableció en [1, 2], la profundidad en 10 y el no lineal funcionar como ReLU. El método de relleno fue cero-relleno. No Se adoptó la capa de agrupación. El subsiguiente completamente conectado capa tenía 100 nodos. La tasa de aprendizaje fue de 0.001 mientras que la El coeficiente de 2 normas γ fue igual a 0,001. La transformación fue entrenado para 2000 iteraciones. Además, configuramos la clave parámetros de las líneas base de la siguiente manera: SVM lineal (C = 1), Bosque aleatorio (RF, n = 200), KNN (k = 1). en LSTM (Memoria a largo plazo) y GRU (Unidad recurrente cerrada), nsteps = 5, otras configuraciones fueron las mismas que [6]. la cnn tenía la misma estructura y ajuste de hiperparámetros con el componente de mapeo convolucional en el programa propuesto.

B. Comparación general

1) Líneas base de comparación: Para medir la precisión de la método propuesto, lo comparamos con un conjunto de métodos de referencia incluyendo cinco aprendizaje no profundo y tres basados en aprendizaje profundo líneas base. Además, elegimos algunos algoritmos competitivos de última generación para cada tarea por separado.

Líneas Base MIR:

Rashid et al. [20] utiliza la Transformada Wavelet Discreta (DWT) para extraer características y alimentar el algoritmo de Levenberg-Marquardt (LMA) red neuronal basada en imágenes motoras EEG intención reconocimiento.

Zhang et al. [5] diseñar una neural recurrente convolucional conjunta red para aprender sólidas presentaciones de características de alto nivel por incrustaciones densas de baja dimensión a partir de señales MI-EEG sin procesar.

Ma et al. [21] transformar los datos de EEG en un espacial secuencia para conocer más información valiosa a través de RNN.

Alomari et al. [22] analizan las características del EEG por el Coiflets wavelets y extraiga características manualmente usando diferentes estimadores de amplitud. Las características extraídas se introducen en Clasificador SVM para reconocimiento de datos EEG.

Sita et al. [23] emplear análisis de componentes independientes (ICA) para extraer características que se alimentan a un clasificador de análisis discriminante cuadrático (QDA).

Alomari et al. [24] use la transformación wavelet para filtrar y procesar señales de EEG. Luego calcule la Raíz Cuadrada Media y funciones de valor medio absoluto para el reconocimiento de EEG.

Shenoy et al. [25] proponen un enfoque de regularización basado en la estimación de la contracción para manejar el problema de la muestra pequeña y conservar las características discriminatorias específicas del sujeto.

Szczuko [26] diseña un clasificador basado en un conjunto aproximado para el objetivo de clasificación de datos EEG.

Stefano et al. [27] extraer μ (7 y 13 Hz) y β (13 y 30 Hz) densidad espectral de potencia (PSD) de bandas como manual características para discriminar diferentes intenciones de imágenes motoras.

Pinheiro et al. [28] adoptar un árbol de decisión C4.5 como clasificador para distinguir las características EEG extraídas manualmente

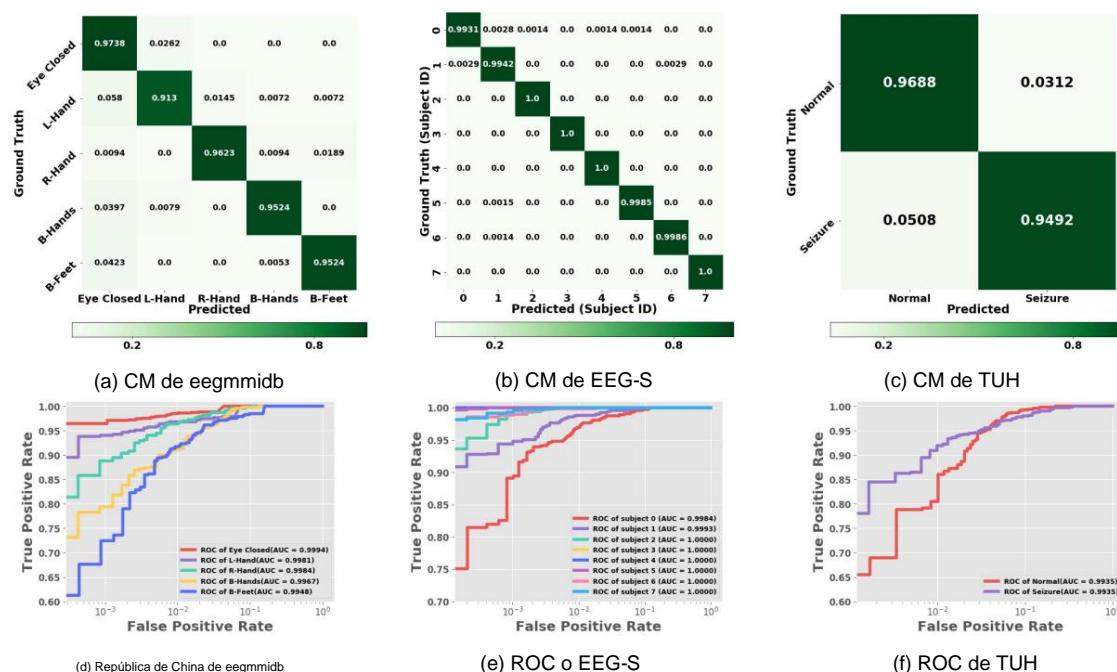


Fig. 4: Matriz de confusión y curvas ROC con puntajes AUC de cada conjunto de datos. CM denota matriz de confusión.

como la media aritmética y el valor máximo de Fourier transformar.

Kim et al. [29] utilizan una descomposición de modo empírico multivariante para obtener los ritmos μ y β de las señales EEG no lineales.

Líneas base de PI:

Ma et al. [30] adoptan una estructura CNN para extraer automáticamente las mejores y únicas características neuronales de un individuo con el objetivo de identificar a la persona.

Yang et al. [31] presentan un enfoque para la identificación biométrica utilizando señales de EEG basadas en características extraídas con la Transformada de Hilbert-Huang (HHT).

Rodríguez et al. [32] propone el ritmo del algoritmo de polinización de flores bajo diferentes funciones de transferencia para seleccionar el mejor subconjunto de canales que maximiza la precisión, que se mide utilizando el clasificador Optimum-Path Forest.

Frashini et al. [12] descomponen las señales de EEG en bandas de frecuencia estándar mediante un filtro de paso de banda y estiman la conectividad funcional entre los sensores utilizando el índice de retardo de fase. La matriz de conectividad resultante se utilizó para construir una red ponderada para la identificación de personas.

Tomás et al. [33] extrae las características de entropía de la muestra de las bandas delta, theta, alfa, beta y gamma de los datos de EEG de 64 canales, que se evalúan para la identificación del sujeto.

Líneas base de ND:

Ziyabari et al. [34] adoptan una arquitectura híbrida de aprendizaje profundo, que incluye LSTM y un codificador automático de eliminación de ruido apilado, que integra el contexto temporal y espacial para detectar la incautación.

Harati et al. [35] demuestran que una variante del enfoque basado en el banco de filtros y proporciona una reducción sustancial en

la tasa de error global.

Zhang et al. [36] extrajo una lista de 24 tipos de características de las señales del EEG del cuero cabelludo y encontró 170 de las 2794 características para clasificar las crisis epilépticas con precisión.

Goodwin et al. [37] combinan los avances recientes en RNN con el acceso a datos textuales en informes de EEG para extraer automáticamente características a nivel de palabra y de informe e inferir información no especificada de EHR (registros médicos electrónicos).

Golmohammadi et al. [38] proponen un método de detección de convulsiones mediante el uso de modelos ocultos de Markov (HMM) para la decodificación secuencial y redes de aprendizaje profundo.

2) Resultados: la Tabla II presenta la comparación de las métricas de clasificación entre nuestro enfoque y las líneas base conocidas (incluidas las líneas base No DL y DL), donde DL, AdaB, LDA representan el aprendizaje profundo, el refuerzo adaptativo y el análisis discriminante lineal, respectivamente. Los resultados muestran que nuestro enfoque logró la mayor precisión en todos los conjuntos de datos.

Específicamente, el enfoque propuesto logró la precisión más alta de 0,9632, 0,9984 y 0,9975 en el conjunto de datos eegmmidb, EEG-S y TUH, respectivamente. Además, realizamos un estudio de ablación comparando nuestro método, que combinaba principalmente el mecanismo de atención selectiva y CNN, con el solo CNN.

Resultó que nuestro enfoque superó a CNN, demostrando que el mecanismo de atención selectiva propuesto mejoró el aprendizaje de características distintivas. Mostramos la matriz de confusión y las curvas ROC (incluidas las puntuaciones AUC) de cada conjunto de datos en la Figura 4. En la Figura 4a, 'L', 'R' y 'B' indican izquierda, derecha y ambas, respectivamente.

Además, para evaluar aún más el rendimiento de nuestro modelo, comparamos nuestro marco con 21 métodos de última generación que utilizan el mismo conjunto de datos. En particular, comparamos con




Fig. 5: Comparación de latencia Fig. 6: Número variable de canales

11 métodos competitivos de última generación sobre clasificación de imágenes motoras y cinco avances por separado sobre escenarios de identificación de personas y diagnóstico neurológico. La Tabla III muestra los resultados de la comparación.

Pudimos observar que nuestro marco propuesto superó consistentemente un conjunto de métodos de referencia ampliamente utilizados y fuertes competidores en tres conjuntos de datos diferentes. El rendimiento muestra una mejora significativa en comparación con otras líneas de base. Estos conjuntos de datos se recopilaron utilizando diferentes equipos de EEG, que van desde equipos médicos de alta precisión hasta auriculares de EEG listos para usar con una cantidad diferente de EEG.

canales Con respecto al diagnóstico de convulsiones en ND, al establecer el estado normal como impostor mientras que el estado convulsivo como genuino, nuestro enfoque obtuvo una tasa de falsa aceptación (FAR) de 0,0033 y una tasa de falso rechazo (FRR) de 0,0017. Esto superó a los métodos existentes por un amplio margen [11], [35], [37], [38].

C. Evaluación de la Resiliencia

En esta sección, nos enfocamos en evaluar la resiliencia del método propuesto para hacer frente a varios canales de señal de EEG y señales de EEG incompletas.

En la práctica, la cantidad de canales de EEG de los dispositivos de EEG es diversa debido a dos razones. En primer lugar, diferentes dispositivos estándar o disponibles en el mercado tienen varios números de canales. Intuitivamente, la calidad de las señales y la información contenida está directamente asociada con el número de canales. Mientras tanto, los dispositivos con más canales suelen ser más caros y menos portátiles. En segundo lugar, las señales de EEG incompletas provocan la degradación de las aplicaciones de BCI. Podría suceder cuando algunos nodos eléctricos se aflojan debido a un mantenimiento deficiente de dispositivos EEG. Para investigar la solidez de las señales de EEG incompletas con canales faltantes, también llevamos a cabo experimentos seleccionando aleatoriamente parte de una proporción de canales de señal en tres conjuntos de datos. Por ejemplo, al seleccionar el 20 % de los canales en el conjunto de datos eegmldb, el número de canal seleccionado es 12 = redondo (64 \times 0,2). La figura 6 muestra los resultados de los experimentos (0,4 indica la precisión y 20 % indica el porcentaje de canal utilizado para el entrenamiento). El gráfico de radar demuestra que eegmldb y EEG-S, ambos con 64 canales, pueden lograr una precisión competitiva incluso con solo un 20 % de canales de señal. Por el contrario, TUH (22 canales) depende en gran medida de los números de canal. La razón es que TUH solo quedan cinco canales para un porcentaje de canal del 20%, respectivamente. Según nuestra experiencia, el marco propuesto requiere al menos ocho canales de EEG para lograr una alta precisión.

D. Análisis de latencia

Excepto por la alta precisión de la clasificación de señales EEG, la baja latencia es otro requisito crítico para el éxito de las aplicaciones BCI del mundo real.

En esta sección, tomamos el conjunto de datos eegmldb como ejemplo para comparar la latencia del marco propuesto con varios algoritmos de última generación. Los resultados se presentan en la Figura 5. Observamos que nuestro enfoque tenía una latencia competitiva en comparación con otros métodos. La latencia general fue inferior a 1 segundo. Las técnicas basadas en el aprendizaje profundo en este trabajo no conducen explícitamente a una latencia adicional. Una de las principales razones puede residir en que la atención selectiva reforzada ha filtrado información innecesaria. Para ser más específicos, la latencia de clasificación del marco propuesto fue de aproximadamente 0,7 a 0,8 segundos, lo que resultó principalmente del procedimiento de clasificación y el mapeo convolucional. La latencia causada por el clasificador fue de alrededor de 0,7 segundos. El mapeo convolucional solo tomó 0.05 segundos en la prueba, aunque tomó más de diez minutos en el entrenamiento.

E. Demostración del modelo de recompensa

Informamos brevemente la demostración empírica del modelo de recompensa exponencial propuesto (Sección III-B). Comparamos el modelo de recompensa propuesto en la ecuación. 5 con la recompensa tradicional $rt = eacc$ sobre tres conjuntos de datos de referencia (eegmldb, EEG-S y TUH). Los resultados del experimento muestran que el nuevo modelo de recompensa logró una mayor precisión (0,9632, 0,9984 y 0,9975) que el modelo tradicional (0,9231, 0,9901 y 0,9762).

V. DISCUSIONES

En este documento, proponemos un marco de clasificación adaptable, universal y robusto para tratar las señales de EEG cognitivas de manera efectiva y eficiente. Sin embargo, quedan varios desafíos pendientes.

En primer lugar, la clasificación basada en una sola muestra de EEG solo puede reflejar la intención instantánea del sujeto en lugar de una intención estable a largo plazo. Un método de modificación posible es el procesamiento posterior como la votación. Por ejemplo, podemos clasificar 100 muestras de EEG y contar la moda de los 100 resultados como el resultado final de la clasificación.

Además, la política de aprendizaje por refuerzo solo funciona bien en el entorno en el que se entrena el modelo, lo que significa que el índice de dimensión debe ser coherente en las etapas de entrenamiento y prueba. Se deben entrenar varias políticas de acuerdo con diferentes combinaciones de sensores. Además, el proceso de reproducción aleatoria no siempre puede proporcionar la mejor dependencia espacial. Por lo tanto, cuando no se satisface la precisión de la clasificación, la repetición del procedimiento de reproducción aleatoria ayuda a mejorar el rendimiento adicional.

VI. CONCLUSION

Este documento propone un marco genérico y efectivo para la clasificación de señales EEG sin procesar para respaldar el desarrollo de aplicaciones BCI. El marco funciona directamente en datos de EEG sin procesar sin necesidad de ningún procesamiento previo o ingeniería de características. Además, puede seleccionar automáticamente características distinguibles

dimensiones para diferentes datos de EEG, logrando así una alta usabilidad. Llevamos a cabo extensos experimentos en tres conjuntos de datos públicos bien conocidos y un conjunto de datos local. Los resultados experimentales demuestran que nuestro enfoque no solo supera varias líneas de base de última generación por un amplio margen, sino que también muestra una latencia baja y una alta resistencia para hacer frente a múltiples canales de señal de EEG y señales de EEG incompletas. Nuestro enfoque se aplica a escenarios de aplicación más amplios, como el reconocimiento de intenciones, la identificación de personas y el diagnóstico neurológico.

VIII. EXPRESIONES DE GRATITUD

Esta investigación fue parcialmente financiada por la beca ONRG NICOP N62909-19-1-2009.

REFERENCIAS

[1] X. Zhang, L. Yao, X. Wang, J. Monaghan, D. Mcalpine e Y. Zhang, "Una encuesta sobre la interfaz cerebro-computadora basada en el aprendizaje profundo: Avances recientes y nuevas fronteras", preimpresión de arXiv arXiv: 1905.04149, 2019.

[2] H. Adeli, S. Ghosh-Dastidar y N. Dadmehr, "Una metodología de caos de ondas para el análisis de eegs y subbandas de eeg para detectar convulsiones y epilepsia", IEEE Transactions on Biomedical Engineering, vol. 54, núm. 2, págs. 205–211, 2007.

[3] D. Zhang, L. Yao, X. Zhang, S. Wang, W. Chen y R. Boots, "Reconocimiento de intenciones basado en Eeg a partir de representaciones espacio-temporales a través de redes neuronales recurrentes convolucionales paralelas y en cascada", en AAAI , 2018.

[4] A. Vallabhaneni, T. Wang y B. He, "Interfaz cerebro-computadora", en Ingeniería neuronal. Springer, 2005, págs. 85–121.

[5] X. Zhang, L. Yao, QZ Sheng, SS Kanhere, T. Gu y D. Zhang, "Conversión de sus pensamientos en textos: Habilitación de la escritura cerebral a través del aprendizaje profundo de señales de eeg", 2018.

[6] X. Zhang, L. Yao, C. Huang, QZ Sheng y X. Wang, "Reconocimiento de intenciones en la vida inteligente a través de redes neuronales recurrentes profundas", en ICONIP. Springer, 2017, págs. 748–758.

[7] CV Russoniello, K. OBrien y JM Parks, "La eficacia de los videojuegos casuales para mejorar el estado de ánimo y disminuir el estrés", Journal of CyberTherapy & Rehabilitation, vol. 2, núm. 1, págs. 53 a 66, 2009.

[8] V. Schetinin, L. Jakaite, N. Nyah, D. Novakovic y W. Krzanowski, "Extracción de características con redes neuronales de tipo gmdh para la identificación de personas basada en egi", IJNS, p. 1750064 ,

[9] X. Zhang, L. Yao, SS Kanhere, Y. Liu, T. Gu y K. Chen, "Mindid: identificación de personas a partir de ondas cerebrales a través de redes neuronales recurrentes basadas en la atención", ACM IMWUT, vol. 2, núm. 3, pág. 149, 2018.

[10] V. Veeriah, R. Durvasula y G.-J. Qi, "Arquitectura de aprendizaje profundo con capas programadas dinámicamente para la predicción del conectoma cerebral", en SIGKDD. ACM, 2015, págs. 1205–1214.

[11] E. Acar, CA Bingol, H. Bingol, R. Bro y B. Yener, "Reconocimiento de convulsiones en el tensor de características de la epilepsia", en EMBS. IEEE, 2007, págs. 4273–4276.

[12] M. Fraschini, A. Hillebrand, M. Demuru, L. Didaci y GL Marcialis, "Un sistema biométrico basado en EEG que utiliza la centralidad del vector propio en redes cerebrales en estado de reposo", IEEE Signal Processing Letters, vol. 22, núm. 6, págs. 666–670, 2015.

[13] X. Zhang, L. Yao, C. Huang, S. Wang, M. Tan, G. Long y C. Wang, "Clasificación de datos de sensores multimodalidad con atención selectiva", en IJCAI-18, 2018 , págs. 3111–3117.

[14] P. Cavanagh et al., "Percepción de movimiento basada en la atención", Science, vol. 257, núm. 5076, págs. 1563–1565, 1992.

[15] JK Chorowski, D. Bahdanau, D. Serdyuk, K. Cho e Y. Bengio. 577–585.

[16] V. Mnih, K. Kavukcuoglu, D. Silver, AA Rusu, J. Veness, MG Bellemare, A. Graves, M. Riedmiller, AK Fiedjeland, G. Ostrovski et al., "Control a nivel humano a través del aprendizaje de refuerzo profundo" Naturaleza, vol. 518, núm. 7540, pág. 529, 2015.

[17] Z. Wang, T. Schaul, M. Hessel, H. Van Hasselt, M. Lanctot y N. De Freitas, "Arquitecturas de red en duelo para el aprendizaje de refuerzo profundo", vol. 48, 2016, págs. 1995-2003.

[18] M. Tokic, "Exploración adaptativa y-voraz en el aprendizaje por refuerzo basado en diferencias de valores", en Conferencia anual sobre inteligencia artificial. Springer, 2010, págs. 203–210.

[19] A. Krizhevsky, I. Sutskever y GE Hinton, "Clasificación de Imagenet con redes neuronales convolucionales profundas", en NeurIPS, 2012, págs. 1097–1105.

[20] MM o Rashid y M. Ahmad, "Clasificación del movimiento de manos de imágenes motoras usando el algoritmo de levenberg-marquardt basado en características estadísticas de la señal eeg", en ICEEICT. IEEE, 2016, págs. 1–6.

[21] X. Ma, S. Qiu, C. Du, J. Xing y H. He, "Mejora de la clasificación de imágenes motoras basadas en eeg a través de redes neuronales recurrentes espaciales y temporales", en EMBC. IEEE, 2018, págs. 1903–1906.

[22] MH Alomari, A. AbuBaker, A. Turani, AM Baniyounes y A. Manasreh, "The egg mouse: A machine learning-based brain computer interface," IJACSA, vol. 5, núm. 4, págs. 193–198,

[23] J. Sita y G. Nair, "Extracción de características y clasificación de señales de eeg para mapear el área motora del cerebro", en ICCCI. IEEE, 2013, págs. 463–468.

[24] MH Alomari, AM Baniyounes y EA Awada, "Clasificación basada en Eeg de movimientos de puños imaginados mediante aprendizaje automático y análisis de transformación de ondas", Revista internacional de avances en ingeniería electrónica y eléctrica, vol. 3, núm. 3, págs. 83 a 87, 2014.

[25] HV Shenoy, A. Vinod y C. Guan, "Regularización basada en el estimador de contracción para la clasificación de imágenes motoras del electroencefalograma", en ICICS. IEEE, 2015.

[26] P. Szczuko, "Clasificación de movimiento real e imaginario basada en un análisis de conjunto aproximado de señales eeg para aplicaciones multimedia", Herramientas y aplicaciones multimedia, vol. 76, núm. 24, págs. 25 697–25 711, 2017.

[27] CA Stefano Filho, R. Attux y G. Castellano, "Variación de los ritmos sensoriomotores de Eeg y medidas de conectividad funcional durante la imaginaria motora: relaciones lineales y enfoques de clasificación", PeerJ, vol. 5, pág. e3983, 2017.

[28] OR Pinheiro, LR Alves, M. Romero y JR de Souza, "Juego de simulador de silla de ruedas para entrenar a personas con discapacidad severa", en TISHW. IEEE, 2016.

[29] Y. Kim, J. Ryu, KK Kim, CC Took, DP Mandic y C. Park, "Clasificación de imágenes motoras usando ritmos mu y beta de eeg con patrones espaciales comunes complejos basados en una transformación fuerte no correlacionada" Inteligencia computacional y neurociencia, vol. 2016, págs. 1 a 14, 2016.

[30] L. Ma, JW Minett, T. Blu y WS Wang, "Biometría basada en EEG en estado de reposo para la identificación individual mediante redes neuronales convolucionales", en EMBC. IEEE, 2015, págs. 2848–2851.

[31] S. Yang y F. Deravi, "Novedosas funciones basadas en hht para la identificación biométrica mediante señales eeg", en ICPR. IEEE, 2014, págs. 1922–1927.

[32] D. Rodrigues, GF Silva, JP Papa, AN Marana y X.-S. Yang, "Identificación de personas basada en Eeg mediante un algoritmo binario de polinización de flores", Expert Systems with Applications, vol. 62, págs. 81–90, 2016.

[33] KP Thomas y AP Vinod, "Identificación biométrica de personas que utilizan características de entropía de muestra de eeg durante el estado de reposo", en SMC. IEEE, 2016, págs. 003 487–003 492.

[34] S. Ziyabari, V. Shah, M. Golmohammadi, I. Obeid y J. Picone, "Métricas de evaluación objetivas para la clasificación automática de eventos eeg", preimpresión de arXiv arXiv:1712.10107, 2017.

[35] A. Harati, M. Golmohammadi, S. López, I. Obeid y J. Picone, "Clasificación de eventos eeg mejorada usando energía diferencial", en SPMB. IEEE, 2015, págs. 1–4.

[36] Y. Zhang, S. Yang, Y. Liu, Y. Zhang, B. Han y F. Zhou, "Integración de 24 tipos de características para detectar y predecir con precisión las convulsiones mediante señales de electroencefalograma del cuero cabelludo", Sensores (Basilea, Suiza), vol. 18, núm. 5, 2018.

[37] TR Goodwin y SM Harabagiu, "Aprendizaje profundo a partir de informes eeg para inferir información infraespecificada", AMIA Summits on Translational Science Proceedings, vol. 2017, págs. 112 y 121, 2017.

[38] M. Golmohammadi, AHHN Torbati, SL de Diego, I. Obeid y J. Picone, "Análisis automático de eegs usando big data y arquitecturas híbridas de aprendizaje profundo", versión preliminar de arXiv arXiv:1712.09771, 2017.

[39] X. Zhang, L. Yao y F. Yuan, "Incrustación variacional adversaria para un aprendizaje semisupervisado sólido", en SIGKDD, 2019, págs. 139–147.

[40] M. Golmohammadi, V. Shah, S. Lopez, S. Ziyabari, S. Yang, J. Cama ratta, I. Obeid y J. Picone, "The tuh eeg attack corpus", en Reunión Anual de ACNS, 2017, pág. 1.