

PAPEL • ACCESO ABIERTO

Detección y clasificación pseudo-en línea para movimientos de miembros superiores

Para citar este artículo: Jiansheng Niu y Ning Jiang 2022 J. Neural Eng. **19** 036042

Ver el [artículo en línea](#) para actualizaciones y mejoras.

También te puede interesar

[Detección en línea de movimiento durante acciones de alcance y agarre naturales y autoiniciadas a partir de señales de EEG](#) Joana Pereira, Reinmar Kobler, Patrick Ofner et al.

[Influencia de los patrones de movimiento de las extremidades superiores en las mediciones del acelerómetro: una serie de casos pediátricos](#) Jessica Trac, Jaclyn Dawe, Jirapat Likitlersuang et al.

[Restauración del movimiento complejo en el miembro superior paralizado](#) Brady A Hasse, Drew EG Sheets, Nicole L Holly et al.



**EDINBURGH
INSTRUMENTS**

**WORLD LEADING
MOLECULAR
SPECTROSCOPY SOLUTIONS**



edinst.com

Revista de Ingeniería Neural



ACCESO ABIERTO

RECIBÍO
2 enero 2022REVISADO
4 abril 2022ACEPTADO PARA PUBLICACIÓN
10 junio 2022PUBLICADO
23 junio 2022

El contenido original de este trabajo se puede utilizar bajo los términos de la [licencia Creative Commons Attribution 4.0](#).

Cualquier distribución posterior de este trabajo debe mantener la atribución al autor(es) y el título del trabajo, la cita de la revista y el DOI.



PAPEL

Detección y clasificación pseudo-en línea para movimientos de miembros superiores

Jiansheng Niu³ y Ning Jiang^{1,2,yy}

¹ Centro Nacional de Investigación Clínica para Geriátrica, Hospital de China Occidental Universidad de Sichuan, Chengdu, Sichuan, República Popular de China Centro Med-X
² para Fabricación, Universidad de Sichuan, Chengdu, Sichuan, República Popular de China Departamento de Ingeniería de Diseño de Sistemas, Universidad de Waterloo,
³ Waterloo, Ontario, Canadá Autor a quien debe dirigirse toda correspondencia.

Correo electrónico: jiangning21@wchscu.cn**Palabras clave:** interfaz cerebro-computadora, electroencefalograma (EEG), movimiento de miembros superiores, detección, clasificación, intención motora*Objetivo*

abstracto. Este estudio analizó la detección (movimiento versus no movimiento) y la clasificación (diferentes tipos de movimientos) para decodificar las voliciones de movimiento de las extremidades superiores de una manera pseudo-en línea. *Acercarse*. Nueve sujetos sanos ejecutaron cuatro movimientos autoiniciados: extensión de la muñeca izquierda, extensión de la muñeca derecha, extensión del dedo índice izquierdo y extensión del dedo índice derecho. Para la detección, investigamos el rendimiento de tres clasificadores individuales (máquina de vector de soporte (SVM), EEGNET y geometría de Riemann con SVM) en tres bandas de frecuencia (0,05–5 Hz, 5–40 Hz, 0,05–40 Hz). La mejor banda de frecuencia y las mejores combinaciones de clasificadores se construyeron para realizar una canalización de procesamiento de conjunto utilizando la votación por mayoría. Para la clasificación, utilizamos un modelo de geometría de Riemann potenciado adaptativo para diferenciar los movimientos contralaterales e ipsilaterales. *Resultados principales*. El modelo de conjunto logró una tasa de verdaderos positivos del $79,6 \pm 8,8\%$ y $3,1 \pm 1,2$ falsos positivos por minuto con una latencia de $75,3 \pm 112,6$ ms en una tarea de detección pseudoen línea. La siguiente clasificación dio alrededor del 67% de precisión para diferenciar los movimientos contralaterales. *Significado*. El método de conjunto y el procedimiento de prueba pseudo-en línea recientemente propuestos podrían proporcionar un diseño robusto de interfaz cerebro-computadora para la decodificación de movimiento.

1. Introducción

La interfaz cerebro-computadora (BCI) basada en voliciones sensoriomotoras encubiertas y abiertas se puede utilizar para decodificar las intenciones de movimiento de las actividades cerebrales sin estímulos externos. Estos BCI también se denominan BCI endógenos, que son diferentes de los BCI exógenos que dependen de estímulos externos, como los basados en P-300 y los potenciales evocados visuales en estado estacionario (SSVEP) [1]. El electroencefalograma (EEG) es una manifestación eléctrica de las actividades cerebrales, registrada de forma no invasiva sobre el cuero cabelludo, y es una fuente de señal principal de BCI. Se ha demostrado en la literatura que las BCI endógenas que usan EEG tienen el potencial de inducir neuroplasticidad, lo que las convierte en una herramienta potencial en la rehabilitación de la función motora para los sobrevivientes de accidentes cerebrovasculares y pacientes con lesiones de la médula espinal (LME) [1–6]. Como resultado, se invirtió una cantidad considerable de esfuerzo en el diseño de un sistema BCI robusto capaz de detectar intenciones de movimiento [7–9]. Además de la precisión de decodificación, que siempre ha sido el rendimiento clave

índice en la literatura de investigación, el retraso de ciclo cerrado es una consideración crucial para las BCI destinadas a aplicaciones de rehabilitación, ya que se ha demostrado que afecta la eficiencia de la inducción de neuroplasticidad [10, 11].

Con este fin, se exploró ampliamente el potencial cortical relacionado con el movimiento (MRCP) para decodificar la intención del movimiento debido a su respuesta de latencia corta y al protocolo de movimiento balístico natural [12–16]. Es un EEG de baja frecuencia (0,05–5 Hz) generado por intenciones de movimiento, que comienza aproximadamente 1,5–2 s antes del inicio del movimiento con una amplitud de entre 5 y 30 μV [17]. Aparte de MRCP, el ritmo sensorimotor (SMR) también dio resultados de clasificación prometedores en tareas de imágenes motoras [18]. Sin embargo, la SMR normalmente se induce mediante ejecuciones repetitivas o imaginaciones de un movimiento, lo que podía dar como resultado un retraso en la detección de bucle cerrado [13, 18]. De hecho, el retraso o las latencias de detección generalmente no se informaron en los estudios de SMR, lo que dificulta inferir su viabilidad para inducir plasticidad neurológica [19, 20]. Sin embargo, todavía se hicieron algunos intentos

combinar MRCP y SMR para un mejor rendimiento de decodificación [21–23].

Actualmente en la literatura, los estudios de las extremidades inferiores centrados en la dorsiflexión del tobillo y la iniciación de la marcha ya demostraron la viabilidad de los estudios en línea. Detección de movimiento tanto encubierto como abierto. ción a través de MRCP [10, 12, 14]. Varios miembro superior También se han experimentado movimientos con fines de control y rehabilitación, que se pueden separar en dos categorías según la complejidad del movimiento: movimientos simples que incluyen la abducción del hombro, extensión de codo/muñeca/dedos [16, 22, 24] y movimientos compuestos como alcanzar movimientos [24–27]. La imaginaria del compuesto Se encontró que el movimiento tiene mayor entropía espectral de potencia y mayor desincronización alfa que movimiento simple [24, 25]. Además, se encontró que las CPRM durante los movimientos proximales tenían mayor amplitud que las de los movimientos distales. Una diferencia estadísticamente significativa entre estos dos fue encontrado a partir de Cz, dependiendo de la articulación involucrada en el movimiento [28]. La precisión de detección de la articulación distal movimientos como los movimientos de la muñeca fueron más bajos que movimientos proximales, que implican el hombro y codo [22]. Por lo tanto, la detección de movimiento simple distal podría ser más desafiante que el compuesto proximal movimientos

Entre varios estudios de movimiento, hay esencialmente dos tipos de objetivos: (a) Detección, refiriéndose a la identificación de la voluntad de movimiento (cubrir o abierto) del estado de reposo o reposo, es decir, Mov vs. non Mov; (b) Clasificación, que se refiere a la identificación de un tipo particular de volición de movimiento de un conjunto de diferentes tipos de voliciones de movimiento, es decir, Mov vs. Mov [21, 22, 27, 29]. Varias aplicaciones exitosas de detección ya se informaron para un solo movimiento [27, 30]. Clasificación asíncrona implícitamente incluye procedimientos de detección y clasificación. Sin embargo, la forma de detección puede ser diferente según el protocolo del experimento y las configuraciones del clasificador. Por ejemplo, algunos estudios consideraron la reposo o estado inactivo como una clase de la tarea de clasificación [31, 32], mientras que otros dividen la detección y la clasificación en dos pasos [33, 34].

Tanto la detección como la clasificación necesitan diseño modelos de aprendizaje automático para aprender intrínsecamente patrones de señal o características para cada clase. relacionado con BCI Los métodos de aprendizaje automático evolucionaron de los tradicionales enfoques basados en la ingeniería de características para modelos de aprendizaje profundo. Análisis discriminante lineal (LDA), un método tradicional representativo, ha sido ampliamente aplicado en la investigación MRCP debido a su robusta actuación. Muchos estudios emplearon LDA con un regularización de la contracción para lograr el estado del arte precisión [30, 31, 33]. basado en la geometría riemanniana El enfoque es otro método entre el método tradicional basado en características y el enfoque de aprendizaje profundo. Implícitamente incrusta temporal y información espacial de EEG en matrices de covarianza.

Se demostró que es superior a los métodos tradicionales en múltiples paradigmas de BCI, especialmente para motores imágenes [35–37]. Más recientemente, también se propusieron varias arquitecturas de aprendizaje profundo y mostraron su potencial para aplicaciones BCI [38–41]. Sin embargo, pocos estudios combinaron estos métodos para investigar si un se podría lograr un aumento adicional del rendimiento.

En el estudio actual, investigamos la posibilidad de decodificar movimientos simples distales, analizando el EEG de nueve sujetos que realizan cuatro movimientos: (a) extensión de la muñeca izquierda (WE_L), (b) extensión de la muñeca derecha. extensión (WE_R), (c) extensión del dedo índice izquierdo (IE_L), (d) extensión del dedo índice derecho (IE_R). Nosotros adoptó un canal de procesamiento jerárquico, donde un paso de detección seguido de un paso de clasificación. los el análisis de datos se realizó de forma pseudo-online. Se investigaron tres bandas de frecuencia de EEG para detección y clasificación, incluyendo banda baja (0,05–5 Hz), banda alta (5–40 Hz) y banda completa (0,05–40 Hz). En el paso de detección, tres Se entrenaron clasificadores, incluido un SVM, un método de geometría de Riemann y un método de aprendizaje profundo. Sus resultados fueron entonces integrados por mayoría de votos. En el paso de clasificación, un impulso adaptativo modelo de regresión logística con geometría de Riemann fue empleado.

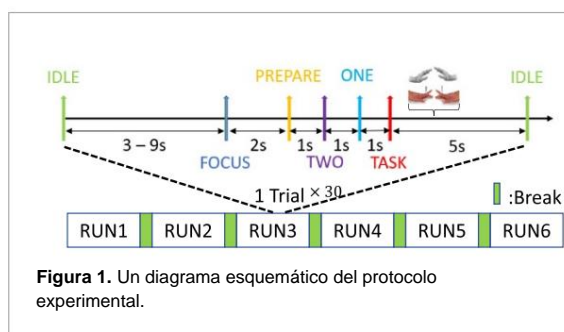
2. Método

2.1. Procedimiento experimental

Un total de nueve participantes sanos diestros (dos F y siete M) fueron reclutados en este estudio. Ética la aprobación fue concedida por la Universidad de Waterloo (aprobación número 43069). Un formulario de consentimiento informado con detalles del procedimiento experimental, el equipo del experimento y los riesgos potenciales fue firmado por cada participante.

El participante estaba sentado en una silla con ambos antebrazos colocados sobre un escritorio. Un monitor de computadora fue colocado a 0,5 m delante de él/ella. El participante fue necesarios para realizar los cuatro movimientos balísticos del aliado durante el experimento: WE_L, WE_R, IE_L y IE_R. Se recolectaron cuarenta y cinco ensayos para cada movimiento para producir 180 ensayos en total. Todos los ensayos se mezclaron al azar y se dieron breves descansos después 30 ensayos consecutivos. Cada participante realizó seis carreras de 30 senderos. Los datos de EEG se adquirieron continuamente para cada ejecución, lo que hizo posible realizar análisis pseudo-online. El protocolo experimental es se muestra esquemáticamente en la figura 1.

En cada ensayo, se mostraron seis señales visuales en el siguiente orden en la figura 1: Inactivo, Foco, Preparar, Dos, Uno y Tarea. La señal de enfoque duraría 2 s, seguido por las señales Preparar, Dos y Uno, cada una de ellas que duraría 1 s. Finalmente, la señal de Tarea sería durar 5 s. El período de una prueba se aleatorizó entre 13 s y 19 s variando el tiempo de inactividad de 3 s a 9 s. Los participantes estaban obligados a realizar movimientos autoiniciados 1 s después de la tarea



aparecieron señales. Se reprodujo una voz de computadora del nombre de la tarea al comienzo de cada prueba. En la pantalla se mostraba una imagen ilustrativa y el nombre de la tarea actual para cada prueba.

2.2. Adquisición y preprocesamiento de la

señal Se utilizó un sistema de EEG multicanal (Enobio32, NeuroElec tric) para recopilar datos de EEG y electromiografía (EMG) de acuerdo con el sistema internacional 10–20. Los datos de EEG se registraron de 27 canales (Fp1, Fp2, F7, F3, Fz, F4, F8, FC5, FC1, FC2, FC6, T7, C3, C1, Cz, C2, C4, T8, CP5, CP1, CP2, CP6, P7, P3, Pz, P4, P8) a una frecuencia de muestreo de 500 Hz. El electrodo de referencia se colocó en el lóbulo de la oreja derecha.

Además, se conectaron cuatro electrodos EMG al músculo extensor digitorum y al músculo extensor carpi ulnaris en ambos brazos con referencia común en el lóbulo de la oreja derecha para medir las actividades musculares de las extensiones del dedo índice y las extensiones de la muñeca.

Las señales EMG se filtraron primero mediante un filtro de paso de banda Butterworth no causal de sexto orden con frecuencias de corte de 70 Hz y 200 Hz para eliminar la interferencia de ECG y el ruido de la línea eléctrica [42]. Luego, aplicamos el operador de energía Teager-Kaiser (TKEO) para mejorar la relación señal-ruido [43]. La salida del operador TKEO se suavizó aún más mediante un promedio móvil para eliminar ráfagas breves no relacionadas con los movimientos. Finalmente, se aplicó un umbral de 1/10 de amplitud EMG máxima para extraer movimiento comienzo.

Los datos de EEG se filtraron mediante filtros de paso de banda Butterworth no causales de cuarto orden para generar tres bandas de datos: banda baja (0,05–5 Hz), banda alta (5–40 Hz), banda completa (0,05–40 Hz). Se aplicó el análisis de componentes independientes para descomponer el EEG en fuentes latentes. Luego, un experto inspeccionó visualmente las fuentes obtenidas e identificó aquellas relacionadas con los movimientos oculares.

Finalmente, se rechazaron las fuentes relacionadas con el movimiento ocular y las fuentes restantes se proyectaron de vuelta al espacio del sensor para reconstruir el EEG. Después de que los datos se muestrearon a 100 Hz, se segmentaron en ventanas Mov y no Mov con una duración de 2 s. Los detalles de la segmentación se proporcionan en la sección

2.8.1. Finalmente, un experto inspeccionó las ventanas y eliminó aproximadamente el 10% de las contaminadas por ruido

Para analizar las oscilaciones cerebrales, usamos la ondícula de Morlet con cinco ciclos para calcular la

representación tiempo-frecuencia con resolución de frecuencia de 1 Hz [44, 45]. Luego, al promediar la potencia entre 5 y 40 Hz de la representación de tiempo-frecuencia se obtuvo la potencia de banda alta, que se ilustra en el mapa topográfico. La desincronización/sincronización relacionada con eventos (ERD/ERS) de γ 2 s a 4 s se calculó restando y dividiendo la potencia media durante la línea base (γ 3 s a γ 2 s)

[46]. El preprocesamiento de EEG y los análisis de oscilación cerebral se realizaron con el paquete Python MNE [47].

2.3. Geometría de Riemann

En la variedad de Riemann, cada punto representa una matriz definida positiva simétrica, necesitamos transferir datos de EEG a esta forma para utilizar las propiedades de la geometría de Riemann. Con este fin, se construyó una matriz de covarianza de potencial relacionado con eventos (ERP) para capturar información temporal y espacial [35].

Para la tarea de detección, cada ventana se apiló primero con una plantilla Mov (promedio de todas las ventanas Mov) y una plantilla no Mov (promedio de todas las ventanas no Mov) para construir una superventana, que tenía la forma de $(27 \times 3, 200)$. Luego, se obtuvo una matriz de covarianza ERP multiplicando la superventana por su transpuesta, que tenía la forma de $(27 \times 3, 27 \times 3)$ [35]. Para la clasificación WE-vs.-IE, cada ventana se apiló con la plantilla WE (promedio de todas las ventanas WE) y la plantilla IE (promedio de todas las ventanas IE) para construir la superventana y la siguiente matriz de covarianza ERP. Se repitió un procedimiento similar para la clasificación de izquierda frente a derecha. Como resultado, la matriz de covarianza ERP de clasificación también tenía la forma de $(27 \times 3, 27 \times 3)$.

Luego, cada punto se proyectó a un espacio tangente mediante mapeo logarítmico para formar un vector de características como entrada a los algoritmos clásicos. El vector de características tenía una dimensión de $n \times (n + 1)/2$, donde n era el tamaño de fila o columna (27×3) de la matriz de covarianza ERP [48]. Este estudio construyó dos clasificadores en el espacio tangente: SVM y regresión logística potenciada adaptativa (Ada-boost), llamados R_SVM y R_Ada_Lgr, respectivamente.

2.4. EEGNET

Otro algoritmo que utilizamos fue EEGNET, una arquitectura compacta de aprendizaje profundo diseñada específicamente para decodificar EEG y se aplicó con éxito en múltiples paradigmas [38]. Utilizó tres capas convolucionales para extraer información temporal y espacial de los datos. La entrada a este modelo fue una matriz 2D con dimensiones de canal y muestra, en forma de $(27, 200)$ como ventana de 2 s. La primera capa agregó un kernel convolucional con tamaño $(1, 50)$ para filtrar cada canal en orden temporal. La salida de la primera capa contenía datos filtrados temporalmente.

La segunda capa aplicó un kernel $(27, 1)$ (siendo 27 el número de canales) en la salida de la primera capa para asignar un peso a cada canal e incrustar información espacial en su salida. Una capa conv2d separable

información temporal y espacial integrada aprendida de la primera y segunda capa. Finalmente, la clasificación se realizó después de una capa completamente conectada usando SoftMax. Su optimizador era Adam, y su función de pérdida era la entropía cruzada categórica. Ajustamos el número de filtros utilizados en cada capa ($F1 = 8$, $D = 6$, $F2 = 48$) [38]. La tasa de caída óptima se estableció en 0,5.

2.5. SVM

SVM se ha aplicado ampliamente en el campo de BCI. Encuentra el mayor margen entre clases al resolver un problema de optimización basado en vectores de muestra. Los datos de EEG se transformaron a 1D al concatenar las muestras de todos los canales, lo que resultó en un vector de características largas de 5400 (27×200) para una ventana de 2 s. Luego, el vector de características 1D se proporcionó a una SVM con un kernel de función de base radial como entrada, para aprender las características intrínsecas de cada clase.

2.6. Fusión de detección

Los resultados de detección de EEGNET, R_SVM y SVM se procesaron posteriormente mediante un método de conjunto simple. Primero, estos tres clasificadores predijeron individualmente cada ventana como Mov o no Mov. Luego, la etiqueta final para la ventana se asignó mediante votación por mayoría.

2.7. Método de clasificación

AdaBoost se utilizó para la tarea de clasificación. Ada Boost es otro método de aprendizaje de conjunto que entrena secuencialmente a un alumno débil (clasificadores con un rendimiento ligeramente superior al nivel de probabilidad) en muestras continuamente reponderadas para mejorar su rendimiento. Se eligió la regresión logística como el alumno débil en este estudio. AdaBoost entrenó diez modelos de regresión logística utilizando características de Riemann para la clasificación.

2.8. Análisis pseudo-en línea

En un escenario BCI en línea, el algoritmo analiza datos en tiempo real y hace predicciones constantemente. Para simular el escenario en línea después de la recopilación de datos, utilizamos la técnica de ventana deslizante para procesar los datos de EEG adquiridos continuamente, es decir, de forma pseudo-en línea. En este análisis, los clasificadores de detección predijeron en primer lugar una ventana como Mov o no Mov. Luego, el clasificador de clasificación predijo además el tipo de movimiento de las ventanas Mov.

Realizamos una validación cruzada de seis veces basada en seis ejecuciones para evaluar el rendimiento del clasificador. La asignación de las ejecuciones de entrenamiento, prueba y validación fue diferente para los diferentes algoritmos. Por ejemplo, EEGNET usó cuatro ejecuciones para capacitación, una ejecución para validación y la ejecución restante para prueba. Sin embargo, R_SVM, SVM y R_Ada_Lgr utilizaron cinco ejecuciones para entrenamiento y la restante para prueba, ya que no fue necesario ajustar los hiperparámetros.

Para analizar el impacto de las bandas de frecuencia de EEG en los clasificadores, los algoritmos de detección y clasificación se entrenaron utilizando tres bandas de frecuencia.

(bajo, alto y completo). El entrenamiento y la prueba de un algoritmo utilizaron la misma banda de frecuencia.

2.8.1. Detección pseudo-en línea

En la fase de entrenamiento, primero separamos los segmentos Mov y no Mov en las pruebas de entrenamiento. Como se muestra en la figura 2, el segmento Mov abarca desde $\bar{y}1,6$ s hasta 0,6 s de cada intento, mientras que el segmento no Mov contiene dos segmentos: desde $\bar{y}8$ s hasta $\bar{y}2$ s y desde 2 s hasta 8 s, siendo 0 s el inicio del movimiento (identificado por el procesamiento EMG). Luego, los segmentos Mov y no Mov fueron escaneados por una ventana de tiempo de 2 s con 0,01 s de zancada y 0,05 s de zancada, respectivamente, para generar múltiples ventanas. Se eligió la zancada más larga para los segmentos que no son de movimiento para ahorrar energía computacional. Con el fin de equilibrar las ventanas Mov y no Mov, se seleccionaron al azar 21 ventanas de 162 ventanas no Mov para igualar la cantidad de ventanas Mov en cada prueba.

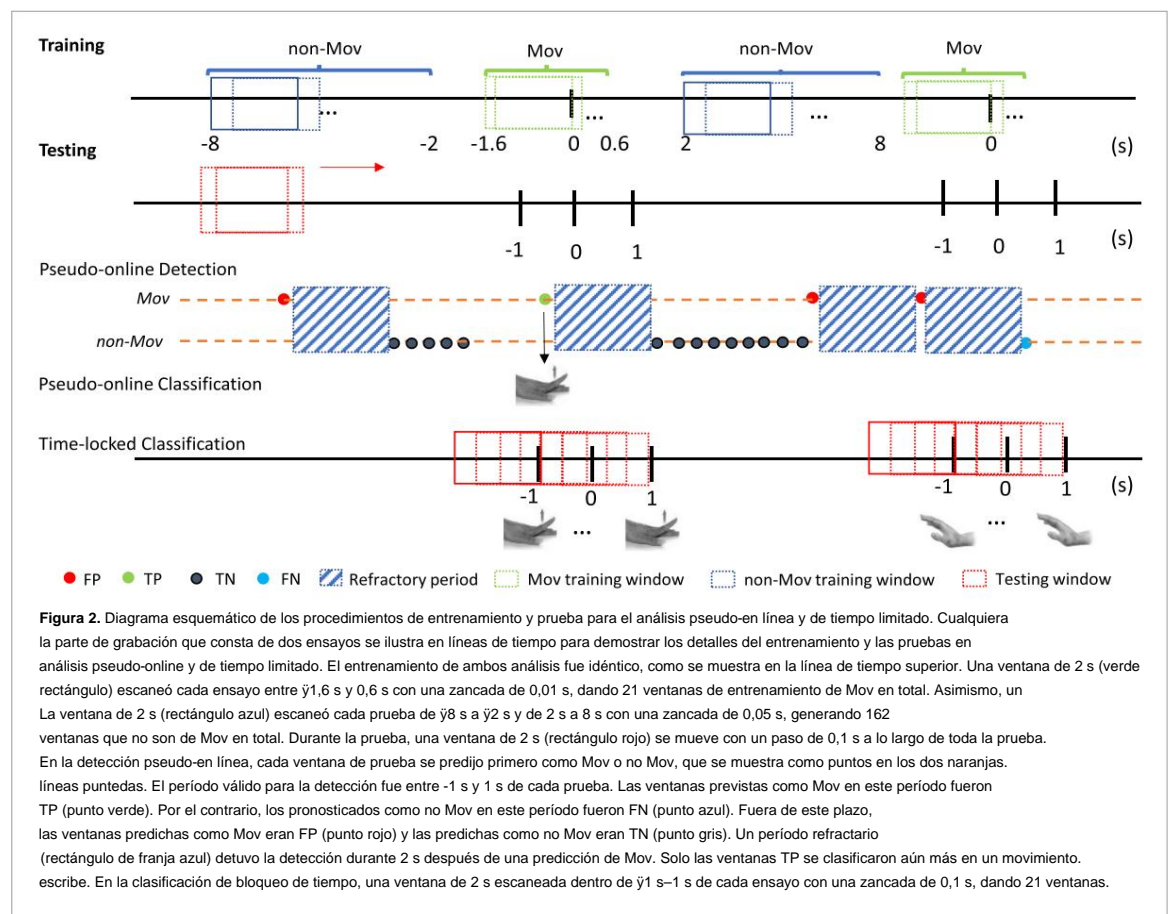
En la fase de prueba, la ejecución de la prueba se escaneó en una ventana de tiempo de 2 s con un paso de 0,1 s para obtener ventanas de prueba, como se muestra en la figura 2. Como se describe en la sección 2.6, estas ventanas se clasificaron en primer lugar por EEGNET, R_SVM y SVM individualmente. Luego, las predicciones finales se obtuvieron por el método de conjunto mediante votación mayoritaria. También se investigó la votación unánime de múltiples ventanas consecutivas.

Se introdujeron cuatro métricas de rendimiento para la evaluación: tasa de verdaderos positivos (TPR), falsos positivos por minuto (FPs min^{-1}), puntaje F1, latencia de detección. TPR fue el número de TP (puntos verdes en la figura 2) dividido por la suma de TP y FN (puntos azules en la figura 2). FP min^{-1} fue el número de FP (puntos rojos en la figura 2) dividido por la duración del estado sin movimiento. TPR y FPs min^{-1} se presentaron en una curva característica del operador del receptor (ROC) variando el número de ventanas consecutivas utilizadas para la votación unánime. Se aplicó un tiempo refractario de 2 s para evitar que los clasificadores generen nuevas detecciones dentro de los 2 s de la última. Dado que algunos clasificadores fueron entrenados en MRCP de banda baja cuya longitud es de 2 s, no era razonable realizar detecciones múltiples para una sola intención. La puntuación F1 representó el equilibrio entre precisión y recuperación, que se calculó mediante $TP/(TP + 0,5 \times (FP + FN))$. Como el período Mov fue más corto que el período no Mov, se eligió la puntuación F1 debido a su solidez en escenarios desequilibrados [39].

La latencia de detección se definió como la diferencia de tiempo entre el inicio del movimiento y el inicio detectado.

2.8.2. Pseudo-clasificación en línea

Después de la detección, la clasificación de cuatro movimientos fue realizada por R_Ada_Lgr. Las ventanas de entrenamiento se extrajeron en una ventana de tiempo de 2 s con zancadas de 0,01 s en los segmentos Mov (es decir, $\bar{y}1,6$ s–0,6 s de las pruebas) para cada prueba. Investigamos las clasificaciones de izquierda frente a derecha y WE frente a IE combinando sus ventanas de entrenamiento en consecuencia. Por ejemplo, la clasificación izquierda versus derecha combinó ventanas de WE_L e IE_L con



la clase izquierda y las ventanas de WE_R e IE_R como el Clase correcta. El mismo procedimiento se llevó a cabo para Clasificación WE-vs.-IE también.

Durante la prueba, la ventana de tiempo actual sería ser predicho por el R_Ada_Lgr entrenado una vez que se activó una detección, como se muestra en la figura 2. La matriz de precisión y confusión evaluó la clasificación rendimiento a nivel de prueba, ya que una prueba dio una etiqueta de clasificación.

2.9. Clasificación de bloqueo de tiempo

La clasificación con bloqueo de tiempo se realizó para analizar el rendimiento de la clasificación utilizando el tres bandas. Genera predicciones para todas las ventanas. entre $\bar{y}1$ s y 1 s de cada ensayo, como se muestra en la figura 2, en contraste con clasificar solo la ventana detectada en el escenario pseudo-online.

También investigamos la clasificación WE-vs.-IE y Left-vs.-right en forma de bloqueo de tiempo. El entrenamiento la extracción de la ventana establecida fue la misma que la pseudo clasificación en línea. La prueba se realizó sobre todas las ventanas de ensayos de prueba como se muestra en la figura 2. La precisión de cada ventana se calculó en un manera basada en ensayos, lo que significa que la proporción de ensayos clasificados correctamente fue la precisión para ese ventana.

2.10. análisis estadístico

Realizamos un análisis de varianza de dos vías (ANOVA) para investigar el efecto de diez modelos en el movimiento

detección. El factor fijo fue el modelo de detección. con diez niveles: modelo de conjunto y tres submodelos entrenados por tres bandas de frecuencia, como se muestra en la figura 3. El sujeto fue considerado como un azar factor. La hipótesis nula fue que los modelos de detección no tuvieron una influencia significativa en el índice de rendimiento, es decir, la puntuación F1. Al detectar una significación estadística, realizamos Bonferroni por pares comparación con el intervalo de confianza del 95%. Se agruparon diez modelos en función de su diferencia de medias [49]. Las agrupaciones se indicaron con letras, las que no compartiendo la misma carta eran significativamente diferentes.

Se llevó a cabo el mismo enfoque para probar si la banda de frecuencia desempeñaba un papel importante durante la clasificación pseudo en línea. Se realizó ANOVA de dos vías eligiendo bandas de frecuencia como factor fijo y sujeto como factor aleatorio. La comparación por pares de Bonferroni con un intervalo de confianza del 95% generó información de agrupación. Todos los análisis estadísticos se realizaron utilizando Minitab Ver. 21

3. Resultados

3.1. Detección y clasificación pseudo-en línea

Para evaluar el desempeño de múltiples clasificadores en diferentes bandas de frecuencia, la figura 3 presenta el violín gráficos de puntajes F1 para diez combinaciones entre diferentes algoritmos y bandas de frecuencia. hubo 54 Puntuaciones F1 calculadas para cada combinación (nueve sujetos, cada uno con seis carreras). La prueba de ANOVA mostró

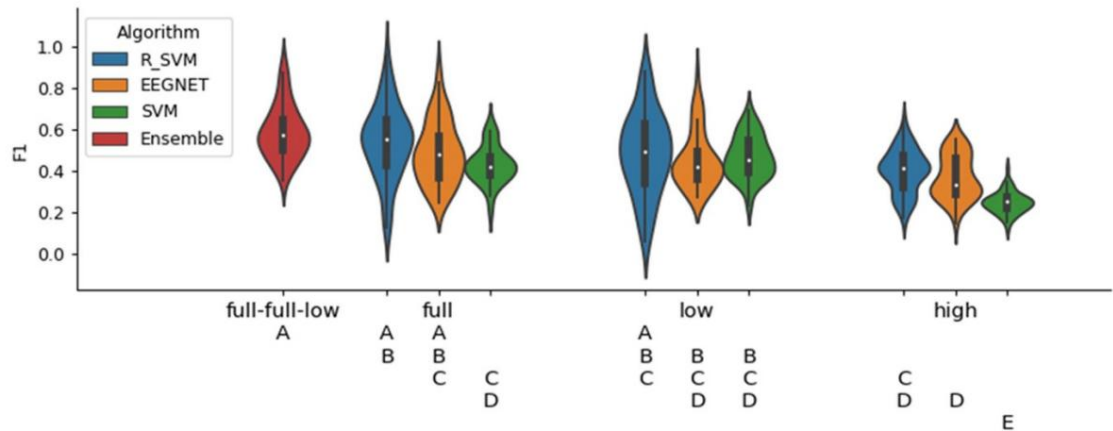


Figura 3. Gráficos de violín de puntajes F1 para todos los clasificadores usando diferentes bandas. Cuatro algoritmos, incluidos R_SVM, EEGNET, SVM y el método de conjunto, se presentan en azul, amarillo, verde y rojo, respectivamente. Los resultados de las bandas de frecuencia completa, baja y alta se agrupan en tres grupos. El método de conjunto consta de R_SVM entrenado en banda completa, EEGNET entrenado en banda completa y SVM entrenado en banda baja, que se muestra como full-full-low. Para cada diagrama de violín, el valor de la mediana se muestra como el punto blanco, la barra negra representa el rango intercuartil, la línea fuera de la barra representa el resto de la distribución. La curva exterior es la densidad kernel de la distribución de datos. Las letras debajo de la gráfica muestran los grupos significativos calculados por comparación por pares de Bonferroni con un intervalo de confianza del 95%. Los grupos que no comparten una letra son significativamente diferentes.

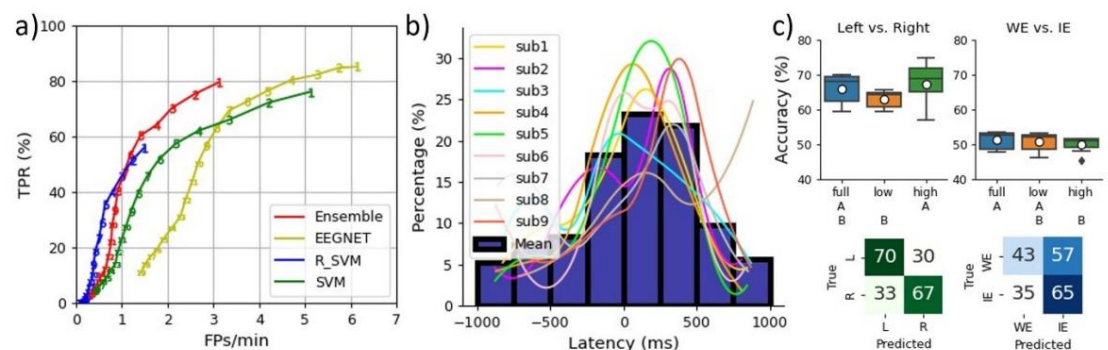


Figura 4. Resultados de detección y clasificación pseudo-online. El panel (A) muestra la ROC de detección del método de conjunto, SVM, R_SVM y EEGNET en rojo, verde, azul y amarillo, respectivamente. Los puntos en cada línea están representados por los números. Representan la cantidad de ventanas de tiempo consecutivas necesarias para activar la detección, desde 1 en la parte superior derecha hasta 19 en la parte inferior izquierda. El panel (B) muestra el histograma porcentual de las latencias de detección utilizando el método de conjunto para cada sujeto (curvas de color) y la media de todos los sujetos (barras moradas en primer plano). El panel (C) muestra los diagramas de caja de precisión y las matrices de confusión de las clasificaciones de izquierda frente a derecha y WE frente a IE. Para cada diagrama de caja, las precisiones de banda completa, baja y alta se muestran en azul, amarillo y verde, respectivamente. La precisión media de nueve sujetos se muestra como un punto blanco. La letra debajo de cada banda muestra la agrupación de significación calculada por comparación por pares de Bonferroni con un nivel de confianza del 95%. Los grupos que no comparten una letra son significativamente diferentes. La matriz de confusión verde representa el resultado de clasificación de banda alta para izquierda frente a derecha, mientras que la matriz de confusión azul representa el resultado de clasificación de banda completa para WE-vs.-IE. Están normalizados para que la suma de cada fila sea 100.

ese modelo de detección tuvo un efecto significativo en la puntuación F1 (grado de libertad = 9, $F = 17,11$, $p < 0,001$).

La comparación adicional por pares de Bonferroni mostró que los clasificadores entrenados en banda completa eran significativamente mejores que los clasificadores entrenados en banda baja, ya que no compartían la misma letra de agrupación, como se muestra en la figura 3. Tres algoritmos mostraron su adaptación para diferentes bandas de frecuencia. Por ejemplo, R_SVM y EEGNET se desempeñaron mejor con la banda completa, mientras que SVM obtuvo las puntuaciones F1 más altas con la banda baja.

Como resultado, el método de conjunto estuvo constituido por R_SVM y EEGNET entrenados en banda completa junto con SVM entrenado en banda baja, que se muestra como el diagrama de violín rojo en la figura 3. En general, el método de conjunto logró la puntuación F1 más alta y fue significativamente mejor que

la mayoría de los submodelos incluyen SVM entrenado en banda completa, EEGNET entrenado en banda baja, SVM entrenado en banda baja y todos los modelos entrenados en banda alta basados en agrupaciones significativas que se muestran en la figura 3.

A partir de estos resultados, los análisis posteriores adoptaron EEGNET entrenado en banda completa, R_SVM entrenado en banda completa, SVM entrenado en banda baja y el método de conjunto sin mencionar la banda explícitamente.

Para evaluar el desempeño del procesamiento pseudo-en línea, la curva ROC de detección, el histograma de latencia de detección y la precisión de clasificación con matriz de confusión se muestran en la figura 4. En la figura 4(a), se presentan TPR y FPs min⁻¹ para diferentes clasificadores como puntos en las curvas ROC con el número de ventanas consecutivas requeridas para activar las detecciones como

Tabla 1. Detección pseudo-online TPR, FPs min⁻¹ y latencias utilizando el método de conjunto.

Tema	TPR % FP (min)		latencias
			(milisegundos)
1	85.5	3.3	32.0
2	84.8	3.4	62.7
3	75.2	4.4	7.2
4	85.0	3.0	16.8
5	96.0	1.8	64.5
6	77.3	2.8	121
7	68.2	4.2	61.2
8	73.4	0.9	340.1
9	71.2 Media ± DE 79.6	4.3	94.6
± 8.8		3.1 ± 1.2	75.3 ± 112.6

el umbral. ROC fue elegido para mostrar el impacto del número de ventana de detección consecutiva en el clasificador actuación. Para todos los algoritmos, con el requisito número de ventanas consecutivas aumentando, TPR y FPs min⁻¹ disminuyó, moviéndose gráficamente desde el lado superior derecho al lado inferior izquierdo a lo largo de la respectiva curva ROC. Comparado con el conjunto método con el mismo número de ventana, EEGNET produjo tanto TP como FP más altos min⁻¹, tiempo R_SVM proporcionó un min⁻¹ de FP más bajo, pero a costa de menor TPR. El rendimiento de SVM fue más equilibrado entre EEGNET y R_SVM. Como resultado, el El método de conjunto se desempeñó mejor que los tres clasificadores individuales, con FP inferiores min⁻¹ y mayor TPR (la línea roja ubicada en la parte superior izquierda lado de los demás en la gráfica ROC (figura 4(a)). Se adoptó una ventana para la detección en el análisis posterior, ya que proporcionó la mejor TPR con razonable FP min⁻¹.

La latencia de detección es la diferencia de tiempo entre la detección y su correspondiente inicio de movimiento identificados por procesamiento EMG. Los histogramas fueron obtenidos al contar el porcentaje de detecciones correctas divididas en ocho subsecciones de 250 ms de ancho de 1000 ms a 1000 ms, como se muestra en la figura 4(b). La latencia de detección se mostró para cada sujeto y el medio de ellos. La observación directa indica que la latencia promedio de todos los sujetos estuvo entre 0 y 250ms Además, aproximadamente el 70% de las detecciones sucedió dentro de ±500 ms del inicio del movimiento. Además, las distribuciones de latencia de la mayoría de los sujetos (con una excepción del sujeto 8) fueron similares a la media histograma, que indica consistencia en todo el tema piscina.

La Tabla 1 resume todos los sujetos TPR, FPs min⁻¹ y latencias. Muestra la media y la desviación estándar entre sujetos. El sujeto 5 dio el mejor TPR como 96,0%, y el sujeto 8 dio la mejor FP min⁻¹ como 0,9. La latencia más corta la logró el sujeto 7, que es 61,2 ms. La latencia media en todos los sujetos es 75,3 ± 112,6ms.

Los resultados de la clasificación pseudo-online son presentado en la figura 4(c). Para la clasificación entre movimientos hacia la izquierda y hacia la derecha, la prueba ANOVA

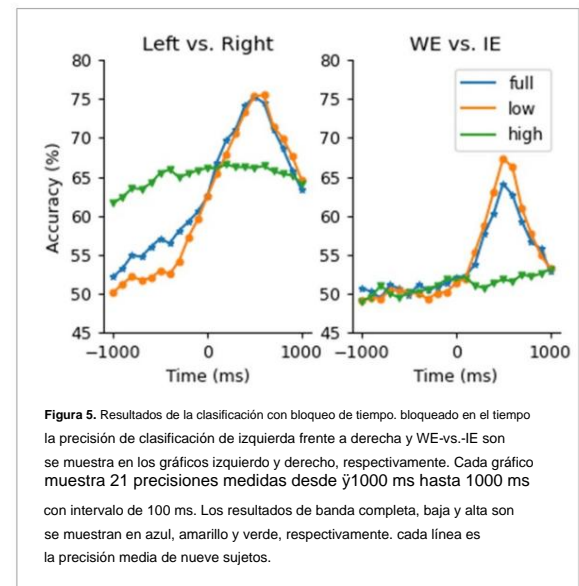


Figura 5. Resultados de la clasificación con bloqueo de tiempo. bloqueado en el tiempo la precisión de clasificación de izquierda frente a derecha y WE-vs.-IE son se muestra en los gráficos izquierdo y derecho, respectivamente. Cada gráfico muestra 21 precisiones medidas desde 1000 ms hasta 1000 ms con intervalo de 100 ms. Los resultados de banda completa, baja y alta son se muestran en azul, amarillo y verde, respectivamente. cada línea es la precisión media de nueve sujetos.

mostró que la banda de frecuencia tuvo un efecto significativo en la precisión de la clasificación (grado de libertad = 2, $F = 6.41$, $p = 0.009$). La gráfica de precisión muestra que el R_Ada_Lgr entrenado en banda alta se desempeñó mejor en términos de la precisión media entre los sujetos. Además, es significativamente mejor que el entrenamiento de banda baja modelo según su agrupación estadística. los matriz de confusión de clasificación normalizada que representa el R_Ada_Lgr entrenado en banda alta indica que el 70% de los movimientos de izquierda y el 67% de los de derecha fueron clasificados correctamente. Para la clasificación entre WE e IE, la prueba ANOVA también indicó que la banda de frecuencia tuvo un efecto significativo en la precisión (grado de libertad = 2, $F = 6.98$, $p = 0.007$). los la precisión del R_Ada_Lgr entrenado en banda completa fue significativamente mejor que el de banda alta en términos de su agrupación estadística. La matriz de confusión normalizada ilustra aún más la precisión de banda completa, mostrando que el 43% de WE y el 65% de IE fueron correctamente clasificados. Observación de diagramas de caja y confusión matriz en la figura 4(c) muestra que la precisión general de clasificación WE-vs.-IE es peor que izquierda-vs.-derecha clasificación.

3.2. Clasificación de bloqueo de tiempo

Las clasificaciones de WE-vs.-IE e izquierda-vs.-derecha también fueron investigados en forma de bloqueo de tiempo utilizando bandas completas, bajas y altas, como se muestra en la figura 5. El precisiones del efecto de bloqueo de tiempo de espectáculo de banda baja y banda completa en ambas clasificaciones. La exactitud las curvas alcanzan sus picos aproximadamente a los 500 ms y luego desplegable. Por el contrario, la banda alta La precisión no tiene una fuerte relación con tiempo. En la clasificación de izquierda frente a derecha, las precisiones de banda completa y baja comienzan en alrededor del 50 % a 1000 ms y lograr picos similares de aproximadamente 75% en 500ms Luego ambos disminuyen a alrededor del 64% en 1000ms Sin embargo, la precisión de banda alta lentamente aumenta de aproximadamente 62% a 1000 ms a

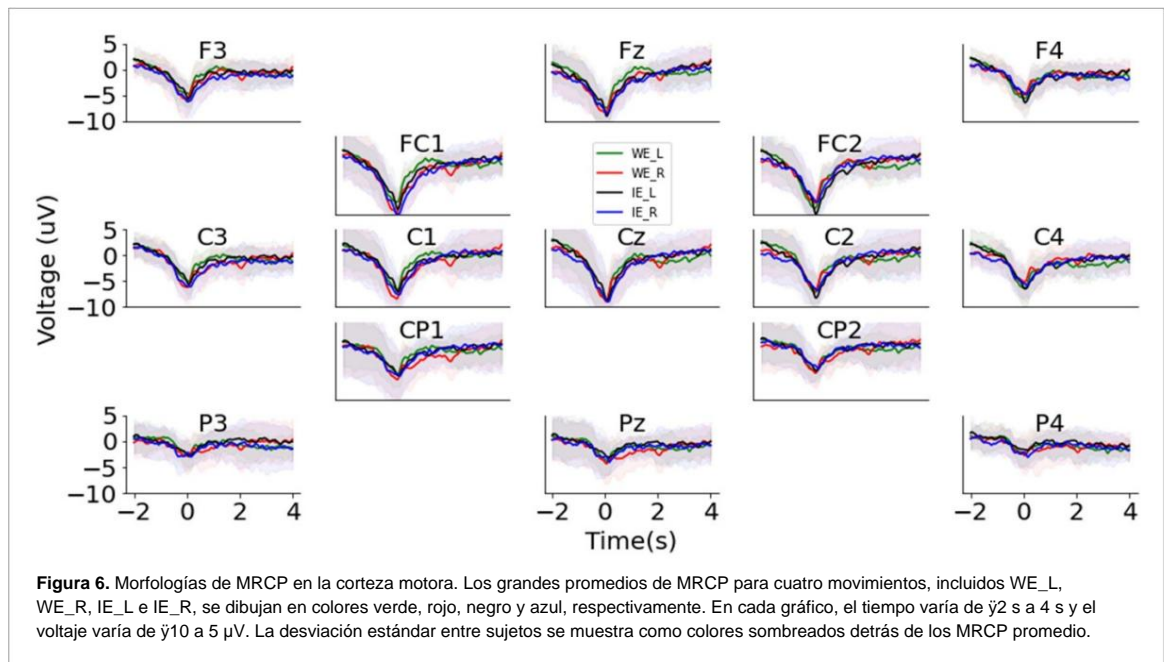


Figura 6. Morfologías de MRCP en la corteza motora. Los grandes promedios de MRCP para cuatro movimientos, incluidos WE_L, WE_R, IE_L e IE_R, se dibujan en colores verde, rojo, negro y azul, respectivamente. En cada gráfico, el tiempo varía de $\bar{y}2$ s a 4 s y el voltaje varía de $\bar{y}10$ a 5 μ V. La desviación estándar entre sujetos se muestra como colores sombreados detrás de los MRCP promedio.

alrededor del 66% a los 200 ms y se mantiene constante después. En la clasificación WE-vs.-IE, las precisiones de banda baja y completa aumentan desde alrededor del 50 % a $\bar{y}1000$ ms y alcanzan picos de 67 % y 64 % a 500 ms, respectivamente. Luego, ambos caen hasta aproximadamente el 53%. Sin embargo, la precisión de banda alta fluctúa alrededor del 51 % entre $\bar{y}1000$ ms y 1000 ms.

Además, las tres bandas muestran que los movimientos de izquierda frente a derecha se clasifican más fácilmente que la clasificación WE frente a IE en la misma extremidad al observar la figura 5.

3.3. CPRM

Los grandes promedios de MRCP se calcularon promediando los MRCP medios para cada sujeto. En la figura 6, podemos ver que los MRCP se identifican de forma difusa sobre la corteza motora con una morfología similar: el potencial de Bereitschaft disminuye bruscamente de $\bar{y}2$ s a 0 s, seguido de una fase de rebote rápido de 0 s a 1 s. Específicamente, los canales frontal, frontal-central y central mostraron amplitudes de MRCP más grandes que otros canales parietales y central-parietales. La amplitud máxima de MRCP de pico a pico es de aproximadamente 12 μ V en FC1, FC2 y Cz. Se puede ver una ligera lateralización en FC1, FC2, C1 y C2. Por ejemplo, la amplitud pico negativa de WE_L es mayor que WE_R en FC2 pero menor que WE_R en FC1. También se encuentra el mismo patrón para IE, la amplitud del pico negativo de IE_L es mayor que IE_R en FC2 y C2, mientras que es ligeramente menor que IE_R en FC1 y C1. Sin embargo, la diferencia de morfología entre WE e IE del mismo lado no se encuentra en la figura 6.

3.4. ERD/ERS La

ERD/ERS de banda alta se calculó para cuatro clases promediando todas las pruebas en nueve sujetos y se muestra en

figura 7. Al observar mapas topográficos, ERD comienza desde $\bar{y}1$ s y muestra una ligera lateralización en WE_L e IE_L sobre FC2, C2 y C4. Luego, ERS emerge de 3 s y se distribuye contralateralmente. Sin embargo, la lateralización no se localiza en canales específicos para ERS. Los ERD/ERS detallados para C1 y C2 se muestran en el diagrama de la derecha de la figura 7. Los ERD de C1 y C2 disminuyen de 0 en $\bar{y}2$ s a alrededor de $\bar{y}30$ % en alrededor de 0 s y luego comienzan a recuperarse. El ERS aparece alrededor de los 3 s y aumenta hasta aproximadamente el 10 % a los 4 s. Se observa la diferencia ERD entre C1 y C2.

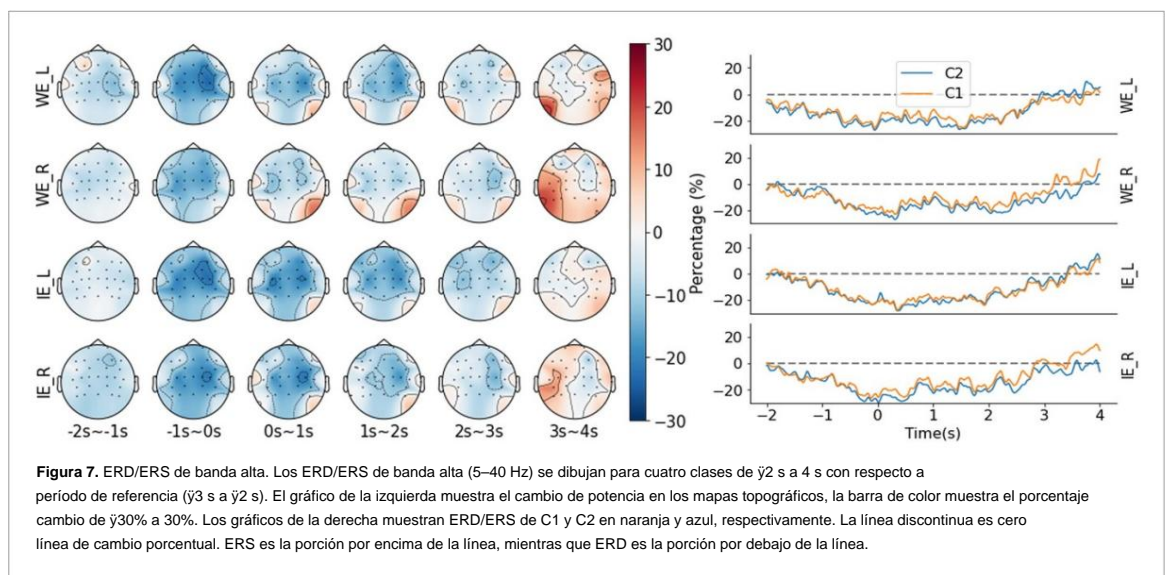
hábil pero sutil. Sin embargo, la diferencia de ERS se pudo encontrar entre 3 s y 4 s. El ERS de C2 es mayor que C1 en tareas WE_L e IE_L, mientras que menor que C1 en tareas WE_R e IE_R. En general, el efecto de bloqueo de tiempo de ERD/ERS es menos prominente que MRCP. Similar a MRCP, el ERD/ERS tampoco da una diferencia observable entre las tareas WE e IE en la misma extremidad.

4. Discusión

4.1. Algoritmo y banda de frecuencia EI

estudio actual investigó el desempeño de tres algoritmos de detección (R_SVM, EEGNET y SVM) y un algoritmo de clasificación (R_Ada_Lgr) en tres bandas de frecuencia diferentes (baja, alta y completa) en el contexto de identificar cuatro motores diferentes. voliciones de las señales de EEG.

En detección, se encontraron diferencias entre bandas de frecuencia en casi todos los clasificadores. De acuerdo con la figura 3, el puntaje F1 de la banda completa es significativamente mejor que el de la banda alta para todos los clasificadores. Además, la banda baja también es generalmente mejor que la banda alta, aunque no todos los clasificadores mostraron diferencias significativas. La morfología de MRCP y ERD/ERS podría explicar esta preferencia en la banda baja y completa sobre



la banda alta. Evidentemente de las figuras 6 y 7, MRCP tiene un pico negativo claro, que está bloqueado en el tiempo para inicio del movimiento. Esta característica de bloqueo de tiempo de MRCP es más pronunciada que cualquier característica de ERD/ERS. Se puede inferir que MRCP contiene enfermedades críticas información criminal en la detección de movimiento balístico cuando se requiere consistencia en la latencia de detección, como en aplicaciones que se centran en la plasticidad neuronal inducción.

En clasificación pseudo-online, bandas de frecuencia también mostró un impacto en el rendimiento. Figura 4(c) mostró que la banda alta se desempeñó significativamente mejor que la banda baja al clasificar entre movimientos hacia la izquierda y hacia la derecha, lo que sugiere que la valiosa información para la clasificación lateral existe en ERD/ERS. Esto es apoyado por el contra-lateral activación de ERD/ERS mostrada en mapas topográficos (figura 7). Sin embargo, la clasificación entre WE e IE presentaron un escenario diferente. la banda completa proporcionó el mejor rendimiento y fue significativamente mejor que la banda alta, como se muestra en la figura 4(c). Dado que ni el MRCP ni el ERD/ERS mostraron un diferencia notable entre WE e IE, la banda completa podría integrar información útil de la otras dos bandas.

Los análisis de diferentes bandas de frecuencia revelaron diferentes comportamientos de clasificación relacionados con el tiempo también. Como se muestra en la figura 5, la precisión de banda alta no fue sensible al tiempo en ambas tareas de clasificación, mientras que el la banda completa y la banda baja tenían un claro efecto de bloqueo de tiempo. Esto podría explicarse por una morfología más abrupta cambio en MRCP que ERD/ERS entre $\gamma 1$ s y 1 s observando las figuras 6 y 7.

Los clasificadores tenían sus preferencias sobre la frecuencia. bandas. Por ejemplo, R_SVM y EEGNET lograron la puntuación F1 más alta con datos de banda completa, mientras que SVM se desempeñó mejor con datos de banda baja. No fue sorprendente que EEGNET se desempeñara bien en la banda completa ya que se asemeja a las propiedades del algoritmo de patrón espacial común del banco de filtros, que requiere una amplia

ancho de banda de frecuencia para generar varios temporales características [38]. Método basado en la geometría de Riemann también demostró su eficacia en varias bandas de frecuencia de EEG como 8–30 Hz para imágenes motoras, 1–16 Hz para ERP y frecuencias individuales para SSVEP [35, 50–52]. Sin embargo, al leer saber y entender de los autores, El EEG de banda completa nunca se usó con el Riemann método de la geometría niana. El mejor desempeño de Método de la geometría de Riemann en la banda completa sobre las otras dos bandas podrían proporcionar un nuevo ángulo para este algoritmo en el contexto del EEG sensoriomotor descodificación. SVM prefirió EEG de banda baja, que está en línea con varios estudios MRCP en la literatura que

logró resultados de última generación utilizando SVM [53, 54].

El método de conjunto se construyó por votación mayoritaria de los tres clasificadores. Después de pruebas de bandas de frecuencia individuales en algoritmos, EEGNET de banda completa, Se seleccionaron SVM de banda baja y R_SVM de banda completa como submodelos para el clasificador de conjunto. Como Como resultado, este clasificador mostró resultados significativamente mejores en las puntuaciones de F1 que seis algoritmos, como se mencionó. en la sección 3.1. Además, su curva ROC también fue mejor de tres submodelos entrenados en sus mejores bandas, como se muestra en la figura 4(a).

4.2. Detección

El análisis pseudo-en línea fue ampliamente utilizado en el BCI campo para simular el procesamiento de EEG en tiempo real, particularmente en análisis de varios hiperparámetros de tubería, que no son prácticos para realizar completamente en línea [13, 14, 27, 32, 55, 56]. Es un enfoque más realista. que el procesamiento fuera de línea tradicional basado en épocas porque los datos fueron tratados como ventanas de tiempo com ing a través de clasificadores como si fueran procesados en línea. Un mayor desarrollo de los estudios en línea beneficiarse de las experiencias adquiridas en pseudo análisis en línea. Entre estos estudios, hubo algunos discrepancias en cómo deben construirse los datos de prueba. Por ejemplo, algunos estudios probaron en ensayos individuales, la solidez de estos pseudo-online

los análisis serán limitados si los ensayos de prueba son porciones cortas preseleccionadas que podrían no representar el estado de reposo real [27, 34]. Para parecerse más al escenario en tiempo real, nuestros datos de prueba utilizaron grabaciones completas y continuas de corridas experimentales de aproximadamente 10 minutos de duración, y no se realizaron selecciones manuales de ensayos en la ejecución de la prueba.

El pseudo-online del estudio actual mostró se detectaron con éxito cuatro movimientos con TPR promedio de $79,6\% \pm 8,8\%$ y FP promedio min^{-1} como $3,1 \pm 1,2$. Una buena cantidad de estudios pseudo-online eligió el TPR y FP min^{-1} como métricas de rendimiento [14, 55, 56]. Un estudio investigó la volición de pedaleo y logró un $76,7\%$ de TPR con $4,94$ FP min^{-1} en cinco sujetos sanos [55]. Otro periódico informó $68,67\%$ TPR y $18,09$ FPs min^{-1} en intención de marcha investigación cuando la especificidad preestablecida es del 70% [56]. Aunque la mayoría de los estudios todavía están fuera de línea o etapas pseudo-online, una demostró la posibilidad de detectar movimientos de las extremidades superiores en tiempo real en un paciente con LME [33]. La contracción LDA se utilizó para detectar y clasificar MRCP para dos movimientos (mano agarre abierto y palmar) en tiempo real. En la mejor sesión, el rendimiento de detección dio $36,9\%$ TPR y $3,6$ FP min^{-1} . El TPR bajo en este estudio podría ser afectado por el pequeño número de muestra, no saludable participantes y desafíos en el diseño de sistemas en línea [33]. Un estudio siguiente investigó la detección de alcance y agarre en 20 participantes no discapacitados en escenario en línea teniendo en cuenta el cambio de mirada [57]. Propusieron una clasificación jerárquica para detectar primero el movimiento del reposo y luego diferenciar movimiento tiate de mirar. La evaluación en línea logró TPR de 54% y $1,7$ FPs min^{-1} en reposo. Sus TPR fue más bajo que el nuestro pero tuvo mejores FPs min^{-1} . Sin embargo, una comparación directa es difícil debido a las diferentes protocolo experimental.

La latencia de detección es un factor crucial para dispositivos BCI destinados a la rehabilitación, ya que la plasticidad de Hebbian solo podía inducirse dentro de un ciclo cerrado corto retraso [11]. En el contexto BCI, la detección de la voluntad del algoritmo EEG debe ocurrir dentro de $400\text{--}500$ ms del inicio de la voluntad. De lo contrario, la causa relación entre la volición y la retroalimentación aferente generada por la BCI se vería comprometida [10]. En este estudio, la latencia promedio fue de $75,3 \pm 112,6$ ms, que está en este rango. Las BCI de latencia corta se basan principalmente sobre las características de MRCP en la decodificación del movimiento campo, mientras que pocos estudios de SMR mencionaron sus latencias [12-14, 19, 20]. En este estudio actual, tanto el EEG de banda completa como el de banda baja contribuyeron a la detección y obtuvo un rendimiento de latencia corta, lo que sugiere EEG de banda completa tiene el potencial para BCI de latencia corta diseño cuando incluye MRCP.

Las latencias eran normalmente examinadas por promedio entre sujetos y desviación estándar [10, 12-14, 27]. Sin embargo, el intrasujeto la variabilidad de la latencia se pasó por alto en gran medida. en un verdadero aplicación de rehabilitación, solo aquellas detecciones

hecho dentro de la inducción de plasticidad óptima período podrían considerarse ensayos útiles. Como figura 4(b) muestra, alrededor del 70% de los ensayos se detectaron entre ~ 500 ms y 500 ms, aunque la latencia a nivel de grupo es $75,3 \pm 112,6$ ms. Futuros estudios deberían considerar esto para probar la eficacia del sistema.

4.3. Clasificación

Dos tipos de clasificación, incluida la izquierda frente a la derecha y WE-vs.-IE, fueron investigados en pseudo-online y modales bloqueados en el tiempo. En general, podemos encontrar que la clasificación izquierda vs. derecha tuvo un mejor desempeño que Clasificación WE-vs.-IE en todas las bandas de ambas maneras, como se muestra en las figuras 4(c) y 5. Esto está en línea con los hallazgos de MRCP y ERD/ERS, que muestran sutiles diferencia en los movimientos contralaterales pero no difieren encia entre movimientos ipsilaterales.

A partir del análisis de clasificación temporal en figura 5, podemos encontrar un claro pico de precisión alrededor de 500 ms después del inicio del movimiento para banda baja y banda completa EEG. Esto indicó la información más diferenciable de estas dos bandas ubicadas en ~ 1.5 s a 0.5 s con respecto al inicio, lo cual es consistente con el período de MRCP. Sin embargo, la precisión de la banda alta no muestra un cambio sensible al tiempo, que es en línea con la forma suave de ERD/ERS a la derecha trama de la figura 7.

La clasificación pseudo-en línea se realizó en detecciones revestidas. Dado que los efectos de bloqueo de tiempo existen en las bandas bajas y completas, es importante tener en cuenta que la latencia de detección podría afectar significativamente la rendimiento de la clasificación posterior. Por ejemplo, una prueba detectada en 500 ms después del inicio del movimiento tendría la mejor oportunidad de ser clasificado correctamente por la banda baja y completa porque sus precisiones fueron los más altos aproximadamente 500 ms, como se muestra en figura 5. Sin embargo, la distribución de la latencia de detección de la figura 4(b) muestra una gran variabilidad entre ~ 1000 ms y 1000 ms, lo que lleva a algo peor resultados de clasificación en pseudo-clasificación en línea. A diferencia de la banda baja y la banda completa, la banda alta no mostrar un claro efecto de bloqueo de tiempo. En la clasificación de izquierda frente a derecha, su precisión relativamente estable en torno al 64% en la clasificación de bloqueo de tiempo (figura 5) siempre que el mejor precisión media en la clasificación pseudo-en línea (ver figura 4(c)), liderando una significativamente más robusta rendimiento general del sistema. Sin embargo, en la clasificación WE-vs.-IE, la banda alta mostró niveles bajos constantes. precisión durante el período de detección, por lo que es el peor banda en clasificación pseudo-online.

4.4. Limitaciones del estudio

Aunque este estudio proporcionó una detección de última generación solución en detección pseudo-online, las clasificaciones entre movimientos ipsilaterales están lejos de ser prácticas. Podría valer la pena investigar futuras investigaciones sobre el bloqueo del mejor período de clasificación después de la detección. Otra limitación importante es que este estudio aún realiza un análisis fuera de línea posterior al experimento. los

El estudio actual no exploró por completo muchos de los desafíos del procesamiento en tiempo real, incluidos el diseño de filtros, las latencias computacionales y el análisis de complejidad de los clasificadores.

5. Conclusión

Este estudio ha demostrado la viabilidad de detectar movimientos distales simples de las extremidades superiores (WE_L, WE_R, IE_L, IE_R) en un escenario pseudo-en línea. Se propuso un método de aprendizaje conjunto para detectar intenciones de movimiento utilizando características de bandas mixtas.

Dentro de nueve sujetos, el mejor caso muestra que el 96 % de las intenciones se detectaron en el sujeto 5, y menos de una ventana sin movimiento se clasificó erróneamente por minuto en el sujeto 8. Siete de los nueve sujetos, las intenciones de movimiento se predijeron con una latencia de 100 ms en promedio. El siguiente paso de clasificación también demuestra su posibilidad de diferenciar los movimientos laterales con una precisión de alrededor del 67% utilizando EEG de banda alta. Investigaciones posteriores mostraron que hay un efecto de bloqueo de tiempo en la clasificación en la banda baja y completa. Las exploraciones en MRCP y ERD/ERS revelaron diferentes patrones de movimientos EEG y explicaron los resultados de detección y clasificación.

Declaración de disponibilidad de datos

Los datos generados y/o analizados durante el estudio actual no están disponibles públicamente por razones éticas/legales, pero están disponibles del autor correspondiente a pedido razonable.

Expresiones de gratitud

Este trabajo fue apoyado por la Universidad de Sichuan del Hospital de China Occidental; y Ministerio de Investigación, Innovación y Ciencia de Ontario. Los autores desean agradecer a todos los participantes por contribuir con su tiempo y esfuerzo a la parte experimental de este estudio.

ID de ORCID

Jiansheng Niu <https://orcid.org/0000-0001-8002-4691> _ Ning Jiang <https://orcid.org/0000-0003-1579-3114> _

Referencias

- [1] Abiri R, Borhani S, Sellers EW, Jiang Y y Zhao X 2019 Una revisión exhaustiva de los paradigmas de interfaz cerebro-computadora basados en EEG *J. Neural. Ing.* **dieciséis** 011001 [2] Jackson A y Zimmermann JB 2012 Interfaces neuronales para el cerebro y la médula espinal: restauración de la función motora *Nat. Rev. Neurol.* **8** 690
- [3] Ang KK y Guan C 2013 Interfaz cerebro-computadora en rehabilitación de accidentes cerebrovasculares *J. Comput. ciencia Ing.* **7** 139–46 [4] Cervera MA, Soekadar SR, Ushiba J, Millan JDR, Liu M, Birbaumer N y Garipelli G. 2018 Computación cerebral interfaces para la rehabilitación motora posterior al accidente cerebrovascular: un metanálisis *Ann. clin. Traducir Neurol.* **5** 651–
- [5] Langhorne P, Coupar F y Pollock A 2009 Recuperación motora después de un accidente cerebrovascular: una revisión sistemática *Lancet Neurol.* **8** 741–54 [6] Dobkin BH 2004 Estrategias para la rehabilitación del accidente cerebrovascular *Lancet Neurol.* **3** 528–36
- [7] Al-Quraishi MS, Elamvazuthi I, Daud SA, Parasuraman S y Borboni A 2018 Control basado en EEG para exoesqueletos y prótesis de miembros superiores e inferiores: una revisión sistemática *Sensores* **18** 3342
- [8] Hortal E, Planillas D, Resquin F, Clemente JM, Azorín JM y Pons JL 2015 Uso de una interfaz cerebro-máquina para controlar un exoesqueleto híbrido de miembro superior durante la rehabilitación de pacientes con enfermedades neurológicas *J. Neuroeng. rehabilitación* **12** 1–6
- [9] Bhagat NA *et al* 2016 Diseño y optimización de un Interfaz cerebro-máquina (BMI) basada en EEG para un exoesqueleto de miembro superior para sobrevivientes de accidentes cerebrovasculares *Fronte. Neurosci.* **10** 122 [10] Xu R, Jiang N, Mrachacz-Kersting N, Lin C, Prieto GA, Moreno JC, Pons JL, Dremstrup K y Farina D 2014 Una interfaz cerebro-computadora de circuito cerrado que desencadena una ortesis activa de tobillo y pie para inducir cortical plasticidad neuronal *IEEE Trans. biomedicina Ing.* **61** 2092–101 [11] Mrachacz-Kersting N, Kristensen SR, Niazik IK y Farina D 2012 La asociación temporal precisa entre los potenciales corticales evocados por la imaginación motora y la aferencia induce la plasticidad cortical *J. Physiol.* **590** 1669–82 [12] Xu R, Jiang N, Lin C, Mrachacz-Kersting N, Dremstrup K y Farina D 2013 Detección mejorada de baja latencia de intención motora de EEG para aplicaciones de interfaz cerebro-computadora de circuito cerrado *IEEE Trans. biomedicina Ing.* **61** 288–96
- [13] Xu R, Jiang N, Mrachacz-Kersting N, Dremstrup K y Farina D 2016 Factores de influencia en el desempeño de un interruptor cerebral no invasivo de latencia corta: evidencia en individuos sanos e implicación para la rehabilitación de la función motora *Front. Neurosci.* **9** 527
- [14] Niazik IK, Jiang N, Tiberghien O, Nielsen JF, Dremstrup K y Farina D 2011 Detección de la intención de movimiento a partir de potenciales corticales relacionados con el movimiento de prueba única *J. Neural. Ing.* **8** 066009 [15] Ofner P, Schwarz A, Pereira J, Wyss D, Wildburger R y Müller-Putz GR 2019 Los intentos de movimiento del brazo y la mano pueden decodificarse a partir del EEG de baja frecuencia de personas con lesión de la médula espinal *Sci. Rep.* **9** 7134
- [16] Ofner P, Schwarz A, Pereira J, Müller-Putz GR y Zhang D 2017 Los movimientos de las extremidades superiores se pueden decodificar desde el dominio del tiempo de EEG de baja frecuencia *PLoS One* **12** e0182578
- [17] Wright DJ, Holmes PS y Smith D 2011 Usando el potencial cortical relacionado con el movimiento para estudiar el aprendizaje de habilidades motoras *J. Mot. Comportamiento* **43** 193–201
- [18] Chu Y, Zhao X, Zou Y, Xu W, Song G, Han J y Zhao Y 2020 Decodificación de imágenes motoras multiclase EEG del mismo miembro superior mediante la combinación de características de geometría riemanniana y regresión de mínimos cuadrados parciales *J. Neural. Ing.* **17** 046029
- [19] Schwarz A, Scherer R, Steyrl D, Faller J y Müller-Putz GR 2015 Una interfaz cerebro-computadora de ritmos motores sensoriales coadaptativos basada en patrones espaciales comunes y bosque aleatorio 2015 37th Annual Int. Conf. Sociedad de Ingeniería en Medicina y Biología del IEEE (EMBC) (25 de agosto de 2015) (IEEE) págs. 1049–52
- [20] Pfurtscheller G, Brunner C, Schlögl A y Da Silva FH 2006 Sincronización del ritmo Mu (des) y clasificación EEG de prueba única de diferentes tareas de imágenes motoras *NeuroImage* **31** 153–9
- [21] Bai O, Lin P, Vorbach S, Li J, Furlani S y Hallett M 2007 Exploración de métodos computacionales para la clasificación de la intención de movimiento durante el movimiento voluntario humano a partir de un solo ensayo EEG *Clin. Neurofisiol.* **118** 2637–55 [22] López-Larraz E, Montesano L, Gil-Agudo A and Minguez J 2014 Decodificación continua de la intención de movimiento de los movimientos analíticos autoiniciados de miembros superiores a partir de correlatos EEG previos al movimiento *J. Neuroeng. rehabilitación* **11** 1–5

- [23] Sburlea AI, Montesano L, de la Cuerda RC, Alguacil Diego IM, Miangolarra-Page JC and Minguez J 2015 Detección de la intención de caminar en pacientes con accidente cerebrovascular a partir de correlaciones EEG previas al movimiento *J. Neuroeng. rehabilitación* **12** 1–2
- [24] Yi W, Qiu S, Qi H, Zhang L, Wan B y Ming D 2013 Comparación de características EEG y clasificación de imágenes motoras de extremidades simples y compuestas *J. Neuroeng. rehabilitación* **10** 1–2
- [25] Yi W, Qiu S, Wang K, Qi H, Zhang L, Zhou P, He F, Ming D y Maurits NM 2014 Evaluación de los patrones oscilatorios del EEG y el proceso cognitivo durante la visualización de imágenes motoras de extremidades simples y compuestas *PLoS One* **9** e114853
- [26] Lew E, Chavarriaga R, Silvoni S y Millán JD 2017 Detección de intención de movimiento de alcance a ritmo propio a partir de señales EEG *Frontal. neuroing.* **5** 13
- [27] Randazzo L, Iturrate I, Chavarriaga R, Leeb R y Millán JD 2015 Detección de intención de agarrar durante movimientos de alcance de EEG 2015 37th Annual Int. Conf. IEEE Engineering in Medicine and Biology Society (EMBC) (25 de agosto de 2015) (IEEE) pp 1115–8 [28] Jankelowitz S y Colebatch J 2002 Relacionado con el movimiento
- potenciales asociados con movimientos de brazos imaginados, con indicaciones y a su propio ritmo *Exp. Res. cerebral.* **147** 98–107 [29] Pereira J, Ofner P, Schwarz A, Sburlea AI y Müller-Putz GR 2017 Correlatos neurales del EEG de la intención de movimiento dirigida a un objetivo *Neuroimagen* **149** 129–40 [30] Pereira J, Sburlea AI y Müller-Putz GR 2018 EEG
- patrones de imaginaciones de movimiento a su propio ritmo hacia objetivos con indicaciones externas y seleccionados internamente *Sci. Reps.* **8** 13394
- [31] Schwarz A, Ofner P, Pereira J, Sburlea AI y Müller-Putz GR 2017 Decodificación de acciones naturales de alcance y agarre del EEG humano *J. Neural. Ing.* **15** 016005 [32] Hernández-Rojas LG, Montoya OM y Antelis JM 2020 Detección anticipada de movimientos de rehabilitación a ritmo propio en la misma extremidad superior a partir de señales EEG *IEEE Access* **8** 119728–43
- [33] Ofner P, Pereira J, Schwarz A y Müller-Putz GR 2019 Detección en línea de intentos de agarre de mano abierta vs palmar en una persona con lesión de la médula espinal *Proc. 8ª Conferencia de Interfaz Cerebro-Computadora de Graz. 2019 (septiembre de 2019)*
- [34] Omedes J, Schwarz A, Montesano L y Müller-Putz G 2017 Descodificación jerárquica de comandos de agarre de EEG 2017 39th Annual Int. Conf. Sociedad de Ingeniería en Medicina y Biología del IEEE (EMBC) (11 de julio de 2017) (IEEE) págs. 2085–8 [35] Congedo M, Barachant A y Bhatia R 2017 Geometría de Riemann para interfaces cerebro-computadora basadas en EEG; una cartilla y una revisión *Brain-Comput. Interfaces* **4** 155–74 [36] Guan S, Zhao K y Yang S 2019 Clasificación de EEG de imágenes motoras basada en el marco del árbol de decisión y el cálculo de la geometría de Riemann. *Intel. Neurosci.* **2019** 5627156
- [37] Gaur P, McCreddie K, Pachori RB, Wang H y Prasad G 2019 Modelo de clasificación de aprendizaje de transferencia basado en características de espacio tangente para interfaz cerebro-computadora de imágenes motoras de dos clases *Int. J. Neural Syst.* **29** 1950025 [38] Lawhern VJ, Solon AJ, Waytowich NR, Gordon SM, Hung CP y Lance BJ 2018 EEGNet: una red neuronal convolucional compacta para interfaces cerebro-computadora basadas en EEG *J. Neural. Ing.* **15** 056013 [39] Roy Y, Banville H, Albuquerque I, Gramfort A, Falk TH y Faubert J 2019 Análisis de electroencefalografía basado en aprendizaje profundo: una revisión sistemática *J. Neural. Ing.* **diciesis** 051001 [40] Mane R, Chew E, Chua K, Ang KK, Robinson N, Vinod AP, Lee SW y Guan C 2021 FBCNet: una vista múltiple
- red neuronal convolucional para interfaz cerebro-computadora (arXiv:2104.01233)
- [41] Zhang X, Xu G, Mou X, Ravi A, Li M, Wang Y y Jiang N 2019 Una red neuronal convolucional para la detección de potencial evocado visual de movimiento asincrónico en estado estacionario *IEEE Trans. Neural. sist. rehabilitación Ing.* **27** 1303–11 [42] Chen M, Zhang X, Chen X, Zhu M, Li G y Zhou P 2016 FastICA peel-off para la eliminación de interferencias de ECG de superficie EMG *Biomed. Ing. En línea* **15** 1
- [43] Solnik S, DeVita P, Rider P, Long B y Hortobágyi T 2008 El operador Teager-Kaiser mejora la precisión de la detección de inicio de EMG independientemente de la relación señal-ruido *Acta Bioeng. Biomecánica.* **10**
- 65 [44] Liu D, Chen W, Chavarriaga R, Pei Z y Millán JDR 2017 Decodificación de la intención de movimiento autodirigido de las extremidades inferiores: un estudio de caso sobre los factores de influencia *Front. Tararear. Neurosci.* **11** 560
- [45] Sburlea AI, Montesano L y Minguez J 2015 Detección continua del estado previo al movimiento de la marcha autoiniciada a partir de correlaciones de EEG sin recalibración de sesión a sesión *J. Neural. Ing.* **12** 036007 [46] Pfurtscheller G y Da Silva FH 1999 Relacionado con eventos
- Sincronización y desincronización EEG/MEG: principios básicos *Clin. Neurofisiol.* **110** 1842–1857 [47] Gramfort A et al 2013 Análisis de datos MEG y EEG con MNE-Python *Front. Neurosci.* **7** 267 [48] Yger F, Berar M y Lotte F 2016 Enfoques riemannianos en interfaces cerebro-computadora: una revisión *IEEE Trans. Neural. sist. rehabilitación Ing.* **25** 1753–62
- [49] Minitab LLC 2021 *Minitab* (disponible en: <https://support.minitab.com/en-us/minitab/18/help-and-how-to/modeling-statistics/anova/how-to/one-way-anova/methods-and-formulas/grouping-information-table/>) (Consultado el 19 de marzo de 2022)
- [50] Transferencia de Kalunga EK, Chevallier S y Barthélemy Q 2018 Aprendizaje para BCI basado en SSVEP utilizando similitudes riemannianas entre usuarios 2018 26th European Signal Processing Conf. (EUSIPCO) (3 de septiembre de 2018) (IEEE) pp 1685–9 [51] Chevallier S, Kalunga E, Barthélemy Q y Yger F 2018 Clasificación de Riemann para BCI basada en SSVEP: implementaciones fuera de línea versus en línea Manual de interfaces cerebro-computadora: tecnológico y teórico Avances (Boca Raton, FL: CRC Press)
- [52] Barachant A, Bonnet S, Congedo M y Jutten C 2013 Clasificación de matrices de covarianza usando un núcleo basado en Riemann para aplicaciones BCI *Neurocomputación* **112** 172–8 [53] Jochumsen M, Niazi IK, Mrachacz-Kersting N, Farina D y Dremstrup K 2013 Detección y clasificación de potenciales corticales relacionados con el movimiento asociados con la fuerza de tarea y la velocidad *J. Neural. Ing.* **10** 056015 [54] Wang J, Bi L, Fei W y Guan C 2020 Decodificación de direcciones de movimiento de una mano y ambas manos a partir de señales neuronales no invasivas *IEEE Trans. biomedicina Ing.* **68** 1932–1940 [55] Rodríguez-Ugarte M, Iáñez E, Ortíz M y Azorín JM 2017 Modelos BCI personalizados offline y pseudo-online para detectar intención de pedaleo *Front. Neuroinformar.* **11** 45 [56] Hasan SS, Siddiquee MR y Bai O supervisados
- clasificación de señales de EEG con regulación de umbral de puntuación para detección asincrónica pseudo-en línea de intención de marcha 2019 18th IEEE Int. Conf. on Machine Learning and Applications (ICMLA) (16 de diciembre de 2019) (IEEE) págs. 1476–9 [57] Pereira J, Kobler R, Ofner P, Schwarz A y Müller-Putz GR 2021 Detección en línea de movimiento durante procesos naturales y autoiniciados Acciones de alcance y agarre de señales EEG *J. Neural. Ing.* **18** 046095